

Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal

Rafael da Silva Melo¹

¹Universidade Federal de Goiás – Regional Catalão (UFG)
Catalão – GO – Brasil

Orientador: Prof. Dr. Márcio de Souza Dias

rafael.melo@discente.ufcat.edu.br

Abstract. *This paper presents a hybrid **deep learning** model (CNN+LSTM) to predict the **direction of price movements** in 15-minute intraday bars on the Brazilian stock exchange B3. The work incorporates **liquidity**, **volatility** and volume data, along with **feature engineering** and a **sliding temporal validation** (walk-forward) methodology to avoid information leakage and obtain a realistic evaluation. The model was compared to classical baselines (Naive, ARIMA, Prophet) on three liquid assets (PETR4, VALE3, ITUB4), from October 2020 to October 2025. Results show marginal gains in directional accuracy for the hybrid model, but without statistical significance in the Diebold–Mariano test; in part of the test blocks, class collapse was observed, with almost constant probabilities. The main contribution lies in the reproducible **methodological protocol** — temporal validation, prevention of data leakage, backtests with explicit costs — which can be reused for other architectures and assets.*

Resumo. *Este artigo apresenta um modelo híbrido de **aprendizado profundo** (CNN+LSTM) para prever a **direção do movimento de preços** em barras intradiárias de 15 minutos na bolsa brasileira B3. O trabalho incorpora dados de **liquidez**, **volatilidade** e volume, além de **engenharia de características** e uma metodologia de **validação temporal deslizante** (walk-forward) para evitar vazamento de informação e obter avaliação realista. O modelo foi comparado a referências clássicas (Naive, ARIMA, Prophet) em três ativos líquidos (PETR4, VALE3, ITUB4), com período de outubro de 2020 a outubro de 2025. Os resultados indicam ganhos marginais de acurácia direcional para o híbrido, porém sem significância estatística no teste de Diebold–Mariano; em parte dos blocos de teste observou-se colapso de classe, com probabilidades quase constantes. A principal contribuição reside no **protocolo metodológico** reprodutível — validação temporal, prevenção de data leakage, backtests com custos explícitos —, que pode ser reutilizado para outras arquiteturas e ativos.*

Palavras-chave: *predição financeira; séries temporais; aprendizado profundo; CNN-LSTM; B3; validação walk-forward.*

1. Introdução

As bolsas de valores funcionam como infraestruturas em que compradores e vendedores negociam ativos sob regras e supervisão, ajudando na formação de preços e na alocação de recursos [Mishkin and Eakins 2018, Bodie et al. 2021]. No Brasil, a B3 — Brasil, Bolsa,

Balcão — concentra negociação, registro, compensação e liquidação, sob marcos como a Lei do Mercado de Valores Mobiliários e a Lei das S.A. Os preços refletem expectativas sobre fluxos de caixa e risco, mas também exibem **volatilidade** e variação de **liquidez** que tornam a previsão de curto prazo um desafio tanto teórico quanto prático.

No horizonte **intradiário** aparecem questões clássicas de *microestrutura*: periodicidades ao longo do dia, intervalos irregulares entre negócios e impacto do **spread** e do custo de imediatismo [Andersen and Bollerslev 1997, Hasbrouck 2007]. Choques macroeconômicos e eventos externos podem deslocar as cotações rapidamente. Esse cenário motiva a busca por métodos preditivos que respeitem a ordem do tempo e as particularidades do mercado brasileiro.

Embora a ideia de que o mercado seja perfeitamente previsível seja indefensável, muitos investidores e pesquisadores procuram padrões que permitam melhorar decisões. Neste estudo, adotamos um modelo híbrido que combina **redes convolucionais** (CNN) e **redes recorrentes** do tipo **LSTM**: as primeiras capturam padrões locais em janelas deslizantes; as segundas, dependências de longo prazo. A escolha se apoia em evidências de que LSTMs representam melhor relações não lineares e sequências longas, enquanto convoluções extraem motivos de curto prazo; juntas, buscam-se maior robustez a ruído e a mudanças de regime.

Os alvos preditivos considerados são a **direção do retorno** na próxima barra (alta ou baixa), medidas de volatilidade intradiária e sinais relacionados a liquidez. Para assegurar comparabilidade e realismo, os resultados são confrontados com **modelos de referência** (*baselines*) estatísticos (ARIMA, Prophet) e com validação **temporal deslizante** (*walk-forward*), sem uso de informação futura no treino. O foco está em estabilidade e reprodutibilidade, e na pergunta: em que condições um modelo CNN+LSTM supera comparadores clássicos na previsão direcional intradiária (+1 barra, 15 min) em ações líquidas da B3, quando avaliado com métricas pós-custos?

A Figura 1 resume a tarefa: em uma série de preços intradiária, cada instante gera um vetor de atributos (preço, volume, indicadores técnicos) e o modelo estima a probabilidade de a próxima barra fechar acima ou abaixo da atual. O horizonte é de uma barra à frente, e as janelas de treino e teste avançam no tempo, refletindo o fluxo real do mercado.

2. Desenvolvimento

2.1. Contexto e fundamentação

Em mercados acionários, séries temporais costumam ser decompostas em *tendência*, *sazonalidade*, *ciclos* e ruído [Hyndman and Athanasopoulos 2018, Box et al. 2015, Tsay 2010]. A tendência indica se os preços estão subindo ou caindo no curto prazo; a sazonalidade envolve padrões repetitivos (por exemplo, ao longo do dia); os ciclos são oscilações de médio a longo prazo ligadas a condições econômicas. No horizonte **intradiário**, surgem questões de *microestrutura*: periodicidades ao longo do pregão [Andersen and Bollerslev 1997], duração irregular entre negócios [Engle and Russell 1998], impacto do spread e da liquidez nos preços [Hasbrouck 2007, Amihud 2002, Dufour and Engle 2000]. Modelos clássicos como **ARIMA** e **Prophet** lidam bem com séries estacionárias ou de baixa não linearidade [Box et al. 2015,




Figura 1. Previsão direcional intradiária: horizonte +1 barra (15 min). Fonte: autor.

Taylor and Letham 2018], mas tendem a perder eficácia em mercados muito voláteis, em que pequenos choques podem alterar as projeções [Sunki et al. 2024]. Redes **LSTM** têm se mostrado capazes de capturar dependências temporais longas e relações não lineares [Hochreiter and Schmidhuber 1997, Ding and Qin 2020, Nascimento et al. 2023]; combinações híbridas com convoluções (CNN+LSTM) permitem extrair padrões locais e dependências de longo prazo simultaneamente [Borovykh et al. 2017]. A inclusão de indicadores técnicos (MME, RSI, Bandas de Bollinger) enriquece o conjunto de *features* e ajuda a discriminar entre sinal e ruído [Murphy 1999, Bollinger 2001].

Neste trabalho, consideramos explicitamente a **estacionariedade**: em vez de modelar preços em nível, utilizamos **retornos logarítmicos** $r_t = \ln(P_t) - \ln(P_{t-1})$, o que estabiliza a escala e permite composição aditiva no tempo [Tsay 2010, Dacorogna et al. 2001]. A **volatilidade intradiária** é mensurada em janelas móveis (por exemplo, 20 períodos), e a liquidez é abordada por volume e, quando disponível, spread. Indicadores como **Médias Móveis Exponenciais** (MME), **RSI** (Índice de Força Relativa) e **Bandas de Bollinger** enriquecem o conjunto de *features*, em linha com a literatura de análise técnica [Murphy 1999, Bollinger 2001].

2.2. Trabalhos relacionados

A previsão de preços ou de direção de retornos em mercados acionários com redes neurais e modelos híbridos tem ampla tradição. Ding e Qin [Ding and Qin 2020] utilizaram redes LSTM associadas para prever abertura, mínima e máxima, com ganhos em dados históricos. Nascimento et al. [Nascimento et al. 2023] compararam ARIMA, Prophet e LSTM em séries financeiras e mostraram que redes recorrentes capturam melhor dependências de longo prazo. No Brasil, Rotela Jr. et al. [Rotela Jr et al. 2014] aplicaram ARIMA à previsão do índice Bovespa; Marcondes [Lima Junior 2013] propôs um modelo híbrido combinando redes neurais, técnicas estatísticas e indicadores técnicos via comitê de aprendizado. Assis e colaboradores [Souza et al. 2022] exploraram análise de sentimento aplicada à predição do Ibovespa. Tais trabalhos em geral não avaliam de

forma sistemática a robustez a mudanças de regime nem adotam validação temporal deslizando e backtests com custos explícitos como neste estudo [Tsay 2010, Prado 2018]. Arquiteturas mais recentes, como *Temporal Fusion Transformer* e variantes baseadas em Transformers ou em grandes modelos de linguagem (LLMs), vêm sendo aplicadas a séries temporais e a dados financeiros; há, porém, debate sobre a efetividade prática dos Transformers em previsão de séries [Zeng et al. 2022, Wen et al. 2022]. O presente trabalho restringe-se ao híbrido CNN+LSTM e a baselines clássicos (Naive, Drift, ARIMA, Prophet), com foco em reprodutibilidade e avaliação rigorosa no contexto intradiário da B3 [Lo 2017, Bergmeir and Benítez 2012, Prado 2018].

2.3. Dados e pré-processamento

Os dados foram obtidos via plataforma MetaTrader 5 (MT5), com histórico em barras de **15 minutos** (timeframe M15). O universo compreende três ativos de alta liquidez da B3: **PETR4** (Petrobras), **VALE3** (Vale) e **ITUB4** (Itaú Unibanco), no período de 22 de outubro de 2020 a 22 de outubro de 2025. Cada barra contém variáveis **OHLCV** (abertura, máxima, mínima, fechamento, volume). As séries foram ajustadas por eventos corporativos (desdobramentos, grupamentos, dividendos) e submetidas a tratamento de qualidade (remoção de anomalias, consistência de fuso horário). Para evitar **vazamento de dados** (*data leakage*), a normalização (por exemplo, Min-Max ou Z-Score) é ajustada *apenas* no bloco de treino e depois aplicada ao teste; nenhuma estatística do futuro entra no treinamento [Prado 2018, Bergmeir and Benítez 2012].

Foi adotada uma **banda morta** na rotulagem: retornos com valor absoluto menor que 0,1% são tratados como neutros e excluídos do cálculo da acurácia direcional. Isso aproxima a avaliação da decisão real de comprar ou vender e reduz o peso de microvariações onde o spread domina.

2.4. Modelo proposto e baselines

A arquitetura proposta é um híbrido **CNN-LSTM**: uma camada convolucional unidimensional (Conv1D) extrai padrões locais; em seguida, MaxPooling reduz a dimensão temporal; uma camada LSTM captura dependências de longo prazo; por fim, uma camada densa com ativação sigmoide produz a probabilidade de a próxima barra ser de alta. A janela de entrada (*lookback*) utilizada é de 60 barras, com 12 características (OHLCV processado, retornos, volatilidade móvel, MME, RSI, Bandas de Bollinger em janelas típicas).

Os **baselines** incluem: (i) **Naive** (repetir a última direção); (ii) **Drift** (tendência recente); (iii) **ARIMA**; (iv) **Prophet**. Todos são avaliados sob o mesmo protocolo de validação temporal, com as mesmas métricas e o mesmo particionamento, para garantir comparabilidade.

2.5. Validação temporal e desenho experimental

A validação **walk-forward** funciona assim: em cada *fold* i , o modelo é treinado apenas com dados passados; os hiperparâmetros são escolhidos por otimização bayesiana (Optuna) em uma validação interna contida no bloco de treino. Entre o fim do treino/validação e o início do conjunto de teste é imposto um **embargo temporal** de h observações, para mitigar vazamento de informação. O desempenho é medido no bloco de teste seguinte (Teste $i + 1$). O processo se repete ao longo do tempo, produzindo várias avaliações fora

da amostra; as métricas finais são agregadas sobre os blocos de teste. Esse desenho é fundamental em séries financeiras, pois respeita a causalidade e reduz otimismo indevido [Bergmeir and Benítez 2012, Prado 2018].




Figura 2. Esquema da validação temporal deslizante (walk-forward) com embargo. Fonte: autor.

2.6. Métricas e backtests

A métrica central é a **acurácia direcional** (*hit rate*): proporção de vezes em que a previsão de alta ou baixa coincide com a direção realizada, após aplicar a banda morta. Complementarmente, reportam-se F1-Score, **MCC** (Matthews Correlation Coefficient), **Brier Score** e Log-Loss para qualidade probabilística e calibração. Como acerto estatístico não garante lucro, foram realizados **backtests** com custos explícitos: custo proporcional (emolumentos B3, 0,03%) e **deslizamento de preço** (*slippage*, 0,05%), em estratégias *long-only* e *long/short*. Para verificar se diferenças entre modelos são estatisticamente significativas, aplicou-se o teste de **Diebold–Mariano** [Diebold and Mariano 1995] à série de perdas direcionais e à perda Brier.

2.7. Resultados principais

Os experimentos geraram quatro *folds* de teste por ativo (cada fold com cerca de um mês de barras). Em termos de **acurácia direcional** média, o CNN–LSTM ficou ligeiramente à frente em PETR4 (51,55% contra 50,13% do melhor baseline) e em VALE3 (50,76% contra 50,69% do ARIMA); em ITUB4, o Naive superou o híbrido (51,21% contra 50,83%). De forma geral, todos os modelos operam em uma faixa próxima a 50%, ou seja, ao acaso.

O **MCC** ficou muito próximo de zero em todos os casos ($-0,034$ a $+0,025$), indicando que nenhum modelo discriminou de forma consistente entre as classes alta e baixa. Em 10 dos 12 *folds*, o CNN–LSTM apresentou **colapso de classe**: as probabilidades emitidas tinham desvio-padrão extremamente baixo (0,002 a 0,012), concentrando-se em um lado do limiar 0,5, de modo que o modelo predizia predominantemente uma única direção para todo o bloco. Isso explica o MCC nulo e o número muito baixo de operações nos backtests.

O teste de **Diebold–Mariano** (perda direcional) não rejeitou a hipótese nula de igualdade de desempenho em nenhuma das 12 comparações (3 ativos $\times$ 4 baselines); os

p-valores variaram de 0,071 a 0,967. Na comparação por **perda Brier**, o CNN-LSTM foi significativamente melhor que todos os baselines ($p < 0,001$), o que reflete a natureza probabilística da saída (valores próximos de 0,5 geram perda Brier menor que previsões binárias erradas), e não necessariamente uma capacidade preditiva superior.

Nos **backtests**, PETR4 em modo long/short obteve retorno líquido de 4,10% e Sharpe de 1,41 na média dos folds, mas esse resultado ficou concentrado em um único fold (o que teve MCC positivo e maior dispersão de probabilidades). VALE3 e ITUB4 ficaram próximos do zero ou negativos. A baixa rotatividade (poucas operações) é consequência direta das probabilidades quase constantes.

2.8. Interpretação e limitações

Os resultados são compatíveis com a hipótese de **eficiência semiforte** do mercado para o horizonte e a granularidade estudados: retornos intradiários de 15 minutos em ações líquidas da B3 parecem conter alto ruído e baixa autocorrelação, dificultando a extração de padrões preditivos estáveis. Mostrar que um modelo de deep learning não supera baselines simples nessas condições é, em si, uma contribuição: reforça a importância de avaliações rigorosas (validação temporal, testes de significância, custos de transação) e ajuda a evitar a *ilusão de performance* comum em estudos sem esses controles [Prado 2018].

As limitações identificadas incluem: (i) **signal fraco** em 15 minutos com apenas 12 *features*; (ii) possível mínimo local na paisagem de perda (Binary Cross-Entropy) quando as probabilidades ficam próximas de 0,5; (iii) arquitetura relativamente simples; (iv) tamanho efetivo de treino (cerca de um ano por bloco) que pode ser insuficiente para generalização robusta. O que os resultados *não* invalidam é o protocolo: walk-forward, comparação com baselines, Diebold-Mariano e backtests com custos foram aplicados corretamente e o pipeline é reproduzível.




Figura 3. Heatmap de p-valores do teste de Diebold-Mariano (perda direcional).
Fonte: autor.

3. Conclusão

Este trabalho propôs e avaliou um modelo híbrido CNN–LSTM para **previsão direcional intradiária** (barras de 15 minutos) em três ativos de alta liquidez da B3 (PETR4, VALE3, ITUB4). A abordagem integrou um pipeline completo — da aquisição de dados à avaliação financeira — com ênfase em **validação temporal** rigorosa, prevenção de **data leakage** e reprodutibilidade [Bergmeir and Benítez 2012, Prado 2018].

A principal contribuição não é um ganho de acurácia sobre baselines, mas o **protocolo metodológico**: (i) base intradiária de cinco anos com tratamento de qualidade e ajustes corporativos; (ii) engenharia de 12 características técnicas com rotulagem direcional e banda morta; (iii) validação walk-forward com embargo; (iv) comparação com Naive, Drift, ARIMA e Prophet sob as mesmas condições; (v) otimização bayesiana de hiperparâmetros por fold; (vi) testes de Diebold–Mariano e segmentação por regime de volatilidade; (vii) backtests com custos explícitos em modalidades long-only e long/short; (viii) pipeline reprodutível com sementes fixas e scripts documentados. Esse protocolo pode ser reutilizado para outras arquiteturas, conjuntos de *features* ou granularidades.

Os resultados empíricos indicam que, para os dados e a configuração adotados, o CNN–LSTM não supera os baselines de forma estatisticamente significativa nem de forma financeiramente consistente. O fenômeno de **colapso de classe** em boa parte dos folds e a concentração de resultado positivo em um único cenário (PETR4 long/short em um fold) sugerem que trabalhos futuros podem explorar: granularidades maiores (30 min ou 1 h); *features* adicionais (microestrutura, sentimento, codificação temporal); arquiteturas com atenção (por exemplo, Temporal Fusion Transformer) ou *ensembles*; funções de perda que penalizem a concentração de previsões; e limiares adaptativos por regime. O código e a documentação do pipeline estão disponíveis para reprodução e extensão pela comunidade.

Referências

- Amihud, Y. (2002). Illiquidity and stock returns: Cross-section and time-series effects. *Journal of Financial Markets*, 5(1):31–56.
- Andersen, T. G. and Bollerslev, T. (1997). Intraday periodicity and volatility persistence in financial markets. *Journal of Empirical Finance*, 4(2-3):115–158.
- Bergmeir, C. and Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191:192–213.
- Bodie, Z., Kane, A., and Marcus, A. J. (2021). *Investments*. McGraw-Hill Education, New York, 12 edition.
- Bollinger, J. (2001). *Bollinger on Bollinger Bands*. McGraw-Hill, New York.
- Borovykh, A., Bohte, S., and Oosterlee, C. W. (2017). Conditional time series forecasting with convolutional neural networks.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. Wiley, Hoboken, NJ, 5 edition.
- Dacorogna, M. M., Gençay, R., Müller, U. A., Olsen, R. B., and Pictet, O. V. (2001). *An Introduction to High-Frequency Finance*. Academic Press, San Diego, CA.

- Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.
- Ding, G. and Qin, L. (2020). Study on the prediction of stock price based on the associated network model of lstm. *International Journal of Machine Learning and Cybernetics*, 11(6):1307–1317.
- Dufour, A. and Engle, R. F. (2000). Time and the price impact of a trade. *Journal of Finance*, 55(6):2467–2498.
- Engle, R. F. and Russell, J. R. (1998). Autoregressive conditional duration: A new model for irregularly spaced transaction data. *Econometrica*, 66(5):1127–1162.
- Hasbrouck, J. (2007). *Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading*. Oxford University Press, New York.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Hyndman, R. J. and Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 2 edition.
- Lima Junior, M. M. d. O. (2013). Proposta de um modelo de predição da bolsa de valores utilizando uma abordagem híbrida. Dissertação de mestrado, Universidade Federal do Maranhão, São Luís.
- Lo, A. W. (2017). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press, Princeton, NJ.
- Mishkin, F. S. and Eakins, S. G. (2018). *Financial Markets and Institutions*. Pearson, New York, 9 edition.
- Murphy, J. J. (1999). *Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications*. New York Institute of Finance, New York, 2 edition.
- Nascimento, O. S., Santos, F. G., and Ferreira, K. H. A. (2023). Previsão de preços de ações utilizando inteligência artificial. In *Anais do I Brazilian Workshop on Artificial Intelligence in Finance*, pages 37–47, Porto Alegre, RS, Brasil. Sociedade Brasileira de Computação (SBC).
- Prado, M. L. d. (2018). *Advances in Financial Machine Learning*. Wiley, Hoboken, NJ.
- Rotela Jr, P., Salomon, F. L., and de Oliveira, M. M. (2014). Modelo arima aplicado à previsão do índice bovespa. *Open Journal of Statistics*, 4(5):319–324.
- Souza, Y. G. V., Tarrataca, L., Cardoso, D. O., and Assis, L. S. d. (2022). Sentiment analysis applied to ibovespa prediction. In *Anais do Congresso Brasileiro de Inteligência Computacional (CBIC)*, pages 373–388.
- Sunki, A., SatyaKumar, C., Surya Narayana, G., Koppera, V., and Hakeem, M. (2024). Time series forecasting of stock market using arima, lstm and fb prophet. In *MATEC Web of Conferences – ICMED 2024*, volume 392, page 01163.
- Taylor, S. J. and Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1):37–45.

- Tsay, R. S. (2010). *Analysis of Financial Time Series*. Wiley, Hoboken, NJ, 3 edition.
- Wen, Q., Zhou, T., Zhang, C., Chen, W., Ma, Z., Yan, J., and Sun, L. (2022). Transformers in time series: A survey. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*.
- Zeng, A., Chen, M., Zhang, L., and Xu, Q. (2022). Are transformers effective for time series forecasting? *arXiv preprint arXiv:2205.13504*.