

Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal

Rafael da Silva Melo

Orientador: Prof. Dr. Márcio de Souza Dias

Universidade Federal de Goiás – Regional Catalão

2025

Resumo

Este artigo apresenta um modelo híbrido de **aprendizado profundo** (CNN+LSTM) para prever a **direção do movimento de preços** em barras intradiárias de 15 minutos na bolsa brasileira B3. O trabalho incorpora dados de **liquidez**, **volatilidade** e volume, além de **engenharia de características** e uma metodologia de **validação temporal deslizante** (*walk-forward*) para evitar vazamento de informação e obter avaliação realista. O modelo foi comparado a referências clássicas (Naive, ARIMA, Prophet) em três ativos líquidos (PETR4, VALE3, ITUB4), com período de outubro de 2020 a outubro de 2025. Os resultados indicam ganhos marginais de acurácia direcional para o híbrido, porém sem significância estatística no teste de Diebold–Mariano; em parte dos blocos de teste observou-se *colapso de classe*, com probabilidades quase constantes. A principal contribuição reside no **protocolo metodológico** reproduzível — validação temporal, prevenção de *data leakage*, backtests com custos explícitos —, que pode ser reutilizado para outras arquiteturas e ativos.

Palavras-chave: predição financeira; séries temporais; aprendizado profundo; CNN-LSTM; B3; validação walk-forward.

Sumário

1	Introdução	3
2	Desenvolvimento	3
2.1	Contexto e fundamentação	3
2.2	Dados e pré-processamento	4
2.3	Modelo proposto e baselines	5
2.4	Validação temporal e desenho experimental	5
2.5	Métricas e backtests	5
2.6	Resultados principais	6
2.7	Interpretação e limitações	6
3	Conclusão	6
	Referências	7

1 Introdução

As bolsas de valores funcionam como infraestruturas em que compradores e vendedores negociam ativos sob regras e supervisão, ajudando na formação de preços e na alocação de recursos [Mishkin and Eakins, 2018, Bodie et al., 2021]. No Brasil, a B3 — Brasil, Bolsa, Balcão — concentra negociação, registro, compensação e liquidação, sob marcos como a Lei do Mercado de Valores Mobiliários e a Lei das S.A. Os preços refletem expectativas sobre fluxos de caixa e risco, mas também exibem **volatilidade** e variação de **liquidez** que tornam a previsão de curto prazo um desafio tanto teórico quanto prático.

No horizonte **intradiário** aparecem questões clássicas de *microestrutura*: periodicidades ao longo do dia, intervalos irregulares entre negócios e impacto do **spread** e do custo de imediatismo. Choques macroeconômicos e eventos externos podem deslocar as cotações rapidamente. Esse cenário motiva a busca por métodos preditivos que respeitem a ordem do tempo e as particularidades do mercado brasileiro.

Embora a ideia de que o mercado seja perfeitamente previsível seja indefensável, muitos investidores e pesquisadores procuram padrões que permitam melhorar decisões. Neste estudo, adotamos um modelo híbrido que combina **redes convolucionais** (CNN) e **redes recorrentes** do tipo **LSTM**: as primeiras capturam padrões locais em janelas deslizantes; as segundas, dependências de longo prazo. A escolha se apoia em evidências de que LSTMs representam melhor relações não lineares e sequências longas, enquanto convoluções extraem motivos de curto prazo; juntas, buscam-se maior robustez a ruído e a mudanças de regime.

Os alvos preditivos considerados são a **direção do retorno** na próxima barra (alta ou baixa), medidas de volatilidade intradiária e sinais relacionados a liquidez. Para assegurar comparabilidade e realismo, os resultados são confrontados com **modelos de referência** (*baselines*) estatísticos (ARIMA, Prophet) e com validação **temporal deslizante** (*walk-forward*), sem uso de informação futura no treino. O foco está em estabilidade e reprodutibilidade, e na pergunta: em que condições um modelo CNN+LSTM supera comparadores clássicos na previsão direcional intradiária (+1 barra, 15 min) em ações líquidas da B3, quando avaliado com métricas pós-custos?

A Figura 1 resume a tarefa: em uma série de preços intradiária, cada instante gera um vetor de atributos (preço, volume, indicadores técnicos) e o modelo estima a probabilidade de a próxima barra fechar acima ou abaixo da atual. O horizonte é de uma barra à frente, e as janelas de treino e teste avançam no tempo, refletindo o fluxo real do mercado.

2 Desenvolvimento

2.1 Contexto e fundamentação

Em mercados acionários, séries temporais costumam ser decompostas em *tendência*, *sazonalidade*, *ciclos* e ruído [Hyndman and Athanasopoulos, 2018, Box et al., 2015]. A tendência indica se os preços estão subindo ou caindo no curto prazo; a sazonalidade envolve padrões repetitivos (por exemplo, ao longo do dia); os ciclos são oscilações de médio a longo prazo ligadas a condições econômicas. Modelos clássicos como **ARIMA** e **Prophet** lidam bem com séries estacionárias ou de baixa não linearidade, mas tendem a perder eficácia em mercados muito voláteis, em que pequenos choques podem alterar as projeções. Redes LSTM, por outro lado, têm se mostrado capazes de capturar dependências temporais longas e relações não lineares, às vezes com acurácia superior em horizontes maiores; combinações híbridas (por exemplo, com




Figura 1: Previsão direcional intradiária: horizonte +1 barra (15 min). Fonte: autor.

indicadores técnicos e validação temporal) aparecem na literatura como caminho para maior robustez.

Neste trabalho, consideramos explicitamente a **estacionariedade**: em vez de modelar preços em nível, utilizamos **retornos logarítmicos** $r_t = \ln(P_t) - \ln(P_{t-1})$, o que estabiliza a escala e permite composição aditiva no tempo. A **volatilidade intradiária** é mensurada em janelas móveis (por exemplo, 20 períodos), e a liquidez é abordada por volume e, quando disponível, spread. Indicadores como **Médias Móveis Exponenciais** (MME), **RSI** (Índice de Força Relativa) e **Bandas de Bollinger** enriquecem o conjunto de *features*, ajudando a rede a discriminar entre sinal e ruído.

2.2 Dados e pré-processamento

Os dados foram obtidos via plataforma MetaTrader 5 (MT5), com histórico em barras de **15 minutos** (timeframe M15). O universo compreende três ativos de alta liquidez da B3: **PETR4** (Petrobras), **VALE3** (Vale) e **ITUB4** (Itaú Unibanco), no período de 22 de outubro de 2020 a 22 de outubro de 2025. Cada barra contém variáveis **OHLCV** (abertura, máxima, mínima, fechamento, volume). As séries foram ajustadas por eventos corporativos (desdobramentos, grupamentos, dividendos) e submetidas a tratamento de qualidade (remoção de anomalias, consistência de fuso horário). Para evitar **vazamento de dados** (*data leakage*), a normalização (por exemplo, Min-Max ou Z-Score) é ajustada *apenas* no bloco de treino e depois aplicada ao teste; nenhuma estatística do futuro entra no treinamento [Prado, 2018, Bergmeir and Benítez, 2012].

Foi adotada uma **banda morta** na rotulagem: retornos com valor absoluto menor que 0,1% são tratados como neutros e excluídos do cálculo da acurácia direcional. Isso aproxima a avaliação da decisão real de comprar ou vender e reduz o peso de microvariações onde o spread domina.

2.3 Modelo proposto e baselines

A arquitetura proposta é um híbrido **CNN–LSTM**: uma camada convolucional unidimensional (Conv1D) extrai padrões locais; em seguida, MaxPooling reduz a dimensão temporal; uma camada LSTM captura dependências de longo prazo; por fim, uma camada densa com ativação sigmoide produz a probabilidade de a próxima barra ser de alta. A janela de entrada (*lookback*) utilizada é de 60 barras, com 12 características (OHLCV processado, retornos, volatilidade móvel, MME, RSI, Bandas de Bollinger em janelas típicas).

Os **baselines** incluem: (i) **Naive** (repetir a última direção); (ii) **Drift** (tendência recente); (iii) **ARIMA**; (iv) **Prophet**. Todos são avaliados sob o mesmo protocolo de validação temporal, com as mesmas métricas e o mesmo particionamento, para garantir comparabilidade.

2.4 Validação temporal e desenho experimental

A validação **walk-forward** funciona assim: em cada *fold* i , o modelo é treinado apenas com dados passados; os hiperparâmetros são escolhidos por otimização bayesiana (Optuna) em uma validação interna contida no bloco de treino. Entre o fim do treino/validação e o início do conjunto de teste é imposto um **embargo temporal** de h observações, para mitigar vazamento de informação. O desempenho é medido no bloco de teste seguinte (Teste $i + 1$). O processo se repete ao longo do tempo, produzindo várias avaliações fora da amostra; as métricas finais são agregadas sobre os blocos de teste. Esse desenho é fundamental em séries financeiras, pois respeita a causalidade e reduz otimismo indevido [Bergmeir and Benítez, 2012, Prado, 2018].




Figura 2: Esquema da validação temporal deslizante (walk-forward) com embargo. Fonte: autor.

2.5 Métricas e backtests

A métrica central é a **acurácia direcional** (*hit rate*): proporção de vezes em que a previsão de alta ou baixa coincide com a direção realizada, após aplicar a banda morta. Complementarmente, reportam-se F1-Score, **MCC** (Matthews Correlation Coefficient), **Brier Score** e Log-Loss para qualidade probabilística e calibração. Como acerto estatístico não garante lucro, foram realizados **backtests** com custos explícitos: custo proporcional (emolumentos B3, 0,03%) e **deslizamento de preço** (*slippage*, 0,05%), em estratégias *long-only* e *long/short*. Para

verificar se diferenças entre modelos são estatisticamente significativas, aplicou-se o teste de **Diebold–Mariano** [Diebold and Mariano, 1995] à série de perdas direcionais e à perda Brier.

2.6 Resultados principais

Os experimentos geraram quatro *folds* de teste por ativo (cada fold com cerca de um mês de barras). Em termos de **acurácia direcional** média, o CNN–LSTM ficou ligeiramente à frente em PETR4 (51,55% contra 50,13% do melhor baseline) e em VALE3 (50,76% contra 50,69% do ARIMA); em ITUB4, o Naive superou o híbrido (51,21% contra 50,83%). De forma geral, todos os modelos operam em uma faixa próxima a 50%, ou seja, ao acaso.

O **MCC** ficou muito próximo de zero em todos os casos ($-0,034$ a $+0,025$), indicando que nenhum modelo discriminou de forma consistente entre as classes alta e baixa. Em 10 dos 12 *folds*, o CNN–LSTM apresentou **colapso de classe**: as probabilidades emitidas tinham desvio-padrão extremamente baixo (0,002 a 0,012), concentrando-se em um lado do limiar 0,5, de modo que o modelo predizia predominantemente uma única direção para todo o bloco. Isso explica o MCC nulo e o número muito baixo de operações nos backtests.

O teste de **Diebold–Mariano** (perda direcional) não rejeitou a hipótese nula de igualdade de desempenho em nenhuma das 12 comparações (3 ativos $\times$ 4 baselines); os p-valores variaram de 0,071 a 0,967. Na comparação por **perda Brier**, o CNN–LSTM foi significativamente melhor que todos os baselines ($p < 0,001$), o que reflete a natureza probabilística da saída (valores próximos de 0,5 geram perda Brier menor que previsões binárias erradas), e não necessariamente uma capacidade preditiva superior.

Nos **backtests**, PETR4 em modo long/short obteve retorno líquido de 4,10% e Sharpe de 1,41 na média dos folds, mas esse resultado ficou concentrado em um único fold (o que teve MCC positivo e maior dispersão de probabilidades). VALE3 e ITUB4 ficaram próximos do zero ou negativos. A baixa rotatividade (poucas operações) é consequência direta das probabilidades quase constantes.

2.7 Interpretação e limitações

Os resultados são compatíveis com a hipótese de **eficiência semiforte** do mercado para o horizonte e a granularidade estudados: retornos intradiários de 15 minutos em ações líquidas da B3 parecem conter alto ruído e baixa autocorrelação, dificultando a extração de padrões preditivos estáveis. Mostrar que um modelo de deep learning não supera baselines simples nessas condições é, em si, uma contribuição: reforça a importância de avaliações rigorosas (validação temporal, testes de significância, custos de transação) e ajuda a evitar a *ilusão de performance* comum em estudos sem esses controles [Prado, 2018].

As limitações identificadas incluem: (i) **sinale fraco** em 15 minutos com apenas 12 *features*; (ii) possível mínimo local na paisagem de perda (Binary Cross-Entropy) quando as probabilidades ficam próximas de 0,5; (iii) arquitetura relativamente simples; (iv) tamanho efetivo de treino (cerca de um ano por bloco) que pode ser insuficiente para generalização robusta. O que os resultados *não* invalidam é o protocolo: walk-forward, comparação com baselines, Diebold–Mariano e backtests com custos foram aplicados corretamente e o pipeline é reproduzível.

3 Conclusão

Este trabalho propôs e avaliou um modelo híbrido CNN–LSTM para **previsão direcional intradiária** (barras de 15 minutos) em três ativos de alta liquidez da B3 (PETR4, VALE3,




Figura 3: Heatmap de p-valores do teste de Diebold–Mariano (perda direcional). Fonte: autor.

ITUB4). A abordagem integrou um pipeline completo — da aquisição de dados à avaliação financeira — com ênfase em **validação temporal** rigorosa, prevenção de **data leakage** e reprodutibilidade [Bergmeir and Benítez, 2012, Prado, 2018].

A principal contribuição não é um ganho de acurácia sobre baselines, mas o **protocolo metodológico**: (i) base intradiária de cinco anos com tratamento de qualidade e ajustes corporativos; (ii) engenharia de 12 características técnicas com rotulagem direcional e banda morta; (iii) validação walk-forward com embargo; (iv) comparação com Naive, Drift, ARIMA e Prophet sob as mesmas condições; (v) otimização bayesiana de hiperparâmetros por fold; (vi) testes de Diebold–Mariano e segmentação por regime de volatilidade; (vii) backtests com custos explícitos em modalidades long-only e long/short; (viii) pipeline reprodutível com sementes fixas e scripts documentados. Esse protocolo pode ser reutilizado para outras arquiteturas, conjuntos de *features* ou granularidades.

Os resultados empíricos indicam que, para os dados e a configuração adotados, o CNN–LSTM não supera os baselines de forma estatisticamente significativa nem de forma financeiramente consistente. O fenômeno de **colapso de classe** em boa parte dos folds e a concentração de resultado positivo em um único cenário (PETR4 long/short em um fold) sugerem que trabalhos futuros podem explorar: granularidades maiores (30 min ou 1 h); *features* adicionais (microestrutura, sentimento, codificação temporal); arquiteturas com atenção (por exemplo, Temporal Fusion Transformer) ou *ensembles*; funções de perda que penalizem a concentração de previsões; e limiares adaptativos por regime. O código e a documentação do pipeline estão disponíveis para reprodução e extensão pela comunidade.

Referências

- [Bergmeir and Benítez, 2012] Bergmeir, C. and Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191:192–213.
- [Bodie et al., 2021] Bodie, Z., Kane, A., and Marcus, A. J. (2021). *Investments*. McGraw-Hill Education, New York, 12 edition.

- [Box et al., 2015] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. Wiley, Hoboken, NJ, 5 edition.
- [Diebold and Mariano, 1995] Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.
- [Hyndman and Athanasopoulos, 2018] Hyndman, R. J. and Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 2 edition.
- [Mishkin and Eakins, 2018] Mishkin, F. S. and Eakins, S. G. (2018). *Financial Markets and Institutions*. Pearson, New York, 9 edition.
- [Prado, 2018] Prado, M. L. d. (2018). *Advances in Financial Machine Learning*. Wiley, Hoboken, NJ.