

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO

FELIPE DOS SANTOS GIACOMEL

**Um Método Algorítmico para Operações na
Bolsa de Valores Baseado em *Ensembles* de
Redes Neurais para Modelar e Prever os
Movimentos dos Mercados de Ações**

Dissertação apresentada como requisito parcial para
a obtenção do grau de Mestre em Ciência da
Computação

Orientador: Prof^a. Dr^a. Renata Galante

Porto Alegre
2016

CIP — CATALOGAÇÃO NA PUBLICAÇÃO

Giacomel, Felipe dos Santos

Um Método Algorítmico para Operações na Bolsa de Valores
Baseado em *Ensembles* de Redes Neurais para Modelar e Prever
os Movimentos dos Mercados de Ações / Felipe dos Santos Giacomele. – Porto Alegre: PPGC da UFRGS, 2016.

92 f.: il.

Dissertação (mestrado) – Universidade Federal do Rio Grande do Sul. Programa de Pós-Graduação em Computação, Porto Alegre, BR-RS, 2016. Orientador: Renata Galante.

1. Redes neurais artificiais. 2. Classificação. 3. Previsão.
4. Mercados de ações. 5. Séries temporais. I. Galante, Renata.
II. Título.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitor: Prof. Carlos Alexandre Netto

Vice-Reitor: Prof. Rui Vicente Oppermann

Pró-Reitor de Pós-Graduação: Prof. Vladimir Pinheiro do Nascimento

Diretor do Instituto de Informática: Prof. Luis da Cunha Lamb

Coordenador do PPGC: Prof. Luigi Carro

Bibliotecária-chefe do Instituto de Informática: Beatriz Regina Bastos Haro

“Errei mais de 9.000 cestas e perdi quase 300 jogos. Em 26 diferentes finais de partidas fui encarregado de jogar a bola que venceria o jogo... e falhei. Eu tenho uma história repleta de falhas e fracassos em minha vida. E é exatamente por isso que sou um sucesso.”

— MICHAEL JORDAN

AGRADECIMENTOS

Agradeço primeiramente aos meus pais por terem me tornado a pessoa que sou hoje. À minha noiva Juliane por toda a paciência, compreensão e amor durante estes três anos de mestrado, e a Fausto G. Giacomel por ter me alegrado em vários momentos durante o desenvolvimento deste estudo.

Também agradeço à professora Renata Galante por ter aceitado o desafio de me orientar em uma área tão diferente da que ela está acostumada, e ao professor Adriano Pereira pelas valiosas contribuições tanto nos artigos publicados quanto nesta dissertação.

Agradeço à minha chefe Ana Lúcia Moreira por ter me dado liberdade e flexibilidade de horários sempre que precisei comparecer a algum compromisso do mestrado, e também à UFRGS e seu Instituto de Informática, pela infraestrutura disponibilizada de forma gratuita.

Por fim, agradeço aos professores Carine Webber, Paulo Engel e Viviane Moreira, por aceitarem o convite de fazer parte da banca examinadora e dedicarem parte de seu tempo a este trabalho.

RESUMO

A previsão de séries temporais financeiras tem sido um tópico popular da literatura nos últimos anos. Contudo, embora muitos estudos de previsão de séries temporais foquem na previsão exata de valores futuros, defendemos que este tipo de previsão é de difícil aplicação em cenários reais, sendo mais vantajoso transformar este problema de previsão em um problema de classificação que indique se a série temporal irá subir ou descer no próximo período. Neste trabalho é proposto um método de compra e venda de ações baseado nas previsões feitas por dois *ensembles* de redes neurais adaptados para diferentes perfis de investimento: um para investidores moderados e outro para investidores mais agressivos. Os resultados desses *ensembles* preveem se determinada ação irá subir ou descer no próximo período ao invés de prever seus valores futuros, permitindo que se criem recomendações de operações de compra ou venda para o próximo período de tempo. A criação de tais *ensembles*, contudo, pode encontrar dificuldades no fato de que cada mercado se comporta de uma maneira diferente: fatores como a sazonalidade e a localidade da bolsa de valores são determinantes no desenvolvimento das redes neurais apropriadas. Para mostrar a eficiência do nosso método em diferentes situações, o mesmo é avaliado exaustivamente em dois conjuntos de dados diferentes: os mercados de ações norte-americano (S&P 500) e brasileiro (Bovespa). Operações reais foram simuladas nestes mercados e fomos capazes de lucrar em 89% dos casos avaliados, superando os resultados das abordagens comparativas na grande maioria dos casos.

Palavras-chave: Redes neurais artificiais. Classificação. Previsão. Mercados de ações. Séries temporais.

An Algorithmic Trading based on Neural Network Ensembles to Model and Predict Stock Market Movements

ABSTRACT

Financial time series prediction has been a hot topic in the last years. However, although many time series prediction studies focus on the exact prediction for future values, we defend that this kind of prediction is hard to apply in real scenarios, being more profitable to transform the prediction problem into a classification problem that indicates if the time series is going to raise or fall in the next period. In this work we propose a stock buy and sell method based on predictions made by two neural network ensembles adjusted for different investment profiles: one for moderate investors and another for aggressive investors. The results of these ensembles predict if certain stock will raise or fall in the next time period instead of predicting its future values, allowing the creation of buy and sell operations recommendations for the next time period. The creation of such ensembles, however, can find difficulties in the fact that each market behaves in a different manner: factors as the seasonality and the location of the stock market are determinant in the development of the appropriate neural networks. To show the efficiency of our method in different situations, it is tested exhaustively in two different datasets: the north american (S&P 500) and brazilian (Bovespa) stock markets. Real operations were simulated in these markets and we were able to profit in 89% of the tested cases, outperforming the results of the comparative approaches in most of the cases.

Keywords: Neural networks, Classification, Prediction, Stock markets, Time series.

LISTA DE ABREVIATURAS E SIGLAS

ARV	Average Relative Variance
BBAS3	Ações do Banco do Brasil
BBDC4	Ações do Banco Bradesco
BHP	Ações da BHP Billiton (mineradora e petrolífera anglo-australiana)
DAX	Deutscher Aktienindex (Índice Alemão de Ações)
DJIA	Dow Jones Industrial Average
FF	Feed Forward
FTSE	Financial Times Stock Exchange
IA	Inteligência Artificial
MAPE	Mean Absolute Percentage Error
MASE	Mean Absolute Scaled Error
MLP	Multilayer Perceptron
MSE	Mean Squared Error
NASDAQ	National Association of Securities Dealers Automated Quotations
NMSE	Normalized Mean Squared Error
PDA	Prediction in Direction and Accuracy
PETR4	Ações da Petrobras
POCID	Prediction On Change In Direction
PSO	Particle Swarm Optimization
RI	Retorno de investimento
RN	Rede Neural
RBF	Radial Basis Function
RMS	Root Mean Square Error
SAR	Stop and Reverse

SLG	Sum of Losses and Gains
SP500	Standard & Poor's 500
SVM	Support Vector Machine
USIM5	Ações da Usiminas
VALE5	Ações da Vale

LISTA DE FIGURAS

Figura 2.1 Representação de <i>candlesticks</i> de alta e queda	21
Figura 2.2 Médias Móveis Simples e Exponenciais de 10 dias	24
Figura 2.3 Série temporal financeira representando os valores do índice Bovespa	28
Figura 2.4 Estrutura do neurônio artificial	29
Figura 2.5 Representação de uma rede neural do tipo <i>Single Layer Perceptron</i> e <i>Multi-layer Perceptron</i>	31
Figura 2.6 Representação de uma rede neural do tipo <i>Feed Forward</i>	31
Figura 3.1 Percentual de retorno dos conjuntos de validação e teste.....	38
Figura 3.2 Comparação do crescimento de capital ao usar a rede neural proposta (Model), a estratégia <i>Buy & Hold</i> e Média móvel de 30 dias (<i>Benchmark 3</i>).....	39
Figura 3.3 Diagrama de caixa dos conjuntos de treinamento e teste, agrupados por ação	41
Figura 3.4 Desempenho do método proposto para redes do tipo MLP e RBF, com e sem séries exógenas.....	44
Figura 3.5 Precisão das previsões de acordo com o tipo de entrada e rentabilidade do método proposto.....	45
Figura 3.6 MASE médio para diferentes números de elementos no <i>ensemble</i> para as bases do FRED e ONS, respectivamente	46
Figura 4.1 Visão geral da arquitetura dos <i>ensembles</i> propostos.....	51
Figura 4.2 Arquitetura do <i>ensemble</i> moderado	52
Figura 4.3 Arquiteturas das redes neurais do <i>ensemble</i> moderado	52
Figura 4.4 Arquitetura do <i>ensemble</i> agressivo	55
Figura 4.5 Arquiteturas das redes neurais do <i>ensemble</i> agressivo	56
Figura 5.1 Metodologia de Experimentos	65
Figura A.1 Desenvolvimento do capital para S&P 500	83
Figura A.2 Desenvolvimento do capital para AA	84
Figura A.3 Desenvolvimento do capital para BAC	84
Figura A.4 Desenvolvimento do capital para C	85
Figura A.5 Desenvolvimento do capital para F.....	85
Figura A.6 Desenvolvimento do capital para FCX	86
Figura A.7 Desenvolvimento do capital para GE.....	86
Figura A.8 Desenvolvimento do capital para JPM.....	87
Figura A.9 Desenvolvimento do capital para SWN	87
Figura A.10 Desenvolvimento do capital para BOVA11	88
Figura A.11 Desenvolvimento do capital para BBAS3.....	88
Figura A.12 Desenvolvimento do capital para BBDC4	89
Figura A.13 Desenvolvimento do capital para BBSE3	89
Figura A.14 Desenvolvimento do capital para BRFS3	90
Figura A.15 Desenvolvimento do capital para BVMF3.....	90
Figura A.16 Desenvolvimento do capital para ITSA4	91
Figura A.17 Desenvolvimento do capital para PETR4	91
Figura A.18 Desenvolvimento do capital para VALE5.....	92

LISTA DE TABELAS

Tabela 1.1 Variação média das bolsas de valores em mercados desenvolvidos e emergentes de 01/01/2010 a 31/12/2015	15
Tabela 3.1 Comparativo entre os trabalhos que preveem o movimento de séries temporais ...	42
Tabela 3.2 Comparativo entre os trabalhos que utilizam <i>ensembles</i> para prever séries temporais.....	48
Tabela 5.1 Séries temporais utilizadas na validação dos <i>ensembles</i> propostos.....	61
Tabela 5.2 Quantidades de altas e quedas nos valores diários em cada uma das séries temporais de ações avaliadas	63
Tabela 5.3 Sumário das classificações feitas pelo <i>ensemble</i> moderado	69
Tabela 5.4 Sumário das classificações corretas feitas pelos <i>ensembles</i> moderado e agressivo, e comparação com outras abordagens	71
Tabela 5.5 Lucros finais obtidos por todas as abordagens comparativas considerando um capital inicial de \$100,000.00 para cada ação e considerando corretagem de \$10. Valores em negrito indicam os melhores desempenhos para cada série temporal.....	73

SUMÁRIO

1 INTRODUÇÃO	13
2 FUNDAMENTAÇÃO TEÓRICA	18
2.1 O Mercado financeiro	18
2.1.1 As Bolsas de Valores.....	18
2.1.2 Preços.....	19
2.1.3 Representação dos preços em <i>Candlesticks</i>	20
2.1.4 Compra e venda de ações.....	21
2.1.5 Indicadores técnicos.....	22
2.1.6 Perfis de Investimento e de Investidor	25
2.2 Séries Temporais	26
2.2.1 Séries Temporais Financeiras	27
2.3 As redes neurais artificiais	28
2.3.1 <i>Single Layer</i> e <i>Multilayer Perceptrons</i>	30
2.3.2 Feed forward	31
2.3.3 <i>Backpropagation</i>	32
2.3.4 <i>Ensemble</i> de Redes Neurais	33
2.4 Métricas de desempenho	33
2.4.1 Erro Percentual Absoluto Médio	34
2.4.2 Raiz Quadrada do Erro Quadrático Médio	34
2.4.3 Erro Médio Quadrático	34
2.4.4 Erro Absoluto Escalado Médio	35
2.5 Considerações Finais	35
3 TRABALHOS RELACIONADOS	36
3.1 Previsão do Movimento dos Mercados.....	36
3.2 Uso de <i>Ensembles</i> na Previsão de Valores.....	41
3.3 Considerações Finais	48
4 MODELO PROPOSTO	50
4.1 Visão Geral	50
4.2 <i>Ensemble</i> Moderado.....	51
4.3 <i>Ensemble</i> Agressivo.....	54
4.4 Implementação	56
4.4.1 Considerações	57
5 EXPERIMENTOS	59
5.1 Preparação dos experimentos	59
5.1.1 Base de dados.....	59
5.1.2 Métricas de avaliação.....	63
5.2 Metodologia de Experimentos	65
5.2.1 Organização das Redes Neurais	67
5.3 Avaliação das Classificações dos <i>Ensembles</i>	67
5.3.1 Avaliação das Classificações do <i>Ensemble</i> Moderado	68
5.3.2 Avaliação das Classificações do <i>Ensemble</i> Agressivo	69
5.3.3 Avaliação Geral das Classificações.....	70
5.4 Análise do Desempenho dos <i>Ensembles</i>	72
5.4.1 Ações norte-americanas	72
5.4.2 Ações brasileiras	74
5.4.3 Estratégias comparativas	75
5.4.4 Avaliação Geral	76
6 CONCLUSÃO	77

REFERÊNCIAS	79
APÊNDICE A — GRÁFICOS DOS RENDIMENTOS	83
A.1 Standard & Poor's 500 (S&P 500)	83
A.2 Alcoa Inc (AA)	84
A.3 Bank of America Corp (BAC)	84
A.4 Citigroup Inc (C)	85
A.5 Ford Motor Co (F)	85
A.6 Freeport-McMoRan Inc (FCX)	86
A.7 General Electric Co (GE)	86
A.8 JPMorgan Chase and Co (JPM)	87
A.9 Southwestern Energy Co (SWN)	87
A.10 Bovespa (BOVA11)	88
A.11 Banco do Brasil (BBAS3)	88
A.12 Bradesco (BBDC4)	89
A.13 BB Seguridade (BBSE3)	89
A.14 BRF Foods (BRFS3)	90
A.15 BMF Bovespa (BVMF3)	90
A.16 Itaú (ITSA4)	91
A.17 Petrobras (PETR4)	91
A.18 Vale (VALE5)	92

1 INTRODUÇÃO

Entre todas as aplicações possíveis das redes neurais, tais como reconhecimento de caracteres, análise de crédito, diagnóstico médico e até mesmo robótica, provavelmente a previsão de séries temporais é uma das mais estudadas. Redes neurais são uma escolha comum para este tipo de problema porque se comportam bem em problemas não-lineares que possuem um alto número de variáveis. Mercados de ações em grandes economias ao redor do mundo possuem um volume de operações consideravelmente alto, justificando o interesse de investidores em direcionar seus interesses na automatização de operações que devem ser ao mesmo tempo as mais seguras e lucrativas possíveis. Neste contexto, existe um campo contínuo de pesquisa chamado de *algorithmic trading (algotrading)* (ADLER, 2012; BOEHMER; FONG; WU, 2014), que foca em fornecer tecnologia e modelos inteligentes para implementar estratégias de negociação para estes mercados.

Redes neurais (RN) do tipo *perceptron* de multicamadas (ROSENBLATT, 1958) entregam melhores resultados do que outras técnicas de inteligência artificial na previsão de séries temporais (CAO; LEGGIO; SCHNIEDERJANS, 2005; SAAD; PROKHOROV; WUNSCH, 1998). Por esta razão, não há surpresa no fato de que as redes neurais estão entre as técnicas mais utilizadas para prever valores futuros ou tendências dos mercados de ações ao redor do mundo (ATSALAKIS; VALAVANIS, 2009). Contudo, enquanto métodos baseados em redes neurais artificiais sozinhas têm sido largamente usados na previsão de séries temporais, como será mostrado mais adiante, *ensembles* de redes neurais ainda não possuem a mesma popularidade nessa área, embora apresentem melhores resultados do que redes neurais sozinhas, dependendo da aplicação. Já foi mostrado que *ensembles* simples podem realizar melhores generalizações do que uma rede neural sozinha (HANSEN; LIISBERG; SALAMON, 1992), e diversos estudos também mostram que um subconjunto de todas as redes neurais possíveis podem obter melhores resultados que uma rede neural sozinha (WEST; DELLANA; QIAN, 2005; WU; CHEN, 2001; ZHOU; WU; TANG, 2002).

Indicadores técnicos, por sua vez, foram criados para melhorar os resultados da análise técnica de ações. Em geral, estes indicadores são fórmulas que recebem como entrada dados anteriores de uma ação específica e retornam um ou mais valores que podem ser usados para tentar prever a sua tendência no próximo período. Existem vários indicadores técnicos criados para este propósito — alguns dos mais populares na literatura são as Médias Móveis, as Bandas de *Bollinger*, o Estocástico e o Índice de Força Relativa (ELDER, 2002). Redes neurais realizam uma função de previsão similar à dos indicadores técnicos, uma vez que também recebem como

entrada dados de períodos anteriores. As redes neurais possuem, porém, uma vantagem: se treinadas adequadamente, podem retornar previsões explícitas dos valores exatos da ação para os próximos períodos, e não apenas uma análise do comportamento e tendência da mesma.

Investir em mercados de ações sempre foi um grande desafio para os investidores. Embora este tipo de mercado possua um comportamento aparentemente aleatório, investidores e operadores profissionais batalham tentando prever os próximos movimentos que estes mercados terão. Existem dois tipos principais de análise que são usados por investidores há muito tempo para prever a tendência do mercado, e que podem ser utilizados separadamente ou em conjunto, dependendo da estratégia escolhida pela investidor: a análise fundamentalista e a análise técnica (SCHWAGER, 1984). Na análise fundamentalista, acredita-se que o valor das ações de determinada companhia é determinado por fatores econômicos e pelo desempenho financeiro da própria companhia. Eventuais flutuações nos preços são corrigidas pelo mercado nos próximos períodos uma vez que a análise fundamentalista afirma que o preço de uma ação é sempre justo. A análise técnica, por sua vez, interpreta que toda a informação utilizável já está contida no valor das ações e, portanto, os únicos dados usados na análise do mercado podem ser os valores anteriores deste próprio mercado. Finalmente, a análise técnica também afirma que os movimentos do mercado que ocorrem no passado tendem a se repetir no futuro, o que reforça a necessidade de observar estes valores passados quando se quer prever os futuros. Este tipo de análise usa intensamente *candlesticks*, uma representação gráfica dos preços de uma ação, e indicadores técnicos em seus estudos.

Uma característica normalmente encontrada no investimento em bolsas de valores é que, historicamente, os grandes investidores sempre focaram seus negócios em mercados desenvolvidos. É considerado um mercado desenvolvido aquele que se situa em um país de primeiro mundo, como os Estados Unidos ou a Alemanha. Por possuírem várias grandes empresas e um produto interno maior, estes países são considerados mais seguros de se investir, já que sua economia é menos influenciada por fatores externos. Opondo-se a este tipo de mercado, existem os mercados emergentes, que são aqueles localizados em países de terceiro mundo e cuja economia encontra-se em desenvolvimento, como é o caso do México, da China, ou do Brasil (ARNOLD; QUELCH, 1998). Como as economias destes países ainda não estão plenamente desenvolvidas, são mais propensas a serem influenciadas por fatores externos e a apresentarem altas variações em seus desempenhos quando comparadas às oscilações econômicas verificadas em países desenvolvidos. Essa maior volatilidade dos mercados emergentes é demostrada na Tabela 1.1 e possibilita chances de ganhos maiores ao investidor disposto a investir nesse tipo de mercado ao invés de investir em um mercado desenvolvido..

Tabela 1.1: Variação média das bolsas de valores em mercados desenvolvidos e emergentes de 01/01/2010 a 31/12/2015¹

Bolsa de Valores	País	Mercado	Variação Diária Média
S&P 500	EUA	Desenvolvido	0,702%
FTSE	Reino Unido	Desenvolvido	0,712%
DAX	Alemanha	Desenvolvido	0,938%
SSE	China	Emergente	1,007%
Bovespa	Brasil	Emergente	1,081%
BMV	México	Emergente	1,238%

A maioria dos estudos disponíveis na literatura aborda os mercados financeiros de países com a economia desenvolvida (BOLLEN; MAO; ZENG, 2011; TICKNOR, 2013), onde o comportamento das séries temporais que representam suas ações (mais estáveis) é diferente do observado em mercados emergentes (mais caóticas). Existe um déficit de pesquisa nesta área relativo aos mercados emergentes – muito do que já foi feito está consolidado apenas para os mercados desenvolvidos, ou seja, ainda há muito o que se pesquisar no campo dos mercados emergentes. Adicionalmente, com as mudanças observadas na economia brasileira nos últimos anos, o comportamento do investidor brasileiro vem mudando progressivamente. Se antes era, de certa forma, vantajoso armazenar o dinheiro na caderneta de poupança, hoje em dia isto já não é mais verdade. Com a queda dos juros da SELIC, os rendimentos fornecidos pela poupança estão próximos a zero. O mesmo acontece com outras formas de investimento seguras, ou seja, que oferecem baixo risco de perda de capital ao investidor, como a renda fixa e os certificados de depósito bancário (CDBs). Atualmente, o investidor que deseja obter uma lucratividade maior precisa migrar para formas de investimento mais arriscadas, que levam este nome pois, apesar de fornecerem a possibilidade de lucros maiores, se mal utilizadas podem também trazer ao investidor prejuízos maiores. Neste cenário, o uso de redes neurais na predição de valores torna-se uma importante aliada do investidor.

Embora redes neurais possam realizar previsões úteis de valores futuros em séries temporais financeiras, estudos nesta área geralmente focam apenas na minimização do erro médio da rede neural e não dão importância a um teste de desempenho, que mostraria o lucro que poderia ser obtido se as operações recomendadas pelos métodos propostos fossem seguidas (CHEN; YANG; ABRAHAM, 2007). Na verdade, esses estudos não recomendam como fazer operação alguma, pois mostram os valores previstos com uma certa margem de erro, mas não propõem uma aplicação real destes resultados. Em termos práticos, este tipo de previsão não é suficiente para ser utilizada no mundo real. Finalmente, métodos que tentam prever os valores

¹Fonte: Yahoo! Finance (<http://finance.yahoo.com>)

futuros exatos não se comportam satisfatoriamente em períodos de alta volatilidade (KARA; BOYACIOGLU; BAYKAN, 2011; KIM, 2003), o que diminui a sua confiabilidade.

Prever os movimentos do mercado ao invés de seus valores futuros pode entregar melhores resultados em aplicações reais. Por exemplo: se uma rede neural prevê que no próximo período de tempo haverá um aumento de 0,20 pontos para determinada ação, mas a ação sobe apenas até 0,19 pontos, matematicamente este é um ótimo resultado, pois a rede neural errou por apenas 0,01 ponto. Contudo, se o operador estava esperando a ação alcançar 0,20 pontos para operar, o mesmo teria perdido toda esta tendência de alta, uma vez que o valor previsto nunca foi alcançado. Por outro lado, se a mesma rede neural previu um aumento nos preços, sem dizer de quanto seria este aumento, seria muito mais fácil para o operador montar uma estratégia de operação para esta ação.

Neste trabalho, é proposta a resolução do problema da previsão de movimentos em séries temporais financeiras através do desenvolvimento de um método automatizado de compra e venda de ações que utiliza dois *ensembles* de previsão: o primeiro, chamado de ***ensemble moderado***, é formado por duas redes neurais e fornece previsões para investidores com perfil mais moderado de investimento; o segundo, chamado de ***ensemble agressivo***, é formado por duas redes neurais e um indicador técnico e fornece, através de um sistema de votação, previsões para investidores com perfil mais agressivo. Ambos os *ensembles* classificam um conjunto de entradas em ordens de compra e venda reais. O método recebe como entrada os valores dos períodos passados e retorna uma previsão que indica o que irá acontecer com a série temporal financeira sendo analisada no próximo período: se irá cair ou subir. Com este resultado, um operador pode decidir o que fazer: vender ou comprar a ação. Os resultados são apresentados através do índice de acertos do método, a variação de capital que um investidor hipotético teria obtido se tivesse seguido todas as operações recomendadas, e uma comparação desta variação com a que seria obtida com outras abordagens comparativas, como a *Buy-and-hold* e a Estratégia Trivial. Para validar nosso método em diferentes situações, avaliamos seu comportamento em dois cenários completamente diferentes: um conjunto de ações do mercado norte-americano com granularidade diária e um conjunto de ações do mercado brasileiro com granularidade de 15 minutos. Os resultados em ambos os conjuntos de teste são promissores, com índices de acertos em torno de 60% em ambas as bases de dados e um ganho de capital de até 64% em 166 dias (i.e., em torno de 8 meses) para o mercado norte-americano e de até 7% em 192 períodos de 15 minutos (i.e., em torno de 7 dias) para o mercado brasileiro. Os primeiros resultados deste trabalho já foram publicados em dois congressos (GIACOMEL; PEREIRA; GALANTE, 2015b; GIACOMEL; PEREIRA; GALANTE, 2015a).

O restante deste trabalho está dividido da seguinte forma: o Capítulo 2 fornece uma introdução aos conceitos básicos utilizados; o Capítulo 3 analisa os trabalhos já existentes na área da previsão de séries temporais com técnicas de inteligência artificial, mostrando a método utilizado, eventuais inovações e resultados obtidos, além de fazer uma comparação entre os métodos estudados; o Capítulo 4 descreve o método proposto e apresenta os *ensembles* moderado e agressivo, mostrando suas especificações, arquiteturas e modo de funcionamento; o Capítulo 5 avalia o método proposto com experimentos em diferentes tipos de conjuntos de dados, reforçando a sua confiabilidade; o Capítulo 6, finalmente, faz conclusões sobre o estudo realizado e propõe estudos futuros. Ao final do trabalho, no Apêndice A, são mostrados resultados adicionais onde se pode ter uma ideia melhor do comportamento do método proposto durante o período de testes.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os conceitos utilizados ao longo dessa dissertação. A descrição desses conceitos em profundidade não faz parte do escopo deste trabalho, uma vez que já estão consolidados na literatura. A Seção 2.1 introduz conceitos do mercado financeiro necessários para a compreensão do trabalho. A Seção 2.2 mostra o que são as séries temporais, dando ênfase às séries temporais financeiras. A Seção 2.3 descreve as redes neurais artificiais, focando nos conceitos utilizados na criação do nosso método, que são as redes do tipo *feed forward* e *multilayer perceptron*. A Seção 2.4 mostra as principais métricas usadas na literatura para medir o desempenho das redes neurais. Por fim, a Seção 2.5 faz considerações finais sobre os conceitos apresentados.

2.1 O Mercado financeiro

Muitos dos conceitos utilizados nos trabalhos aqui pesquisados são inerentes ao mercado financeiro, e nem sempre são conhecidos pelo público em geral. O objetivo desta seção é esclarecer os termos financeiros comumente utilizados em tais trabalhos, uma vez que o seu entendimento é essencial para a melhor compreensão dos trabalhos apresentados no Capítulo 3. Como os conceitos aqui apresentados já estão bem definidos na literatura, será utilizado como base o que é apresentado em referências consolidadas na área (ELDER, 1993; ELDER, 2002). Existem várias outras referências tanto ou mais importantes que essas, porém os conceitos utilizados são os mesmos em todas.

2.1.1 As Bolsas de Valores

Quando um país possui várias empresas de capital aberto, estas empresas precisam de um lugar em comum para negociar suas ações (ou ativos): a bolsa de valores. Neste local, entre outras atividades, são feitas as compras e vendas das ações das empresas lá cadastradas. O Brasil possui apenas uma bolsa de valores: a Bolsa de Valores do Estado de São Paulo (Bovespa¹), que atualmente negocia os ativos de aproximadamente 330 empresas brasileiras. Todos os dias, na Bovespa, são executadas milhares de operações de compra e venda destas ações, porém existem certas ações que são negociadas em quantidade muito maior do que as outras e, logo,

¹<http://www.bmfbovespa.com.br/>

exercem muito mais influência sobre o desempenho coletivo do mercado. O conjunto das 71 empresas mais negociadas na bolsa de valores formam o chamado Índice Bovespa, cujo rendimento indica o desempenho médio do mercado acionário brasileiro. Assim como o Brasil tem a Bovespa, outros países também possuem suas próprias bolsas de valores e, consequentemente, seus índices de desempenho. Como exemplo podemos citar os índices S&P 500², DJIA³ (Dow Jones Industrial Average) e NASDAQ⁴, os três dos Estados Unidos, o DAX⁵ da Alemanha, o FTSE 100⁶ da Inglaterra, o NIKKEI⁷ do Japão, entre outros. Os índices geralmente levam o mesmo nome da bolsa em que se baseiam, e uma de suas importâncias é permitir que investidores externos tenham uma ideia de como está se comportando o mercado geral de determinado país.

2.1.2 Preços

Ao final do dia, quando todas as negociações já foram concluídas, a forma mais comum de se analisar o desempenho de uma ação é observando o seu preço final. Essa métrica é usada pelos meios de comunicação e pelo público em geral, porém muitas vezes o preço final por si só não mostra como a ação se comportou ao longo do dia, já que desde a abertura até o fechamento do pregão, inúmeras operações de compra e venda desta ação podem acontecer, jogando seu preço para cima e para baixo durante o dia inteiro até esse preço chegar no seu valor final. As métricas utilizadas por investidores mais especializados para realizar uma avaliação mais profunda do preço de uma ação são as seguintes:

- *Fechamento* - mostra o valor que a ação atingiu ao final do período. É a métrica mais conhecida e utilizada na análise do mercado;
- *Abertura* - é o preço da ação no momento da abertura do pregão. Não é necessariamente igual ao valor de fechamento do dia anterior, visto que geralmente uma ação começa o dia já em alta ou em queda, devido a operações de *pre-market*, feitas antes do horário de abertura do pregão, e de *after-market*, feitas após o final do pregão anterior;
- *Máximo* - geralmente, ao longo do dia, o preço de uma ação sofre variações até chegar no valor de fechamento. Esta métrica mostra o valor máximo atingido pela ação ao longo do

²<http://www.spindices.com/indices/equity/sp-500/>

³<http://www.djaverages.com/>

⁴<http://www.nasdaq.com/>

⁵<http://deutsche-boerse.com/>

⁶http://www.ftse.com/Indices/UK_Indices/index.jsp

⁷<http://www.tse.or.jp/english/>

período. Este valor ajuda na interpretação de um preço porque quando o valor máximo de uma ação é muito maior do que o valor de fechamento, significa que o preço da ação caiu ao longo do período e a tendência é de que continue caindo no período seguinte. O inverso pode ser interpretado para um valor máximo muito perto do valor de fechamento;

- *Mínimo* - mostra o menor valor atingido por uma ação durante o dia. Sua interpretação é inversa à do valor máximo;
- *Volume* - é a soma do valor envolvido em todas as operações de compra e venda de determinada ação ao longo do dia. Pode variar entre alguns milhares de reais para empresas menores, como a Grazziotin⁸, até centenas de milhões de reais para as maiores empresas do Brasil, como a Vale⁹ e a Petrobras¹⁰, além de alguns bancos e construtoras. O volume por si só não permite deduções sobre o comportamento do mercado, mas a análise de seu histórico permite identificar o início ou o final de tendências. Por exemplo, quando o volume é alto por um certo período e depois começa a cair, significa que o interesse do mercado pela tendência adquirida pela ação está acabando, o que pode significar que a mesma mudará.

Todas estas métricas de preços podem ser utilizadas isoladamente, em conjunto ou para criar indicadores de ações, melhor explicados na Seção 2.1.5. Logo, é interessante que uma rede neural cujo objetivo seja prever séries temporais financeiras receba de parâmetros de entrada todas ou uma parte dessas métricas, lhe fornecendo dessa forma mais ferramentas para atingir seu objetivo de previsão.

2.1.3 Representação dos preços em *Candlesticks*

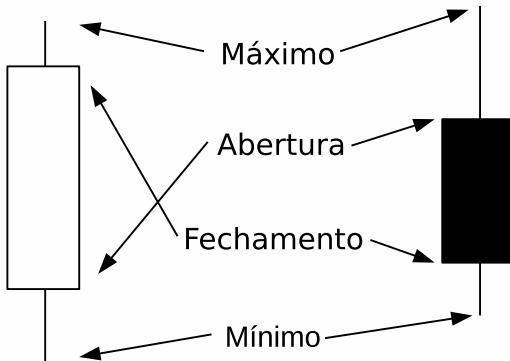
Os preços de abertura, fechamento, máximo e mínimo de uma ação podem ser representados graficamente em um *candlestick*, que tem esse nome porque seu formato lembra o de uma vela. Um *candlestick* pode ser usado para expressar o comportamento de uma ação durante qualquer período de tempo desejado (i.e., um dia, um minuto, etc.) e está ilustrado na Figura 2.1. Os valores de abertura e de fechamento do período de tempo escolhido são representados por linhas horizontais, e o retângulo delimitado por estas linhas é pintado de branco se o preço do fechamento é maior que o de abertura (indicando que houve um aumento no preço), e pintado de preto se o preço de fechamento é menor do que o de abertura (indicando que houve

⁸A grupo Grazziotin é uma rede de lojas de vestuário e decoração para casa

⁹A Vale é a maior empresa mineradora do Brasil

¹⁰A Petrobras é a maior empresa petrolífera do Brasil

Figura 2.1: Representação de *candlesticks* de alta e queda



Fonte: Autor

uma queda no preço). Os limites superior e inferior mostram os valores máximo e mínimo, respectivamente, atingidos durante o período escolhido. Todos os valores atingidos pela ação ao longo deste período estão contidos na linha vertical delimitada pelos valores de máximo e mínimo.

Os valores representados em um *candlestick* permitem algumas interpretações sobre o comportamento de uma ação: Por exemplo, se o tamanho da linha vertical inferior for muito grande em relação ao resto do *candlestick*, significa que o valor da ação caiu muito durante o período, mas que esta queda se reverteu, o que pode significar o início de uma tendência de alta. Por esta razão, os valores representados em *candlesticks* estão geralmente entre os mais utilizados como entrada para redes neurais de previsão ou para indicadores de ações, tratados na Seção 2.1.5.

2.1.4 Compra e venda de ações

Existem duas formas de se negociar ações no mercado financeiro, apresentadas a seguir:

- **Compra e Venda normal:** esta é a forma mais conhecida de negociação. Determinada ação é comprada por um preço e, após certo período, a ação é vendida por outro preço. Caso o preço de venda seja maior que o preço de compra, obtém-se lucro na diferença de valores. Caso contrário, obtém-se prejuízo. Este tipo de compra e venda é bem sucedido quando o valor da ação comprada sobe durante o período de investimento;

- **Compra e Venda a descoberto:** é a forma análoga da compra e venda normal, desconhecida pela maioria das pessoas. Neste método, um investidor começa o processo *vendendo* a ação, sem efetivamente possuí-la. Ao fim de determinado período, o investidor compra a ação vendida e, caso o preço de compra seja menor que o da venda (ou seja, se o valor da ação caiu durante o período), obtém-se lucro com a diferença. Na situação oposta, do preço de compra ser maior do que o preço da venda (ou seja, se o preço da ação subiu durante o período), obtém-se prejuízo. Esta modalidade de negociação de ações permite que investidores lucrem mesmo em períodos de queda na bolsa.

Uma estratégia de compra e venda de ações é composta de várias compras e vendas de ações, tanto normais quanto a descoberto, de acordo com critérios adotados por cada investidor. Essas operações podem ser realizadas com uma alta frequência, baixa frequência, ou apenas uma vez. Neste último caso, é caracterizada a estratégia *Buy and Hold*. Nela, uma operação de compra é feita no início de um período e só é vendida novamente após um período muito longo, que pode se estender até mesmo por vários anos. Neste tipo de estratégia, um investidor está interessado no longo prazo, e suas decisões de investimento são baseadas na confiança que o investidor tem na empresa na qual está investindo: variações negativas ou positivas são ignoradas, pois o que importa é o valor que suas ações terão ao fim do período.

2.1.5 Indicadores técnicos

Para entender melhor o comportamento de determinada ação e a tendência que essa ação está seguindo, apenas observar o histórico de seus preços não é suficiente, pois esse histórico não mostra a análise psicológica do que está acontecendo. Para melhorar o estudo dos preços de determinada ação, foram desenvolvidos indicadores técnicos que capturam comportamentos que não são visíveis quando apenas os preços são observados. Estes indicadores são geralmente modelos matemáticos que analisam valores passados de uma ação e tentam mostrar de alguma forma a tendência que os preços estão seguindo. O objetivo dos indicadores técnicos não é prever o que vai acontecer no futuro, como uma rede neural, mas fornecer ao investidor uma visão diferente da tendência do mercado, que não seria possível de se obter apenas com a observação dos seus preços.

Embora existam centenas de indicadores disponíveis na literatura, aqui é mostrado apenas um subconjunto destes indicadores. Os indicadores escolhidos são alguns dos mais usados, e são mostrados em ordem de complexidade para facilitar o seu entendimento, culminando na

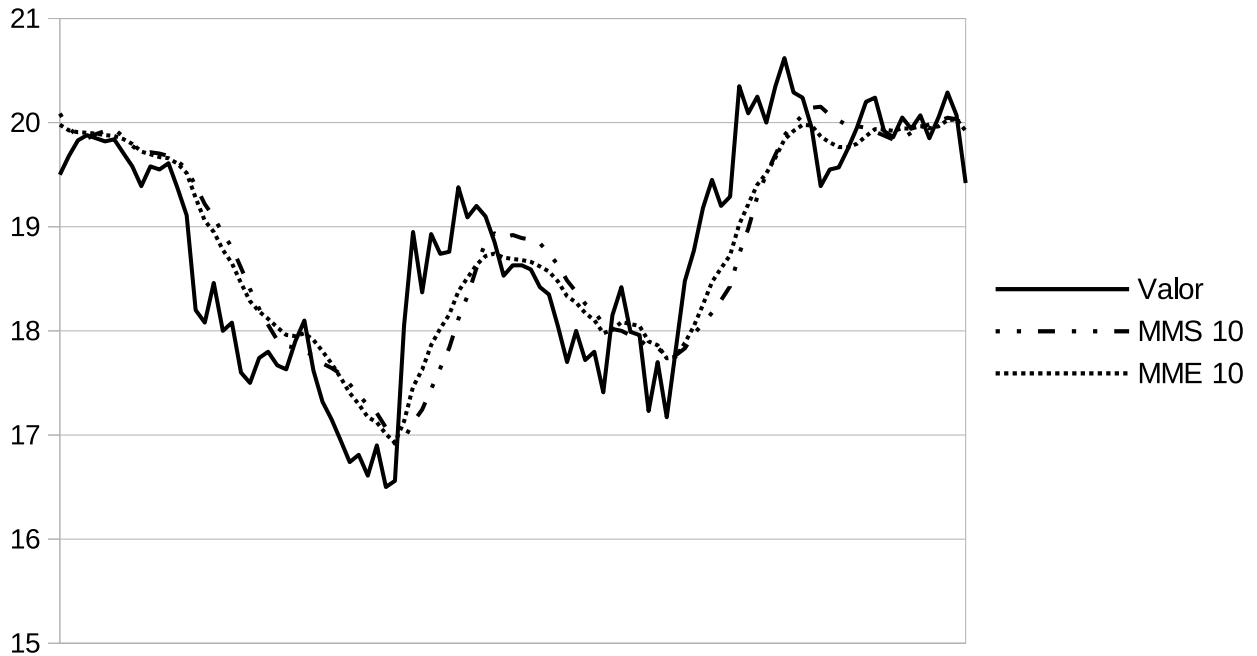
apresentação do indicador SAR, que é utilizado em nosso método. Não é feita uma análise profunda das capacidades de cada indicador visto que este é um tema muito extenso (uma análise completa demandaria um capítulo inteiro para cada indicador), e existe uma literatura adequada para tal. Alguns dos principais indicadores existentes são:

- **Média Móvel Simples (MMS)** - é o indicador mais simples de todos. Para calculá-lo, é feita a média aritmética dos preços da ação nos últimos n dias. Este indicador é muito útil, pois as séries temporais financeiras possuem muito ruído, e fazer a média de seus valores ajuda a eliminar essas pequenas variações, filtrando falsas mudanças de tendência. A interpretação do indicador é a seguinte: quando o indicador está subindo, significa que a tendência é de alta, e quando o indicador está caindo, significa que a tendência é de queda. Quando a direção da MMS muda, indica que a tendência (de alta ou de queda) também mudou;
- **Média Móvel Exponencial (MME)** - é semelhante à MMS, mas com a diferença de que a média dos preços da ação nos últimos n dias não é a aritmética, mas sim a exponencial. Nela, os dias mais recentes possuem peso maior no cálculo da média final do que os dias anteriores. Com esta alteração no cálculo da média móvel, é possível captar variações na tendência da ação com mais eficiência, já que o indicador muda de direção mais rapidamente. A interpretação do comportamento da MME é a mesma da MMS, embora existam técnicas que dão preferência ao uso de uma em detrimento da outra.

A Figura 2.2 mostra uma comparação do comportamento de ambas as médias. Nela, é possível observar que a MMS (dos últimos dez dias) responde mais lentamente do que a MME (também dos últimos dez dias) a variações de valores da série temporal, já que valores anteriores possuem pesos maiores no seu cálculo. Esta demora da MMS em captar a mudança de tendência não é necessariamente uma desvantagem em uma estratégia de investimento, cabendo ao investidor decidir qual tipo de média utilizar para atingir seu objetivo. Estratégias mais complexas utilizam estes dois tipos de médias em conjunto para capturar reversões de tendência da série temporal e detectar pontos de compra e de venda.

- **Índice de Força Relativa (IFR)** - como o nome sugere, o IFR (WILDER, 1978) tenta inferir a “força” da tendência de uma ação. O IFR é dado pela fórmula (2.1), onde n é a amplitude do período que se quer medir, U é a média das cotações dos últimos n dias em que a ação subiu e D é média das cotações dos últimos n dias em que a ação desceu. O IFR varia entre 0 e 100 e o seu valor tem a seguinte interpretação: quando o

Figura 2.2: Médias Móveis Simples e Exponenciais de 10 dias



Fonte: Autor

IFR está muito baixo (o limiar mais usado é abaixo de 30), o mercado está sobre vendido, ou seja, os preços estão muito baixos e podem subir a qualquer momento. Inversamente, quando o IFR está muito alto (o limiar mais usado é acima de 70), indica que mercado está sobre comprado, logo os preços estão muito altos e podem começar a cair a qualquer momento.

$$IFR = 100 - \left(\frac{100}{\left(\frac{U}{D} \right)} \right) \quad (2.1)$$

- **Stop and Reverse (SAR)** - o SAR (WILDER, 1978) tem como objetivo mostrar se o mercado está numa tendência de alta ou de queda. O cálculo do SAR é mostrado nas equações 2.2 (para uma tendência de alta) e 2.3 (para uma tendência de queda), onde SAR_n é o valor atual do SAR, SAR_{n-1} é o valor anterior do SAR, α é um fator de aceleração configurável, e PE (ou ponto extremo) é o maior valor máximo (ou menor valor mínimo) da tendência de alta (ou queda) atual. Se o valor do SAR em t é menor do que o valor mínimo atingido pela ação durante a tendência, configura-se uma tendência de alta e utiliza-se a Equação 2.2. O valor do SAR vai aumentando até ser maior que o valor mínimo atingido pela ação. Quando isto acontece, ocorre uma inversão de tendência: os valores de α e PE são reiniciados e passa-se a utilizar a Equação 2.3, desta vez comparando o valor do SAR com o valor máximo que a ação atingiu durante a tendência (agora de queda). O valor do SAR vai diminuindo até ser ultrapassado pelo valor máximo da

ação, disparando uma nova inversão de tendência e reiniciando o processo. Por apontar, entre outras informações, a direção da tendência do mercado, a saída do SAR é mapeada para os valores -1 se a direção do mercado é de queda e +1, caso contrário.

$$SAR_n = SAR_{n-1} + \alpha(PE - SAR_{n-1}) \quad (2.2)$$

$$SAR_n = SAR_{n-1} - \alpha(PE - SAR_{n-1}) \quad (2.3)$$

Existem inúmeras técnicas de compra e venda de ações que usam esses e outros indicadores. Para usá-las, contudo, é necessário ter um conhecimento da psicologia por trás de cada indicador e encontrar como técnicas diferentes podem se relacionar para prever valores ou tendências futuras. A enorme quantidade de indicadores disponíveis e de parâmetros que podem ser determinados para cada um desses indicadores cria praticamente infinitas combinações possíveis de serem utilizadas, dificultando a tarefa do analista de encontrar uma técnica efetiva de previsão. Quatro indicadores técnicos foram apresentados nessa seção pois, além de ajudar na introdução do conceito de indicadores técnicos, são alguns dos indicadores usados pelos estudos apresentados na revisão literária, mais adiante, e na proposta do nosso método.

2.1.6 Perfis de Investimento e de Investidor

O perfil de um investimento corresponde ao nível de risco que esse perfil proporciona a um investidor para atingir determinada lucratividade. Via de regra, maiores lucratividades são obtidas com investimentos mais arriscados. Por risco de um investimento, se entende que seja a possibilidade de que o capital investido seja perdido, parcialmente ou totalmente. Um perfil de investimento pode se dividir entre dois grupos extremos:

- **Agressivo:** investimentos desta categoria são os que fornecem alto risco ao investidor mas que também podem fornecer altos ganhos. Em alguns casos, a perda de capital pode ser total. Como exemplos deste tipo de investimento, estão o investimento em bolsas de valores ou em fundos de ações;
- **Conservador:** estes investimentos são os que fornecem baixo risco ao investidor, mas que geralmente fornecem ganhos pequenos e consistentes ao mesmo. Como exemplos destes investimentos estão o investimento na poupança e em aplicações de renda fixa.

Adicionalmente, um investidor pode ser classificado em três perfis, de acordo com o tipo

de investimento que utiliza:

- **Agressivo:** é o investidor que possui um alto percentual de investimentos agressivos, pois está disposto a assumir muitos riscos;
- **Moderado:** este investidor possui alguns investimentos agressivos, mas que não são a maioria de seus investimentos totais. Está disposto a assumir uma quantidade moderada de riscos;
- **Conservador:** é o oposto do investidor agressivo. Para este tipo de investidor, um alto percentual de investimentos conservadores é preferido. Opta apenas por operações com risco baixo ou nulo.

O perfil de um investidor é influenciado por vários fatores como: época em que seu investimento foi feito, valor do investimento, confiança do investidor na metodologia de investimento utilizada, idade do investidor (caso o investidor seja uma pessoa), quantidade de capital que se está disposta a perder, prazo desejado para resgate do investimento, etc. Relacionando os perfis de investidor e investimento, cabe ressaltar que não existe uma rigidez quanto à classificação de investidores apresentada: investidores agressivos podem fazer investimentos moderados e vice-versa. Adicionalmente, um investidor pode assumir uma posição agressiva em determinado momento e conservadora em outro.

2.2 Séries Temporais

Por ser um assunto vasto na literatura, nesta seção é utilizado como referência para os conceitos introduzidos o que é apresentado por Morettin e Toloi (2006), que definem uma série temporal como “um conjunto de valores obtidos através de observações, ordenadas no tempo”. Os valores de uma série temporal podem variar apenas com o passar do tempo ou de acordo com um conjunto de variáveis, desde que todas sejam dependentes do tempo. Uma notação comum para uma série temporal Y é dada em (2.4), onde t é o valor, pertencente a algum conjunto de índices, que representa o tempo.

$$IY = Y_t : t \in T \quad (2.4)$$

São exemplos de séries temporais:

- Temperatura em graus da cidade de Porto Alegre ao longo do mês;
- Número de passageiros da companhia de transportes Carris durante um ano;

- O registro do nível do Rio Uruguai durante as quatro fases da Lua;
- Preço das ações da empresa Petrobras na última semana.

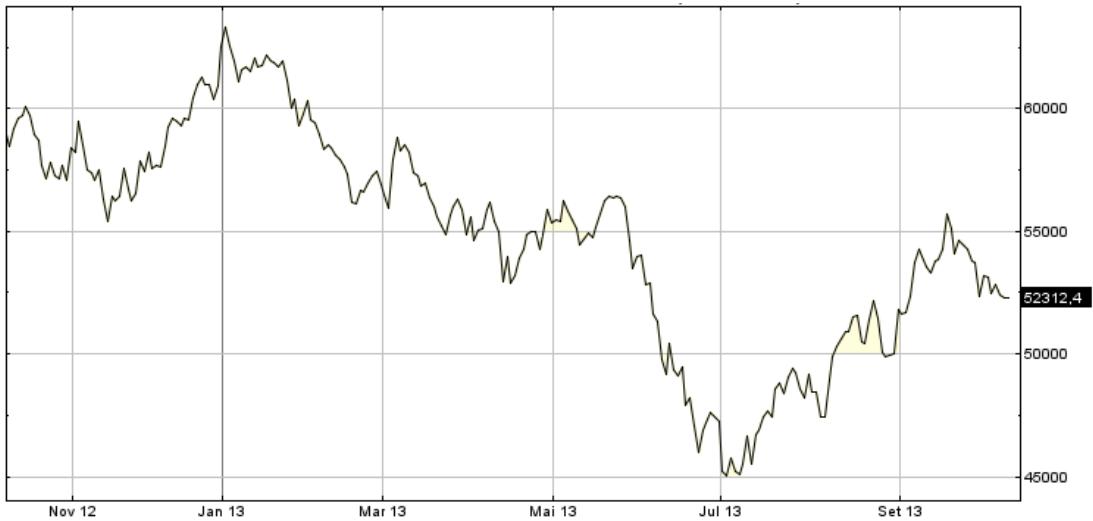
O estudo das séries temporais, por sua vez, é importante à medida que podem resolver os seguintes tipos de problemas: investigação dos fatores que estão influenciando no resultado da própria série temporal; descrição do comportamento da série (identificando características de sazonalidade, ciclos e tendências), busca de periodicidades relevantes nos dados, e previsão de valores futuros da série, sejam de curto ou longo prazo. Este último tipo de problema é onde há um maior interesse no trabalho com séries temporais financeiras, apresentadas na seção a seguir.

2.2.1 Séries Temporais Financeiras

Uma série temporal financeira é aquela que modela os valores de determinado indicador econômico (por exemplo, o valor do dólar, do rendimento da poupança, de determinada ação ou do crescimento do PIB de um país) ao longo do tempo. Este tipo de série apresenta algumas características especiais, também comuns a outros tipos de séries temporais:

- Presença de tendências - enquanto as séries temporais mais simples são estacionárias, ou seja, variam em torno de um valor médio constante, o comportamento das séries temporais financeiras segue tendências de alta e de queda, com durações variáveis, dependendo dos parâmetros do mercado;
- Sazonalidade - os valores alcançados por uma série temporal financeira podem variar de acordo com a época do ano e repetir o padrão de variação nos anos seguintes. Por exemplo, no mês de Dezembro, devido ao Natal, as ações de uma determinada loja de presentes sempre registram uma alta maior do que nos outros meses do ano;
- Pontos influentes - são valores incomuns, que fogem do padrão do restante da série temporal. Em séries financeiras, podem ser considerados pontos influentes momentos de alta volatilidade no mercado, gerando grandes altas ou quedas nos preços, que logo depois voltam ao seu patamar normal;
- Heteroscedasticidade condicional - a variância para os valores de entrada e saída da série temporal não é constante com o passar do tempo, tornando o comportamento da série temporal mais aleatório;
- Não-linearidade - devido à sua complexidade e ao seu comportamento estocástico, não é possível modelar este tipo de série temporal com uma função linear.

Figura 2.3: Série temporal financeira representando os valores do índice Bovespa



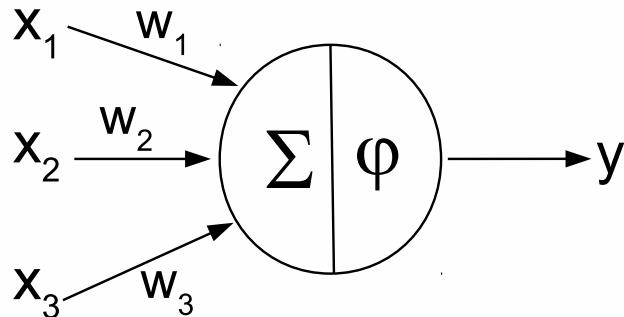
Fonte: Autor

A Figura 2.3 mostra a série temporal que modela os valores do índice Bovespa ao longo de um ano inteiro. Seu comportamento aparentemente aleatório, muito mais acentuado por se tratar de uma bolsa localizada em um país emergente, pode ser aproximado através do uso de redes neurais artificiais, tratadas na Seção 2.3.

2.3 As redes neurais artificiais

Uma rede neural artificial é um modelo matemático inspirado no comportamento do cérebro humano (MCCULLOCH; PITTS, 1943). A rede neural é representada por um grafo orientado, onde cada nó deste grafo representa um neurônio e cada aresta representa uma sinapse, ou seja, uma conexão entre dois neurônios. A menor unidade de uma rede neural é o próprio neurônio, representado na Figura 2.4. O neurônio é uma espécie de agente que recebe uma lista de entradas x e soma essas entradas proporcionalmente de acordo com o valor do peso w da sinapse correspondente. O resultado desta soma Σ é aplicado a uma função de ativação φ que definirá o valor de saída do neurônio. Esse valor de saída pode ser tanto o valor da saída da própria rede neural quanto o valor de entrada a ser fornecido para um próximo neurônio. Isto significa que, apesar de sua arquitetura simples, um neurônio pode ser combinado tanto em série quanto paralelamente a outros neurônios para formar uma rede complexa capaz de solucionar problemas maiores. A capacidade que as redes neurais artificiais têm de fornecer respostas corretas para conjuntos de entradas diferentes é chamada de *generalização*.

Figura 2.4: Estrutura do neurônio artificial



Fonte: Autor

Existem várias técnicas matemáticas voltadas para a previsão (ou generalização) de séries temporais e valores, como por exemplo: regressões lineares (um método matemático utilizado para fazer uma estimativa de uma variável y baseada em valores de outras variáveis x), regressões logísticas (um modelo estatístico que permite prever o resultado de uma variável dependente baseado no valor de outras variáveis independentes) e o método dos mínimos quadrados (que procura um ajuste para um conjunto de dados de entrada que minimize o erro médio quadrático – definido na Seção 2.4.3 – entre o valor real e o estimado). Estes métodos, contudo, não se comportam bem quando a série apresenta algum ruído, ou não alcançam desempenho satisfatório quando o número de variáveis de entrada é muito grande. As redes neurais artificiais surgem como uma alternativa para este tipo de problema, pois além de contornarem as limitações apresentadas, conseguem modelar problemas não lineares e identificar características de sazonalidade, tendência e periodicidade, comumente presentes em séries temporais financeiras. As redes neurais também podem processar os dados de entrada em paralelo, tornando seu desempenho melhor que outros métodos conhecidos. Outra vantagem no uso de redes neurais é que as redes neurais são capazes de processar grandes quantidades de dados de entrada sem o acompanhamento de um especialista.

Em trabalhos voltados à previsão de ações através do uso de redes neurais, os tipos de entrada mais fornecidos a essas redes são entradas relacionadas às próprias séries temporais financeiras (abertura, máximo, mínimo e fechamento, mostrados na Seção 2.1.2), séries temporais externas ao mercado sendo analisado (como valores de outros mercados de ações, *commodities*, ou até mesmo notícias da Internet) (OLIVEIRA et al., 2011) e as mais variadas combinações de indicadores técnicos (mostrados na Seção 2.1.5) (KARA; BOYACIOGLU; BAYKAN, 2011). Cada uma destas entradas é fornecida para um nodo diferente na camada de entrada de uma rede neural, que é treinada para retornar uma previsão de valor ou tendência futura.

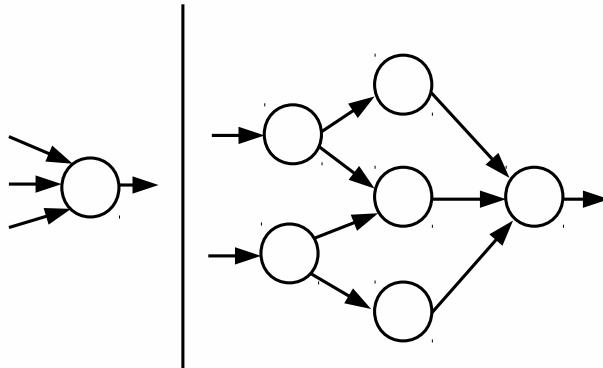
Além de neurônios e sinapses, nas pesquisas feitas com séries temporais financeiras, os termos relativos a redes neurais mais utilizados são: *Multilayer Perceptron*, *Feed Forward* e *Backpropagation*. Estes conceitos são descritos nas seções a seguir.

2.3.1 Single Layer e Multilayer Perceptrons

A divisão inicial entre os tipos de redes neurais se dá de acordo com o número de camadas em que seus neurônios são organizados. O tipo de rede mais simples é o de camada única, ou *Single Layer Perceptron* (SLP). Na SLP (ROSENBLATT, 1958) os neurônios estão organizados de forma paralela em uma única camada, onde recebem os valores de entrada e, de acordo com os pesos atribuídos e com a função de ativação atribuída a esses nodos, calculam a saída correspondente. Uma SLP é capaz apenas de classificar problemas linearmente separáveis, logo é necessário um tipo de rede mais complexo para tratar problemas maiores.

A rede multicamadas, ou *Multilayer Perceptron* (MLP), é um tipo de rede mais avançado e permite a resolução de problemas mais complexos. Numa MLP, os neurônios estão organizados em várias camadas, unidas entre si através de sinapses: a primeira camada recebe as variáveis de entrada e a última retorna os dados de saída. Opcionalmente, uma MLP pode ter também uma ou mais camadas intermediárias (também chamadas de camadas ocultas), responsáveis por aumentar a capacidade de processamento e aprendizagem da rede neural. O funcionamento de uma MLP é semelhante ao de uma SLP: os dados de entrada são passados para a camada inicial e vão trafegando entre as camadas intermediárias, quando presentes, até chegarem na camada de saída. A cada passagem de valor de uma camada para a próxima, o valor que chega do nó de origem é multiplicado pelo peso atribuído à sinapse entre os dois nós e filtrado pela função de ativação do nó de destino. O valor resultante destes cálculos é enviado para a camada seguinte. A Figura 2.5 ilustra um comparativo entre a organização de um SLP (à esquerda) e de um MLP (à direita). Os nós representam os neurônios e as arestas as sinapses entre esses neurônios.

Figura 2.5: Representação de uma rede neural do tipo *Single Layer Perceptron* e *Multilayer Perceptron*

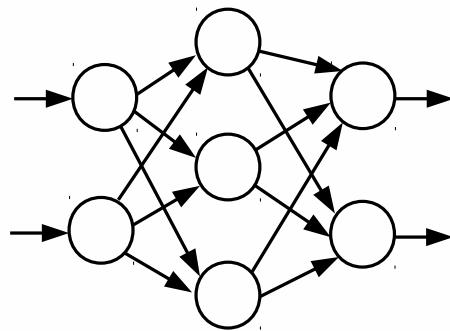


Fonte: Autor

2.3.2 Feed forward

Uma rede neural do tipo *Feed Forward* (FF) é uma MLP em que duas condições são satisfeitas: a primeira é a de que todas as sinapses devem ser direcionadas para a frente, ou seja, em direção à saída; a segunda é que a saída de cada nó deve ser replicada para todos os outros nós da camada seguinte. A Figura 2.6 mostra a arquitetura de uma rede FF com duas saídas. Nela é possível ver que, ao contrário da rede MLP da Figura 2.5, ambos os requisitos para a rede ser considerada FF foram atendidos.

Figura 2.6: Representação de uma rede neural do tipo *Feed Forward*



Fonte: Autor

Para uma rede FF resolver um problema, deve-se fornecer a essa rede os dados de entrada para os neurônios da primeira camada. Estes dados vão sendo propagados ao longo da rede até chegarem à camada de saída, que vai informar o resultado obtido.

2.3.3 Backpropagation

O grande diferencial de uma rede neural em relação a outros modelos matemáticos é a sua capacidade de aprender com o passado. Uma rede neural é capaz de, ao longo de um processo de aprendizado, realizar tal feito através do ajuste dos seus pesos sinápticos até obter uma resposta satisfatória. Existem várias técnicas de aprendizagem de redes neurais, que variam de acordo com o tipo de rede, e a mais famosa, utilizada em MLPs, é a *Backpropagation* (BRYSON; DENHAM; DREYFUS, 1963). Para implementar esta técnica em um algoritmo, é necessário fornecer para a rede neural um conjunto de casos de exemplo, com as entradas a serem fornecidas para a rede neural e as respectivas saídas esperadas. Um processo iterativo fornece um primeiro grupo de entradas para a rede neural que, através de uma configuração inicial de pesos sinápticos e da função de ativação atribuída aos seus neurônios, calcula a saída correspondente. Essa saída obtida é comparada com a saída esperada e, caso não seja satisfatória, uma heurística é utilizada para ajustar os pesos sinápticos da rede de forma que a rede neural retorne uma resposta mais próxima da esperada na próxima iteração. A seguir, um segundo grupo de entradas é fornecido para a rede neural, reiniciando assim o ciclo de treinamento, que é repetido até que a rede atinja um erro mínimo definido pelo programador.

Uma rede neural com *backpropagation* é recomendada para problemas com as seguintes características:

- existe uma grande quantidade de dados de entrada e não se sabe ao certo a sua relação com a saída esperada;
- é possível criar um conjunto de exemplos do comportamento esperado;
- a solução pode mudar ao longo do tempo, mesmo para entradas iguais.

Ao mesmo tempo, este tipo de rede não deve ser utilizada para problemas que:

- possam ser descritos num fluxograma (neste caso é preferível usar programação convencional);
- necessitam de precisão ou de uma solução analítica nos valores numéricos da saída (uma rede neural sempre fornece o resultado aproximado, mesmo que às vezes com um erro desprezível).

Problemas como processamento de imagens, reconhecimento de voz e previsão de séries temporais possuem as características listadas acima. Uma rede neural com *backpropagation* pode ser utilizada no tratamento destes tipos de problemas e obter altos índices de sucesso.

2.3.4 Ensemble de Redes Neurais

Uma forma de melhorar os resultados fornecidos por uma rede neural é colocá-la em um *ensemble* de redes neurais. Um *ensemble* é um conjunto de duas ou mais redes neurais, onde cada rede neural deste conjunto recebe as mesmas entradas e é treinada para resolver um problema em comum. A ideia é que redes neurais diferentes entre si (tanto na organização de sua arquitetura quanto na inicialização dos pesos iniciais de seus neurônios) retornem resultados diferentes para o mesmo conjunto de entradas. De posse de todos os resultados retornados pelas redes neurais internas do *ensemble*, algum método (por exemplo, votação ou média dos valores) é usado para escolher qual o resultado final do *ensemble*. O uso de várias redes neurais para calcular o mesmo problema adiciona uma redundância ao sistema, tornando possível que redes neurais que façam previsões erradas tenham seus resultados ignorados, pois o conjunto geral obtém um resultado diferente.

Na previsão de séries temporais em geral, nem sempre uma rede neural sozinha é a melhor solução para prever valores futuros. Neste sentido, vários trabalhos propõem o uso de *ensembles* de redes neurais para este tipo de tarefa, ou seja, um conjunto de redes neurais que são treinadas juntas mas que, de acordo com o método desejado, têm suas respostas unidas e interpretadas de maneira que o resultado final apresente uma segurança maior do que a do resultado que seria entregue por uma rede neural sozinha.

2.4 Métricas de desempenho

Para quantificar o desempenho de uma rede neural na previsão de séries temporais, costuma-se utilizar métricas que analisam as diferenças entre a série de valores previstos e a série de valores reais. A seguir, são mostradas algumas das métricas mais utilizadas para estes cálculos nos estudos pesquisados. Existem métricas que são utilizadas com maior frequência, porém não há uma que seja considerada melhor que as outras. A maioria dessas métricas é amplamente usada no campo da estatística e possuem autores desconhecidos. O objetivo dessa seção não é listar exaustivamente todas as métricas pesquisadas, mas fornecer uma introdução às métricas de avaliação de desempenho.

2.4.1 Erro Percentual Absoluto Médio

O Erro Médio Percentual Absoluto (ou MAPE – *mean absolute percentage error*) obtém as diferenças percentuais entre todos os valores reais e previstos obtidos e faz uma média simples destes valores. Como todos os elementos da série temporal têm igual peso no resultado final, resultados isolados muito diferentes dos demais não fazem tanta diferença. Essa métrica é útil para se ter uma visão geral do erro médio gerado pelo algoritmo de previsão escolhido. O MAPE é definido de acordo com a fórmula (2.5), onde N é o número de dias da série temporal sendo analisada, $P_{real,i}$ é o valor real da série no dia i e $P_{previsto,i}$ é o valor previsto para a série, também no dia i .

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left(\frac{|P_{real,i} - P_{previsto,i}|}{P_{previsto,i}} \right) * 100 \quad (2.5)$$

2.4.2 Raiz Quadrada do Erro Quadrático Médio

Essa métrica, também chamada de RMS ou RMSE (*Root Mean Squared Error*), é semelhante ao MAPE no sentido de que obtém o erro de todos os valores calculados. A diferença está no fato do erro calculado não ser um percentual, mas sim um valor numérico que indica o tamanho do erro médio obtido. O quanto mais próximo de zero for o erro, melhor são os resultados obtidos. O RMS é calculado a partir da fórmula (2.6), onde N é o número de dias da série temporal sendo analisada, $previsto_i$ é o valor previsto para a série no dia i e $real_i$ é o valor real da série também no dia i .

$$RMS = \sqrt{\frac{1}{N} \sum (previsto_i - real_i)^2} \quad (2.6)$$

2.4.3 Erro Médio Quadrático

O erro médio quadrático, ou MSE (*Mean Squared Error*) é talvez a métrica mais utilizada para calcular o desempenho de modelos de previsão. É calculado a partir da soma da variância e dos quadrados das diferenças obtidas entre os valores reais e previstos, e é dado pela fórmula (2.7) onde N é o número de dias da série temporal sendo analisada, $previsto_i$ é o valor

previsto para a série no dia i e $real_i$ é o valor real da série também no dia i .

$$MSE = \frac{1}{N} \sum_{i=1}^N (previsto_i - real_i)^2 \quad (2.7)$$

2.4.4 Erro Absoluto Escalado Médio

O erro absoluto escalado médio, ou MASE (Mean Absolute Scaled Error) (HYNDMAN; KOEHLER, 2006) é dado pela fórmula (2.8), onde $y_{real,j}$ e $y_{previsto,j}$ são os valores reais e previstos, respectivamente, para todas as observações j , e n é o número de elementos sendo analisados. O denominador é o erro médio absoluto do preditor trivial, que usa o valor anterior como previsão do próximo. As vantagens dessa métrica sobre as outras são que, ao calcular um erro escalado, o MASE permite analisar séries temporais de diferentes escalas e unidades, e como o denominador dificilmente é igual a zero, é mais robusto para calcular o erro em séries temporais com vários valores iguais a 0.

$$MASE = n^{-1} \sum_{j=1}^n \frac{|y_{real,j} - y_{previsto,j}|}{(n-1)^{-1} \sum_{r=2}^n |y_r - y_{r-1}|} \quad (2.8)$$

2.5 Considerações Finais

Este capítulo mostrou os conceitos básicos utilizados em redes neurais voltadas à previsão de séries temporais financeiras. O conhecimento sobre o funcionamento do mercado financeiro, principalmente sobre o funcionamento dos indicadores, é fundamental para a configuração e determinação dos parâmetros de entrada da rede neural. Por fim, foram apresentadas algumas das métricas de avaliação mais usadas na literatura pesquisada, que são importantes pois providenciam uma forma de analisar quantitativamente os resultados obtidos.

3 TRABALHOS RELACIONADOS

Neste capítulo são descritos os trabalhos já publicados que se relacionam com o assunto desta dissertação. Para facilitar a compreensão dos temas, estes trabalhos foram divididos em dois grupos com características similares: o primeiro grupo, mostrado na Seção 3.1, contém os trabalhos que se propõem a prever os movimentos dos mercados de ações. O segundo grupo, listado na Seção 3.2, mostra os trabalhos que usam *ensembles* de redes neurais para prever séries temporais em geral. Ao final de cada seção um comparativo geral entre os trabalhos pesquisados é apresentado. Existem vários trabalhos na literatura que tentam prever valores futuros de séries temporais usando redes neurais com diferentes variações (BERNAL; FOK; PIDAPARTHI, 2012; FARIA et al., 2009; MARTINEZ et al., 2009), mas estes não são descritos pois não estão diretamente relacionados com o método proposto neste trabalho.

3.1 Previsão do Movimento dos Mercados

Nem sempre a previsão de séries temporais implica em prever os próximos valores que essas séries atingirão no futuro. Dependendo do tipo de problema, pode ser mais vantajoso prever apenas se os valores futuros serão maiores ou menores do que os anteriores. Desta forma, a previsão a ser feita não é dos valores, mas sim dos movimentos que a série temporal irá realizar. Os trabalhos desta seção tratam o problema da previsão de séries temporais financeiras desta forma e, para treinar as suas redes neurais para prever movimentos futuros, tratam este tipo de problema como um problema de classificação, que consiste em classificar se a série temporal financeira sendo analisada irá subir ou descer no próximo período de tempo.

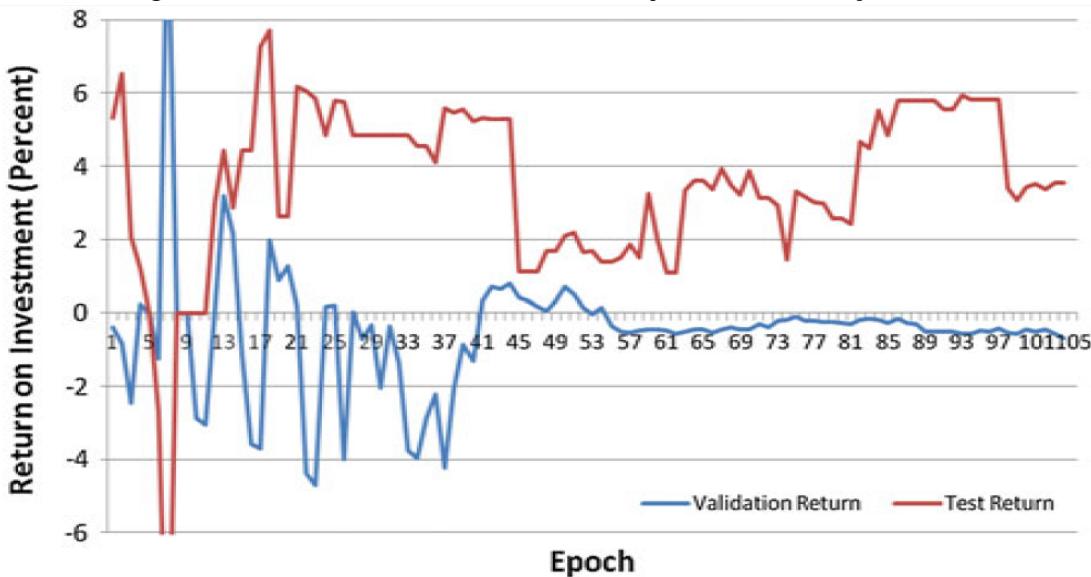
Achamos este tipo de abordagem mais interessante para a previsão de séries temporais financeiras uma vez que, se tentarmos prever o valor exato e sempre errarmos por um centavo, por exemplo, embora o resultado obtido de um ponto de vista matemático seja satisfatório por apresentar um erro muito baixo, na prática esse resultado não é muito útil, uma vez que se errarmos uma previsão por um centavo, a ação nunca irá alcançar o valor desejado. Desta forma, podemos deixar de executar uma operação de compra ou venda, comprometendo o capital investido. Se ao invés disso, tivermos a informação de que uma ação irá subir ou descer no próximo período (sem considerar quanto), podemos desenvolver uma estratégia de compra e venda que se adapte a este tipo de previsão. Kara, Boyacioglu e Baykan (2011) e Kim (2003) mostram que redes neurais que tentam prever o valor exato de uma ação podem não se comportar bem em períodos de alta volatilidade, não sendo possível confiar neles em todos os momentos. Para

corrigir esta insegurança, entradas auxiliares devem ser adicionadas a essas redes neurais para ajudar a tratar esses períodos de incerteza.

Nesta direção, Taylor, Kim e Choi (2014) propõem uma implementação de previsão que usa uma rede neural e uma estratégia de compra e venda. Esta estratégia fornece trinta dias no passado de valores de determinada ação para a rede neural que, por sua vez, é treinada para informar se a série temporal que representa esta ação pode ter um valor maior ou menor dentro de cinco dias. A estratégia é comprar/vender a ação no primeiro dia e vendê-la/comprá-la no quinto dia, dependendo da previsão da rede neural. Os autores afirmam usar como séries temporais nos experimentos 494 papéis da bolsa S&P 500, embora não fique claro nos resultados apresentados como estes papéis foram utilizados. O período de dados utilizado foi de 01/08/2009 a 31/10/2011. A rede neural utilizada é uma *feedforward* com *backpropagation* alimentada com os valores de abertura, fechamento, máximo, mínimo, volume, e médias móveis exponenciais de 5 e 26 dias de 30 dias no passado, totalizando assim 210 nodos de entrada. A rede neural também possui duas camadas ocultas e uma camada de saída com dois nodos que são treinados para retornarem 1 se a ação subir ou cair, respectivamente, mais de 3% dentro de 5 dias. A estratégia implementada utiliza um limiar de 0,8. Operações de compra e venda são executadas apenas se os nodos de saída atingem este valor mínimo, ou seja, não são todos os dias que a rede neural tem confiança em suas previsões, sugerindo uma abordagem mais conservadora. Para melhorar a capacidade da rede neural em descobrir padrões e ficar mais independente do aspecto temporal das entradas, as séries temporais foram randomizadas durante a fase de treinamento. Três medidas de desempenho foram adotadas para avaliar o método: o MSE das previsões, o percentual do retorno do investimento caso um investidor seguisse todas as recomendações do método e o percentual de acertos, ou seja, quantas vezes o método acertou a direção que o mercado iria seguir cinco dias no futuro. A Figura 3.1 mostra o percentual do retorno do investimento obtido pelo método durante um período de três meses. Os menores índices do MSE na fase de treinamento são obtidos a partir da iteração 44. Neste intervalo, o melhor retorno de investimento foi de 5,28%, uma performance 1,25% superior à do mercado em um período de três meses. O percentual de acertos, nestas mesmas condições, foi de 85,7% no melhor caso.

Dentre todos os trabalhos pesquisados, o de O'Connor e Madden (2006) é o que mais se aproxima de nossa proposta. A implementação apresentada é composta por uma rede neural que prevê o valor de fechamento do índice DJIA e, baseado no valor de abertura (já conhecido), infere se a série temporal pode cair ou subir. Se uma alta é prevista, o método efetua uma compra de uma ação hipotética que possui rendimento igual ao do índice. No dia seguinte, este processo

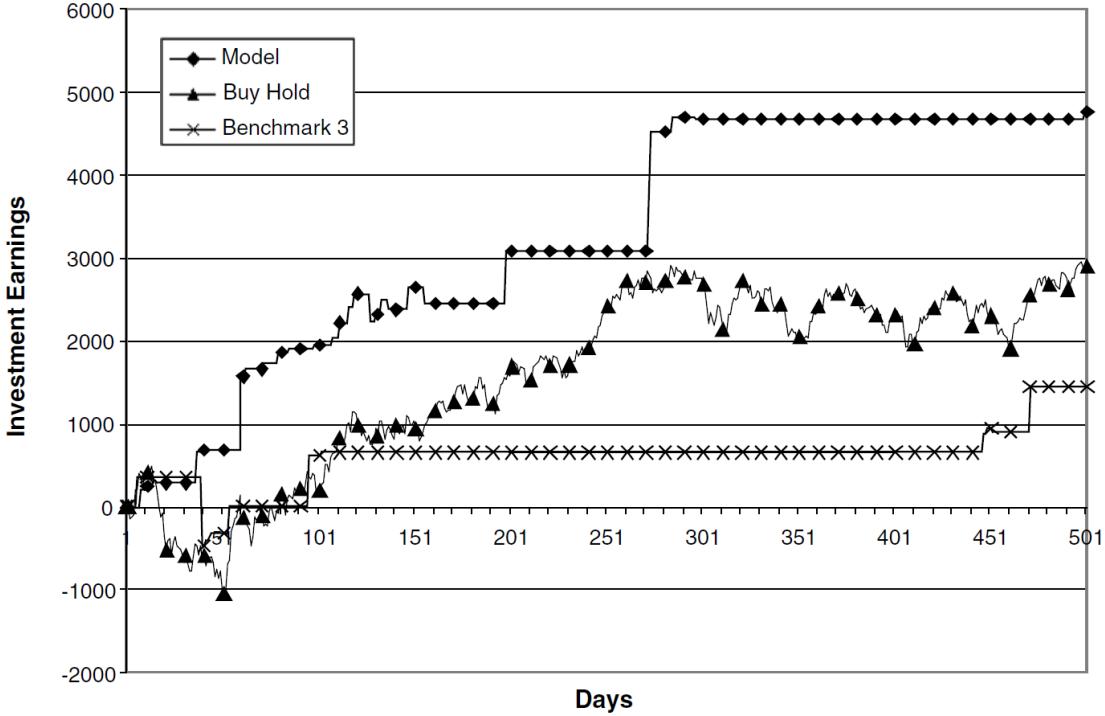
Figura 3.1: Percentual de retorno dos conjuntos de validação e teste



Fonte: (TAYLOR; KIM; CHOI, 2014)

é repetido: se o método prevê uma nova alta, a posição de compra é mantida. Inversamente, caso uma queda seja prevista, a ação é vendida imediatamente na abertura do mercado. O método não considera vendas a descoberto. Para a implementação do método, foi escolhida uma rede neural *feedforward* treinada com *backpropagation*. O período de dados utilizado para treinamento e testes foi de 11/02/1987 a 17/12/2002, totalizando 4500 pontos de dados. Vários conjuntos de entradas diferentes são utilizados no estudo, mas os melhores resultados foram obtidos ao se usar como entrada os últimos cinco valores da abertura do índice DJIA, do indicador financeiro Gradiente, do valor do petróleo, do yene japonês, da libra esterlina e do dólar canadense, além do valor de abertura do dia atual, totalizando assim 31 nodos de entrada. A rede neural também tem 2 camadas ocultas com 37 e 20 nodos, e uma camada de saída com 1 nodo, que embora o artigo não explique o que esse nodo retorna, inferimos que seja 1 para previsão de alta e 0 para previsão de queda. Pelas entradas passadas para o melhor caso, o estudo conclui que os melhores resultados são obtidos quando séries temporais externas são adicionadas à rede neural, ao invés de dados apenas da própria ação sendo analisada. Algo bem interessante que este trabalho propôs e que poucos nesta área fazem é comparar seus resultados com outros métodos, mesmo que triviais. Experimentos similares são feitos com recomendações de operações de 4 técnicas diferentes que são comparadas posteriormente com o desempenho da rede neural: médias móveis de 5, 10 e 30 dias, e a abordagem trivial, que considera que se uma ação subiu hoje, também subirá amanhã, e vice-versa. A Figura 3.2 mostra uma comparação entre os rendimentos do método proposto utilizando a rede neural treinada supondo um capital inicial de \$10.000,00. A figura mostra que o modelo proposto, que atingiu um rendimento de 23,42% ao

Figura 3.2: Comparação do crescimento de capital ao usar a rede neural proposta (Model), a estratégia *Buy & Hold* e Média móvel de 30 dias (*Benchmark 3*)



Fonte: (O'CONNOR; MADDEN, 2006)

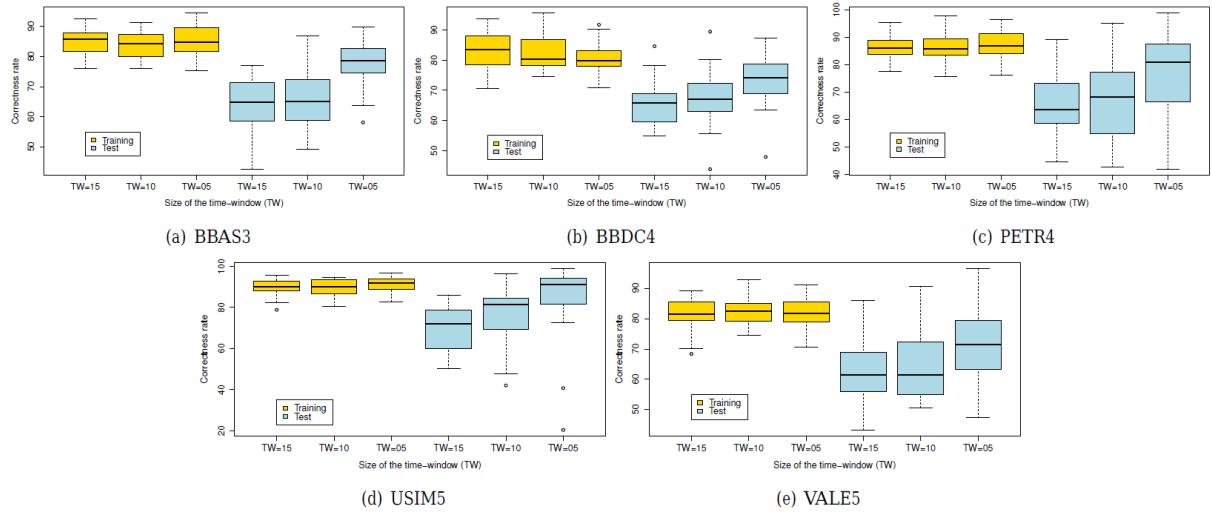
ano, supera todos os métodos de comparação. Uma última contribuição do artigo é propor uma discussão sobre se uma rede neural cujo objetivo seja sua utilização para aplicações financeiras deve ser treinada não para minimizar o erro médio, mas sim para maximizar a lucratividade.

O trabalho de Silva et al. (2014) foca na previsão do movimento de ações no curíssimo prazo, ou seja, com *candlesticks* de 5, 10 e 15 minutos, embora a técnica proposta possa ser estendida para periodicidades maiores. O objetivo é treinar uma rede neural para prever quando determinada ação sobe de valor no próximo *candlestick*. A utilização constante dessas previsões em uma periodicidade tão curta permite a implementação de um sistema de operações com alta frequência. Séries temporais de 5 empresas do índice Bovespa foram escolhidas como testes, e o método de treinamento e interpretação dos resultados da rede neural se diferencia um pouco dos demais nesta área: ao invés de comparar a entrada com a saída para saber se determinada ação subiu, a entrada é comparada com o valor máximo da ação durante o *candlestick*. Esta abordagem é interessante pois, mesmo que o valor de uma ação caia ao final do *candlestick*, o valor máximo atingido pela ação durante este período pode ter sido maior do que o da abertura, possibilitando assim uma operação visando o lucro mesmo com o valor final caindo, já que a operação seria finalizada durante o valor máximo, e não ao final do período. A rede neural considera que o período teve uma alta se o valor máximo atingido é maior do que o seu valor

inicial. A rede neural desenvolvida é formada por 3 camadas: a camada de entrada possui 14 nodos (valor de abertura do período sendo previsto, valores de abertura, fechamento, máximo e mínimo do *candlestick* de n períodos atrás, dependendo do tamanho de janela de tempo desejado, e os valores de 9 indicadores técnicos); a camada oculta possui 7 nodos e a de saída apenas 1, que indica se houve ou não uma oscilação positiva no período previsto. A rede neural foi treinada usando um conjunto com 1000 períodos. Para a geração dos dados de treino e teste, o artigo propõe mais uma novidade: normalmente um *candlestick* dura do período t_0 ao t_4 , e o próximo dura do t_5 ao t_9 , por exemplo, fazendo com que cada unidade de informação esteja contida apenas dentro de um *candlestick* de cada vez. Neste cenário, por exemplo, um período de uma hora pode ter apenas 4 *candlesticks* de 15 minutos. Os autores propõem o uso de *candlesticks* intermediários, ou seja, um dura do período t_0 ao t_4 , mas o próximo dura do período t_1 ao t_5 e assim por diante até t_9 . Esta forma de criação de *candlesticks* permite uma análise mais aprofundada do comportamento do mercado, além de multiplicar o número de *candlesticks* para o mesmo período de tempo. O conjunto de testes possui dados das ações escolhidas do índice Bovespa de Novembro a Dezembro de 2013. Os experimentos consideram janelas de tempo de 5, 10 e 15 minutos, e a rede neural é treinada para saber se a ação em questão pode subir R\$ 0,04 no próximo período (não se importando com o valor de cada ação). Os autores preferiram mostrar os resultados atingidos de uma forma mais estatística ao invés de financeira. A Figura 3.3 mostra os resultados atingidos com as 5 ações analisadas usando diagramas de caixa, divididos entre conjuntos de treino e teste, e agrupados de acordo com as janelas de tempo analisadas. Em cada caixa, a linha central representa a mediana do desempenho da rede neural. Na Figura 3.3, é possível perceber que o desempenho do método é semelhante em todas as ações, o que mostra que o método se comporta de maneira uniforme em diferentes séries temporais. Pela Figura 3.3 também é possível ver que não há uma grande diferença entre cada caso, com exceção da janela de tempo de 5 dias, que consegue obter resultados bem superiores.

Outros dois trabalhos nesta direção também foram analisados: o desempenho de redes neurais, máquinas de vetores de suporte, floresta aleatória e do classificador Naive Bayes na previsão da direção (para cima ou para baixo) de um mercado de ações é analisado em Patel et al. (2015). Os autores concluem que, quando as entradas são discretizadas, todos os algoritmos têm seus resultados melhorados se comparados ao caso em que dados contínuos são usados. Também um novo modelo é apresentado por Jasemi, Kimiagari e Memariani (2011), onde uma modelagem de análise técnica é feita usando redes neurais para capturar sinais de compra e venda que podem ser encontrados analisando os valores dos *candlesticks*.

Figura 3.3: Diagrama de caixa dos conjuntos de treinamento e teste, agrupados por ação



Fonte: (SILVA et al., 2014)

A Tabela 3.1 mostra um quadro comparativo com as principais características de cada estudo. O tipo de entrada mais usado nos estudos dessa categoria são cotações anteriores da série temporal financeira sendo estudada, porém todos os trabalhos adicionam outro tipo de série temporal às entradas da rede neural. Para prever a direção do mercado, o redes neurais do tipo MLP são uma unanimidade na área. As séries temporais utilizadas em sua maioria são ações do mercado sendo analisado, com exceção do trabalho de O'Connor e Madden (2006), que tenta prever a direção do índice Dow Jones. Conforme esperado, a métrica preferida para medir a eficácia de métodos que preveem valores futuros é o retorno de investimento (RI), que é o valor final de uma carteira hipotética que opera de acordo com a saída fornecida pela rede neural. Nossa método proposto consolida o uso de cotações anteriores como entradas para as redes neurais, o uso de MLPs na arquitetura dessas redes neurais, e o retorno de investimento como métrica de avaliação dos resultados. Além disso, estende esse tipo de trabalho no sentido usar *ensembles* para classificar as saídas das redes neurais e de testar os resultados atingidos em séries temporais com características diferentes.

3.2 Uso de *Ensembles* na Previsão de Valores

Embora demostrem resultados satisfatórios na previsão de valores futuros em séries temporais, o uso de *ensembles* (apresentados na Seção 2.3.4) para este tipo de problema ainda é pouco utilizado na literatura. Nesta seção, são analisados os trabalhos que propõem o uso de

Tabela 3.1: Comparativo entre os trabalhos que preveem o movimento de séries temporais

Trabalho	Entradas	Tipo de RN	Série Temporal Prevista	Métricas
(TAYLOR; KIM; CHOI, 2014)	Cotações anteriores, médias móveis	MLP	494 ações americanas	MSE, RI
(O'CONNOR; MADDEN, 2006)	Cotações anteriores, preço do petróleo e cotações de moedas	MLP	Índice Dow Jones	RMSE, RI
(SILVA et al., 2014)	Cotações anteriores, 10 indicadores técnicos	MLP	BBAS3, BBDC4, PETR4, USIM5 e VALE5 (ações brasileiras)	Média aritmética, desvio padrão e coeficiente de variação

ensembles de redes neurais para resolver o problema da previsão de séries temporais, mesmo que esses trabalhos não chamem seus conjuntos de redes neurais assim.

O trabalho de Neto et al. (2010) apresenta três inovações para calcular o valor das ações da bolsa brasileira: o uso de séries exógenas (ou seja, séries externas e independentes das séries sendo calculadas) nos parâmetros de entrada; a criação de uma nova métrica de avaliação dos resultados obtidos, voltada para o mercado financeiro e que, portanto, retorna melhores avaliações; e o uso de um *ensemble* de redes neurais (chamado neste artigo de “comitê”) para prever os valores futuros da série temporal financeira desejada. O artigo foca na previsão das ações das empresas Petrobras e Vale, por serem as mais negociadas no mercado. A base de dados utilizada contém 1200 dias de dados para as fases de treinamento e validação e 300 dias para a fase de testes. Não são informadas as datas em que estas informações foram coletadas. A rede neural proposta, além de ter como parâmetros de entrada séries relacionadas com a ação que se deseja avaliar (preço de abertura, fechamento, máximo e mínimo), também recebe como parâmetros séries externas que influenciam no valor da ação – as chamadas séries exógenas. No caso da Petrobras, as séries temporais exógenas escolhidas foram as que representam o valor do dólar, do índice Bovespa, do índice DAX (a bolsa de valores alemã), o preço do barril de petróleo e o preço da ação da Petrobras na bolsa americana. Para a Vale, as séries exógenas escolhidas foram apenas as que indicam os valores do dólar e do índice Bovespa. O novo método matemático proposto para calcular a eficiência de uma rede neural foi nomeado pelos autores como *Prediction in Direction and Accuracy* (PDA). O cálculo do mesmo é muito extenso e precisaria de uma seção inteira para ser descrito, o que não é o objetivo deste trabalho. Contudo, é válido dizer que a fórmula que calcula o PDA, ao contrário da fórmula das métricas utilizadas normalmente (como a MSE ou qualquer uma das mostradas na Seção 2.4), consi-

dera como de igual peso um erro ou um acerto na previsão, não importando sua acurácia. Por exemplo: não importa se a rede neural errou o valor efetivo por dez centavos ou por um real: ambos têm o mesmo desconto no cálculo do desempenho. O mesmo vale para os acertos. Além disso, no caso de previsões corretas, o valor adicionado à nota do desempenho aumenta a cada acerto consecutivo. Outra métrica de avaliação usada neste trabalho é a SLG (*Sum of Losses and Gains*), proposta pelos mesmos autores em outro trabalho. O último elemento do método proposto é o uso de comitês, descrito como um conjunto de redes neurais que, para resolver um grande problema, o decompõe em problemas menores que são resolvidos por cada uma das suas redes neurais separadamente. As soluções são unidas num agrupador (no caso do artigo, do tipo *Perceptron*) que calcula o resultado final. A inovação do artigo está em ser o primeiro a usar este tipo de rede neural para calcular séries temporais financeiras de empresas brasileiras. Para os experimentos, foram utilizados os dois tipos mais comuns de redes neurais, um de cada vez: *Multilayer Perceptron* (MLP) e *Radial Basis Function Neural Network* (RBF). Um dos objetivos do artigo também é comparar o desempenho das redes neurais destes dois tipos na previsão de séries temporais. A Figura 3.4 mostra uma comparação do desempenho das redes neurais criadas através do uso da métrica PDA (nela, quanto maior o valor, melhor é a rede). A Figura 3.4 é uma simplificação da original do artigo, que faz a comparação não apenas usando o PDA, mas outras seis técnicas comuns na literatura. De qualquer forma, as redes neurais que usam séries exógenas obtiveram melhores resultados em todos os experimentos. O artigo é interessante pois propõe um alto número de inovações propostas: a maioria dos artigos propõe apenas uma inovação, ao passo que este apresenta e avalia três inovações. Também merece destaque o alto número de comparações feitas: são avaliadas redes neurais com e sem séries exógenas, com e sem comitês, e do tipo MLP e RBF. Adicionalmente, sete métricas são utilizadas para a comparação do desempenho, dando mais sustentação aos resultados apresentados.

Um *ensemble* não precisa ser obrigatoriamente formado exclusivamente por redes neurais. Zhai, Shu e Halgamuge (2007) propõem uma implementação que combina notícias do mercado financeiro com séries temporais financeiras em um conjunto de máquinas de vetores de suporte (SVM, do inglês *Support Vector Machine*), mostrando que o desempenho e a rentabilidade de uma SVM que usa apenas séries temporais como entrada cresce ao se adicionar uma SVM que analisa as notícias. Os autores justificam o uso de SVMs sobre o de redes neurais com o argumento de que uma rede neural pode sofrer *overfitting* (ou seja, “decorar” padrões ao invés de “aprender” a prevê-los) e precisar de um alto número de parâmetros de entrada para fornecer resultados satisfatórios. O estudo também é um dos poucos disponíveis que usam notícias sobre o mercado para prever valores futuros. Não é o objetivo desta dissertação analisar

Figura 3.4: Desempenho do método proposto para redes do tipo MLP e RBF, com e sem séries exógenas

BEST RESULTS WITHOUT EXOGENOUS TIME SERIES ($\bar{X}(\sigma)$).		
PETR4 database		
Metric	MLP	RBF
PDA	0.067723(0.011909)	0.071899 (0.0058518)
VALE5 database		
Metric	MLP	RBF
PDA	0.03963(0.016661)	0.069981 (0.0058881)

BEST RESULTS WITH EXOGENOUS TIME SERIES ($\bar{X}(\sigma)$).		
PETR4 database		
Metric	MLP	RBF
PDA	0.194(0.043503)	0.21815 (0.023141)
VALE5 database		
Metric	MLP	RBF
PDA	0.20739(0.013663)	0.21295 (0.020237)

Fonte: (NETO et al., 2010)

a fundo o que são SVMs, mas podemos dizer que SVMs são uma técnica de previsão e classificação de valores concorrente das redes neurais, que resolve problemas através da construção de um hiperplano. Defensores do uso de SVMs alegam como suas vantagens a falta da necessidade de setar vários parâmetros de configuração, a baixa possibilidade de ocorrer *overfitting* e a impossibilidade das SVMs ficarem presas num mínimo local durante a fase de treinamento. A arquitetura da implementação proposta é composta por um *ensemble* de 4 SVMs e um módulo de previsão. A primeira SVM recebe como entrada os valores de 7 indicadores financeiros nos últimos 5 dias e retorna uma classificação informando se a ação vai subir ou descer no próximo dia; usando técnicas de processamento e análise textuais, a segunda e terceiras SVMs retornam classificações baseadas em informações coletadas em notícias que aconteceram entre o último fechamento e a manhã do dia seguinte, específicas da ação sendo analisada e do mercado em geral, respectivamente; a quarta e última SVM combina os resultados da segunda e terceira SVM em uma previsão única que considera todas as notícias relevantes. Finalmente, um módulo final de predição une as classificações da primeira e quarta SVMs para retornar uma previsão final do movimento previsto para a ação. A parte superior da Figura 3.5 mostra o índice de acertos dos movimentos da bolsa para cada elemento do *ensemble* proposto, mostrando que a análise de notícias gera melhores resultados do que a análise dos indicadores financeiros, e que esses resultados podem ainda serem melhorados se combinados em um classificador comum. Os ex-

Figura 3.5: Precisão das previsões de acordo com o tipo de entrada e rentabilidade do método proposto

Data sets	Accuracy (%)
Price	58.8
Direct news	62.5
Indirect news	50.0
Combined news	64.7
Price & News	70.1

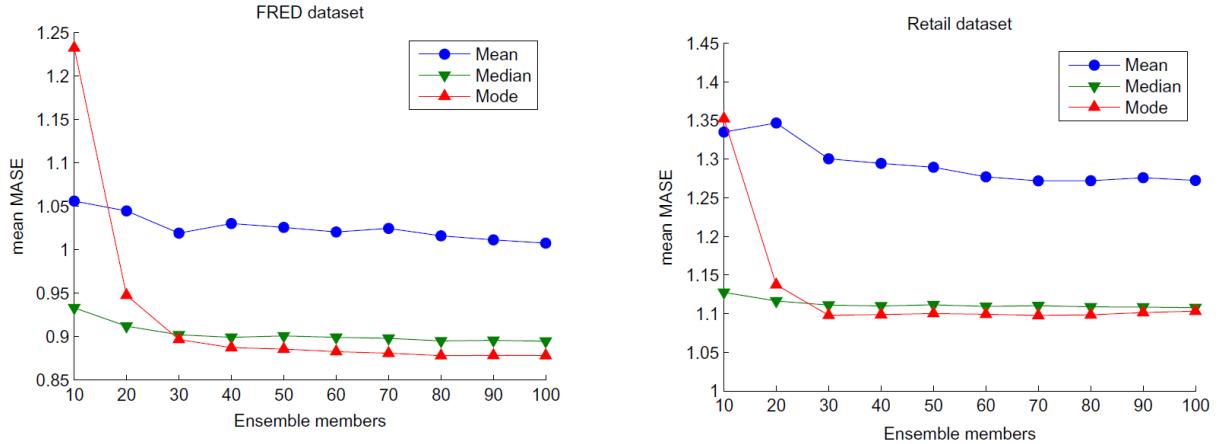
System	No. of trades	Net profit
Random	8	\$-54
Price Only	9	\$284
News Only	7	\$275
Price and News	11	\$511

Fonte: (ZHAI; HSU; HALGAMUGE, 2007)

perimentos foram feitos com a série temporal da BHP Billiton, a maior empresa de mineração do mundo, de origem australiana, com dados diários de 01/02/2005 a 31/05/2006. Baseado na análise anterior, os autores concluíram que a previsão resultante das notícias deve ter um peso maior na decisão final do que a previsão oriunda dos indicadores financeiros, logo, se ambas as previsões discordarem entre si, a previsão gerada pelas notícias sempre prevalece. A previsão a partir dos valores financeiros só é realmente utilizada quando não se possuem notícias suficientes durante o dia para fazer uma previsão com segurança. A parte inferior da Figura 3.5 mostra o número de operações e a lucratividade atingidos num período de 40 dias de operações. Os melhores resultados foram obtidos com o uso de todos os elementos do *ensemble* proposto, mostrando que o uso deste conjunto de SVMs realmente produz melhores resultados.

Baseado em evidências extraídas de outros trabalhos, de que *ensembles* possuem um desempenho melhor do que redes neurais sozinhas, Kourentzes, Barrow e Crone (2014) fazem, em um recente trabalho, uma comparação entre *ensembles* que usam diferentes tipos de operadores (média, mediana e moda) com diferentes quantidades de elementos para analisar quais combinações apresentam os melhores resultados. A motivação para esta comparação é que, embora os *ensembles* sejam superiores às redes neurais, seu desempenho é uma função de como as previsões individuais são combinadas. Logo, melhorias na combinação dos operadores dos *ensembles* influenciam diretamente na precisão das previsões. Os operadores aos quais o artigo se refere são usados na forma que o *ensemble* escolhe o valor final de uma previsão baseado na previsão de todas as suas partes. Os tipos de operadores são brevemente resumidos a seguir:

Figura 3.6: MASE médio para diferentes números de elementos no *ensemble* para as bases do FRED e ONS, respectivamente



Fonte: (KOURENTZES; BARROW; CRONE, 2014)

- *Média* - é a média aritmética entre todos os valores obtidos. É sensível a valores extremos e a distribuições assimétricas;
- *Mediana* - ordenando todos os valores obtidos, é o valor que fica exatamente no centro, caso o número de elementos seja ímpar, ou a média dos dois valores centrais, caso contrário. É mais robusta que a média, mas ainda é sensível a distribuições assimétricas;
- *Moda* - é o valor que mais se repete entre todos os valores obtidos e que, consequentemente, tem a maior probabilidade de ser selecionado dentro da amostra. Este operador não é sensível a valores extremos ou a distribuições assimétricas;

O trabalho tem fundamentação teórica e não tem como objetivo mostrar os resultados atingidos por algum tipo específico de série temporal. Para tentar atingir esta imparcialidade, os autores usam em sua avaliação dois conjuntos de dados: o primeiro possui 3000 séries temporais com dados mensais extraídos da Reserva Econômica Federal de St. Louis (FRED), cada um com ao menos 108 elementos (9 anos de dados); o segundo contém 443 séries temporais extraídas do Escritório Britânico de Estatísticas Nacionais (ONS), cada um também com no mínimo 108 elementos. Os últimos 18 elementos de cada série temporal foram utilizados no período de testes. A Figura 3.6 mostra os resultados (calculados com o MASE) dos experimentos obtidos com os 3 operadores diferentes para *ensembles* possuindo de 10 a 100 elementos. Em ambos os casos, o operador Moda teve os menores índices de erro a partir de 30 elementos, sugerindo que esse operador é mais recomendável para grandes *ensembles*. O operador da Mediana se comportou melhor para *ensembles* de menor quantidade de elementos.

Além dos trabalhos mais profundamente aqui analisados, existem outros que usaram *ensembles* em seus estudos (às vezes não necessariamente para prever séries temporais financeiras, mas para outros tipos de problema) que valem a menção: Chen, Yang e Abraham (2007) utilizam um *ensemble* para prever os próximos valores de três grandes mercados de ações e obtém resultados com índices de erro muito baixos. Um algoritmo genético é usado em Pulido, Melin e Castillo (2011) para implementar um *ensemble* de redes neurais com integração *fuzzy* para prever a série temporal de *Mackey-Glass*, mostrando que esta abordagem também pode ser usada em problemas de otimização, com resultados satisfatórios sendo alcançados. Dois novos métodos de avaliação de *ensembles* (para redes neurais do tipo *feedforward* e para o método *kernel* de regressão por mínimos quadrados parciais) foram propostos por Embrechts et al. (2012) para prever taxas de conversão de câmbio entre moedas diferentes, alcançando índices de erro menores do que redes neurais sozinhas. El-Shafie et al. (2014) mostra que *ensembles* de redes neurais não apenas fazem previsões melhores mas também se adaptam a mudanças bruscas nas séries temporais melhor do que redes neurais sozinhas, usando como caso de estudo dados históricos da combinação entre índices de evaporação do solo e transpiração das plantas na Malásia e no Irã. Finalmente, Asaduzzaman et al. (2014) usa um *ensemble* de dez redes neurais, além de um conjunto de outras otimizações, para prever 30 problemas diferentes no campo da previsão de séries temporais financeiras, obtendo um índice de sucesso de 60%.

A Tabela 3.2 mostra um comparativo dos principais trabalhos pesquisados que utilizam *ensembles* na previsão de séries temporais. Ao contrário dos estudos que focam no movimento da Seção 3.1, não há uma característica que seja amplamente usada pelos estudos que utilizam *ensembles*, indicando uma falta de consenso nesta área. As entradas para os *ensembles* são sempre dados anteriores da série temporal sendo analisada, porém variados tipos de entradas adicionais também são adicionados em cada estudo. O tipo de rede neural mais usado também é o MLP, como em Neto et al. (2010) e em Kourentzes, Barrow e Crone (2014), porém o primeiro não usa MLPs com exclusividade, e cria um conjunto de preditores que usa redes neurais com arquiteturas diferentes (MLP e RBF). As séries temporais mais usadas são valores históricos de ações, mas Kourentzes, Barrow e Crone (2014) usam dados bancários extraídos de bases de dados financeiras. Zhai, Shu e Halgamuge (2007) usam apenas uma série temporal em seus testes, o que pode levantar dúvidas quanto à eficácia do seu método para outras séries temporais. Por fim, as métricas de avaliação são totalmente diferentes entre cada estudo, com Neto et al. (2010) inclusive propondo uma técnica nova de medição dos resultados atingidos. Nossa método busca consolidar o uso de cotações anteriores como entrada para o *ensemble*. Além disso, propomos uma classificação dos resultados semelhante à feita por Zhai, Shu e

Halgamuge (2007), porém com uma nova arquitetura de *ensembles*, capaz de prever séries temporais financeiras de vários tipos e características diferentes.

Tabela 3.2: Comparativo entre os trabalhos que utilizam *ensembles* para prever séries temporais

Trabalho	Entradas	Tipo de RN	Série Temporal Prevista	Métricas
(NETO et al., 2010)	Cotações anteriores, 6 séries exógenas	MLP e RBF	PETR4 e VALE5 (empresas brasileiras)	MSE, MAPE, POCID, NMSE, ARV, SLG e PDA
(ZHAI; HSU; HAL-GAMUGE, 2007)	Cotações anteriores, 4 indicadores técnicos e notícias das companhias	SVM	BHP (empresa australiana)	Índice de acertos, precisão (%), RI
(KOURENTZES; BARROW; CRONE, 2014)	Valores anteriores	MLP	3443 séries temporais com dados financeiros dos EUA e da Inglaterra	MASE

3.3 Considerações Finais

Existe uma grande quantidade de estudos na literatura que foca na previsão da direção de séries temporais, mas a maioria desses estudos usa uma rede neural sozinha para esta tarefa. Por outro lado, também existem vários trabalhos que usam *ensembles* para melhorar a previsão de séries temporais, mas a maioria desses estudos não tenta prever o movimento da série, mas sim seus valores futuros. Finalmente, trabalhos que focam em séries temporais financeiras geralmente calculam sua eficiência com uma métrica de erro, sendo poucos os casos em que os autores conseguem efetivamente transformar suas previsões em operações reais.

Com tantos estudos mostrando que os resultados das previsões de redes neurais melhoram quando *ensembles* são utilizados, é seguro afirmar que estes devem ser usados sempre que possível em detrimento a redes neurais isoladas. Adicionalmente, a classificação de séries temporais é a abordagem mais comum quando o objetivo do estudo é transformar os resultados devolvidos por uma rede neural em operações no mundo real. Usando este tipo de classificação, pode ser desenvolvido um método de compra e venda para operar no mercado de ações com um nível satisfatório de segurança. Como foi possível observar nos trabalhos relacionados, ainda não existe um método de previsão da direção dos mercados que usa *ensembles* de redes neurais para transformar seus resultados em operações reais.

Identificamos uma lacuna nesta área de pesquisa, uma vez que estes estudos poderiam complementar um ao outro. Neste sentido, se pudéssemos melhorar um sistema de classificação de séries temporais financeiras adicionando-o a um *ensemble*, um número maior de classificações corretas seria atingido, possibilitando desta forma um maior ganho de capital.

4 MODELO PROPOSTO

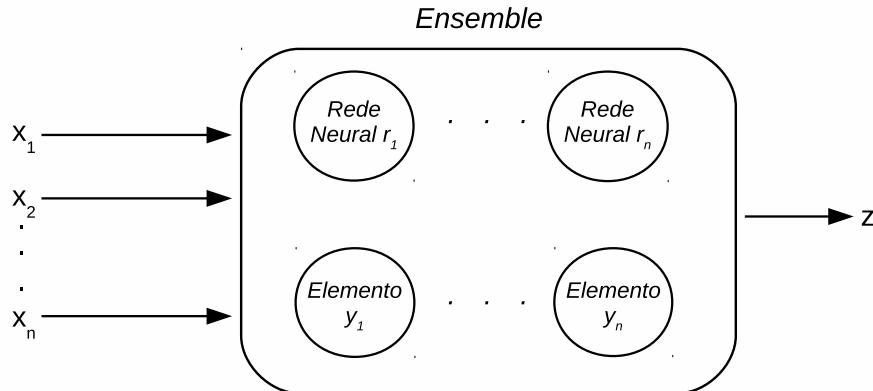
O objetivo deste capítulo é apresentar o método proposto para a previsão de séries temporais financeiras, cuja visão geral é mostrada na Seção 4.1. Posteriormente, são propostos neste capítulo dois *ensembles* diferentes, cada um para determinado perfil de investidor: na Seção 4.2 é apresentado nosso *ensemble* moderado, que sugere operações apenas nos dias em que certo grau de certeza é atingido; na Seção 4.3 mostramos uma expansão do *ensemble* moderado, resultando em um *ensemble* agressivo que sugere operações todos os dias. O *ensemble* agressivo permite lucros maiores do que os lucros obtidos pelo *ensemble* moderado no mesmo período de tempo, porém o risco de prejuízo também é maior devido ao grande volume de operações recomendadas. A Seção 4.4 discute como foi feita a implementação do método proposto, mostrando quais técnicas existentes na literatura foram utilizadas e quais foram descartadas.

Os *ensembles* propostos são formados por redes neurais que classificam os valores das saídas de séries temporais financeiras em previsões de alta ou queda dos valores e usam os resultados dessas classificações em um sistema de compra e venda de ações. Os resultados finais são mostrados como um conjunto de operações simuladas baseadas nas recomendações dos *ensembles*. A contribuição do método proposto, além de preencher a lacuna identificada na Seção 3.3, é a proposta de uma metodologia de compra e de venda de ações automatizada através dos *ensembles* apresentados.

4.1 Visão Geral

A Figura 4.1 mostra a arquitetura geral de ambos os *ensembles* propostos. As variáveis $x_1, x_2 \dots x_n$ são os valores anteriores da série temporal sendo analisada, fornecidos como entrada ao *ensemble*. O operador não conhece a organização interna do *ensemble* então, para esse operador, o *ensemble* é apenas uma caixa preta formada por um conjunto de redes neurais $r_1, r_2 \dots r_n$ e por outros elementos $y_1, y_2 \dots y_n$ que não precisam ser necessariamente redes neurais. Todos esses elementos se relacionam para fornecer a classificação final z . Essa classificação é escolhida entre um conjunto de valores possíveis, e é uma previsão do valor que a série temporal terá no próximo período de tempo. O operador utilizará esse resultado na tomada de decisão sobre o que fazer nesse próximo período de tempo.

Figura 4.1: Visão geral da arquitetura dos *ensembles* propostos



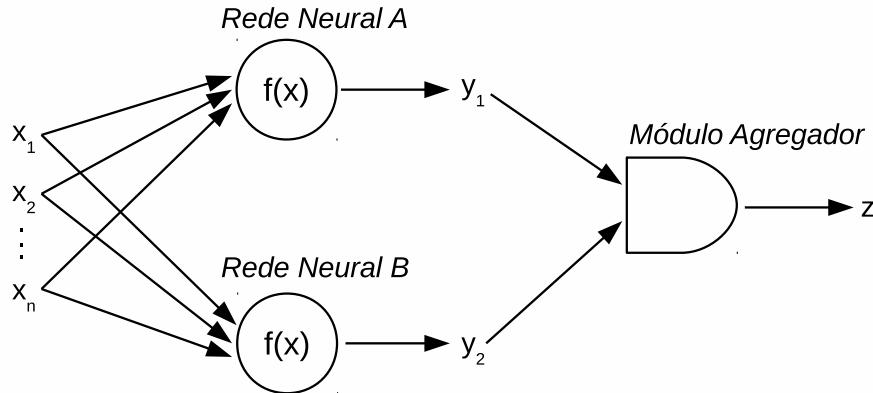
Fonte: Autor

4.2 Ensemble Moderado

O *ensemble* moderado é visualizado pelo usuário como uma caixa preta que recebe como entradas os últimos valores da abertura, máximo, mínimo e fechamento de determinada ação e classifica este conjunto de entradas em um de três valores de saída possíveis, que se referem à próxima unidade de tempo: *alta*, *queda* ou *não sabe*. De posse desta informação, um investidor pode decidir como operar no próximo período de tempo.

Internamente, o *ensemble* moderado é composto por duas redes neurais, daqui em diante chamadas de “redes neurais A e B”, e por um módulo agregador que combina as saídas dessas redes. Ambas as redes neurais são treinadas para classificar suas entradas em uma de duas saídas possíveis: *alta* ou *queda*. A Figura 4.2 mostra como as redes neurais e o módulo agregador são organizados de forma a fornecer uma classificação final. As entradas $x_1, x_2 \dots x_n$ do *ensemble* são passadas diretamente para ambas as redes neurais A e B. Estas redes neurais, usando uma função de ativação f , são treinadas para que retornem diferentes tipos de classificação nas suas saídas y_1 e y_2 . Finalmente, o módulo agregador é responsável por combinar as classificações y_1 e y_2 e fornecer uma orientação de operação z , que deve ser uma das saídas possíveis do *ensemble* moderado.

As redes neurais A e B recebem as mesmas entradas e podem possuir arquiteturas similares ou diferentes (i.e., número de camadas ocultas e nodos em cada uma dessas camadas, algoritmo de treinamento, função de ativação, taxa de aprendizado e *momentum*), mas essas redes neurais devem obrigatoriamente ser diferentes quanto ao tipo de saída que produzem. Essas saídas devem ter significados similares, mas são obtidas de maneiras diferentes que variam de acordo com o tipo de treinamento que a rede neural recebeu. A Figura 4.3 ilustra a diferença

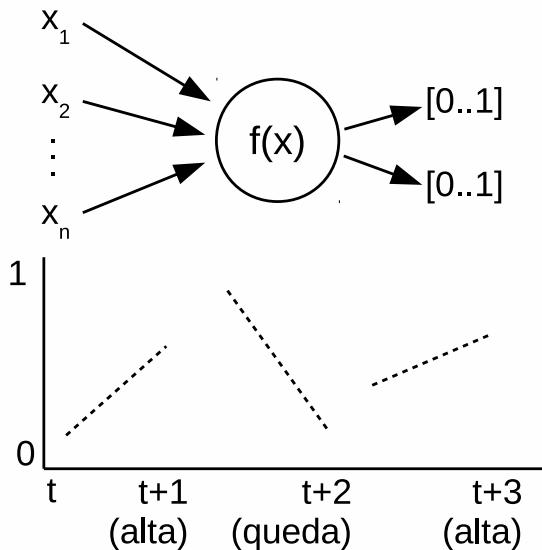
Figura 4.2: Arquitetura do *ensemble* moderado

Fonte: Autor

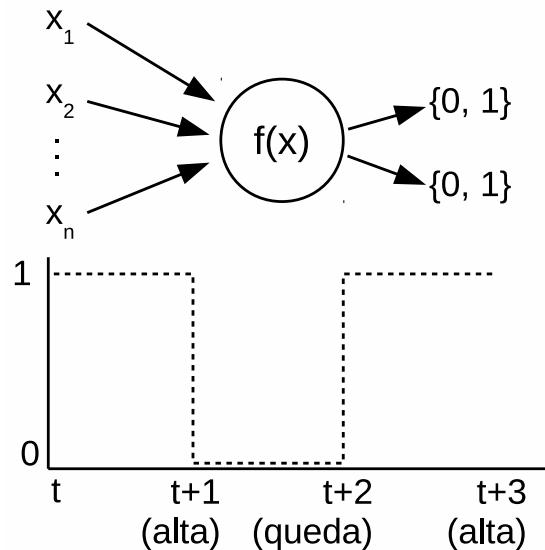
que é proposta para as redes neurais A e B. Embora as entradas que as redes neurais recebem possam ser as mesmas, o valor e a forma de interpretação das saídas diferem entre si.

Figura 4.3: Arquiteturas das redes neurais do *ensemble* moderado

(a) Rede Neural A: valores futuros



(b) Rede Neural B: tendência



Fonte: Autor

A rede neural A é treinada para prever os valores esperados de abertura e de fechamento para o próximo período de tempo. De posse desses valores, é possível prever se determinada ação vai subir ou cair durante o próximo período de tempo. Se o valor da previsão de abertura é inferior ao valor da previsão de fechamento, é feita uma interpretação de que a rede neural está prevendo uma alta nos preços para o próximo período de tempo. A comparação oposta gera uma interpretação de queda nos preços. A Figura 4.3a ilustra como este processo funciona.

A rede neural A possui 2 saídas (valores previstos de abertura e de fechamento) que retornam valores entre zero e um, uma vez que os dados de entrada e de saída do conjunto de treinamento são normalizados (o método de normalização é explicado mais adiante, na Seção 5.1.1). As previsões nos períodos de tempo $t+1$ e $t+3$ possuem valores de abertura menores do que os valores de fechamento, logo são interpretadas como previsões de alta. De forma oposta, a previsão no período de tempo, $t+2$ possui o valor de abertura maior do que o valor de fechamento, logo a previsão desse período é definida como de queda.

A rede neural B, adicionalmente, é treinada para prever exatamente o que queremos: se uma ação vai subir ou descer, não importa o quanto. Para atingir este objetivo, durante a fase de treinamento, diferentes conjuntos de entradas são fornecidos à rede neural de forma que a rede neural aprenda a retornar 1 no primeiro nodo de saída e 0 no segundo, quando uma alta nos preços é prevista para o próximo período de tempo, ou 0 no primeiro nodo de saída e 1 no segundo, caso contrário (quando uma queda é prevista). Obviamente, devido à natureza do algoritmo das redes neurais, os valores exatos 0 e 1 nunca são retornados na fase de testes, mas sim um número real entre 0 e 1 em cada um dos nodos. O que é feito neste caso é a adoção da abordagem *winner takes all*, onde o nodo com o maior valor é considerado o vencedor e é mapeado em 1, e o nodo com o menor valor, por sua vez, é mapeado para 0. A Figura 4.3b mostra como estas saídas são gerenciadas internamente pelo *ensemble* proposto. Assim como na rede neural A, a previsão nos períodos $t+1$ e $t+3$ foi mapeada em 1, indicando uma previsão de alta. A previsão no período de tempo $t+2$, por sua vez, foi mapeada em 0, indicando uma previsão de queda nos preços.

O módulo agregador funciona basicamente como um AND lógico, uma vez que ambas as redes neurais devem concordar em suas previsões para que o *ensemble* possa fornecer uma classificação apropriada. Quando as redes neurais A e B preveem uma alta (ou queda) nos preços, o *ensemble* faz a sua previsão de acordo as previsões dessas redes neurais. Por outro lado, se as redes neurais A e B discordam em suas previsões (i.e., uma prevê alta e a outra prevê queda nos preços), o *ensemble* retorna a saída *não sabe*, que significa que o mesmo não está fornecendo nenhuma previsão. Isto acontece porque, quando existe este tipo de discordância nas saídas, a interpretação é de que o próximo período de tempo é de incerteza no mercado, e qualquer tentativa de previsão nada mais é do que uma aposta. Neste tipo de cenário, um operador de ações não deveria realizar operação alguma no próximo período de tempo. O módulo agregador torna-se importante porque cada uma das recomendações fornecidas pelas redes neurais A e B possui determinados índices de erro, mas esses índices são diminuídos se forem consolidados em uma única previsão. Muitos dos erros de recomendação feitos por uma

rede neural sozinha são anulados quando a outra rede neural fornece um resultado diferente, fazendo com que o *ensemble* entre no estado *não sabe*.

Qualquer rede neural cujo conjunto de saídas possa ser mapeado em 0 ou 1 poderia substituir algum dos elementos do *ensemble* proposto sem causar maiores impactos na arquitetura proposta. Com relação ao número de redes neurais utilizadas para formar o *ensemble*, em um primeiro momento, o uso de duas redes pode parecer pouco para analisar uma série temporal financeira e suas complexidades, mas experimentos preliminares com até quatro redes neurais mostraram que aumentar o número de redes neurais não melhora os resultados. Além do índice de acertos médio não aumentar significantemente, um aumento no número de elementos do *ensemble* causa mais discordâncias no módulo agregador, uma vez que agora existem mais itens que precisam dar a mesma opinião. Muitas discordâncias não são desejáveis uma vez que fariam com que o *ensemble* fornecesse muitas saídas do tipo *não sabe* e poucas previsões de alta ou queda nos preços.

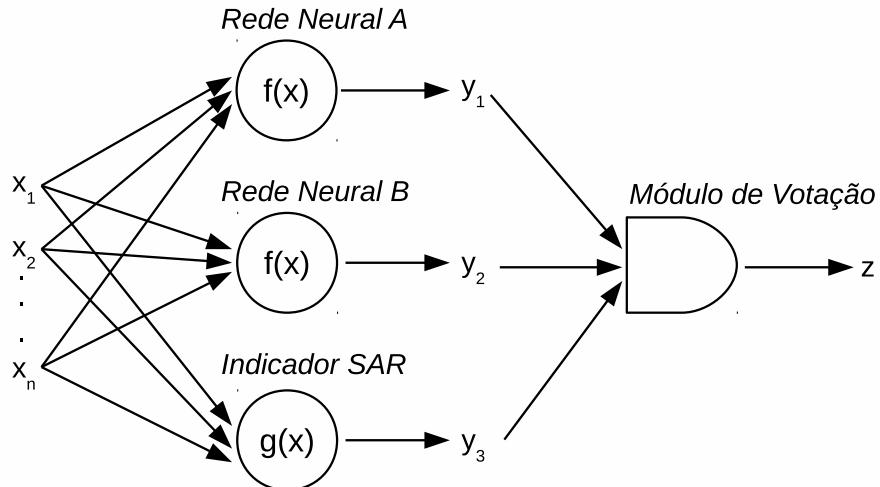
4.3 Ensemble Agressivo

O *ensemble* agressivo é uma extensão do *ensemble* moderado. Essa extensão visa atender a perfis mais agressivos de investimento, mantendo o mesmo objetivo de prever movimentos de séries temporais financeiras.

O *ensemble* agressivo é apresentado na Figura 4.4. Esse *ensemble* se assemelha muito ao *ensemble* moderado, porém é composto por três elementos: duas redes neurais e o indicador técnico SAR (apresentado na Seção 2.1.5). Este indicador foi escolhido porque, além de ser um indicador que também retorna como saída um valor indicando se a tendência é de alta ou de queda, também foi o que teve o melhor desempenho entre todos os indicadores avaliados. Todas as entradas x_1, x_2, \dots, x_n são fornecidas ao *ensemble*, que por sua vez irá distribuí-las para cada um de seus elementos. Cada uma das redes neurais do *ensemble* agressivo usa uma função de ativação f . O terceiro elemento, por representar um indicador técnico e não uma rede neural, está representado com uma função diferente, no caso, g . Essas diferentes funções processam as entradas em um valor de classificação mapeado para 0 ou 1 (indicando um sinal de venda ou compra, respectivamente). Outra mudança implementada no *ensemble* agressivo é que as saídas de seus elementos são passadas para um Módulo de Votação, que junta todos os resultados das classificações y_1, y_2, y_3 e retorna um valor z que é o valor que foi mais vezes retornado entre os elementos do *ensemble*. Sistemas de votação para a classificação de séries temporais já foram usados em outros trabalhos, como o de Lee et al. (2014). Nele, para analisar o histórico de

consultas em motores de buscas, foi utilizado um sistema de votação com pesos e SVMs para prever se um tópico vai virar tendência ou não. A entrada para método proposto é uma série temporal com o histórico de consultas ao tópico sendo analisado.

Figura 4.4: Arquitetura do *ensemble* agressivo



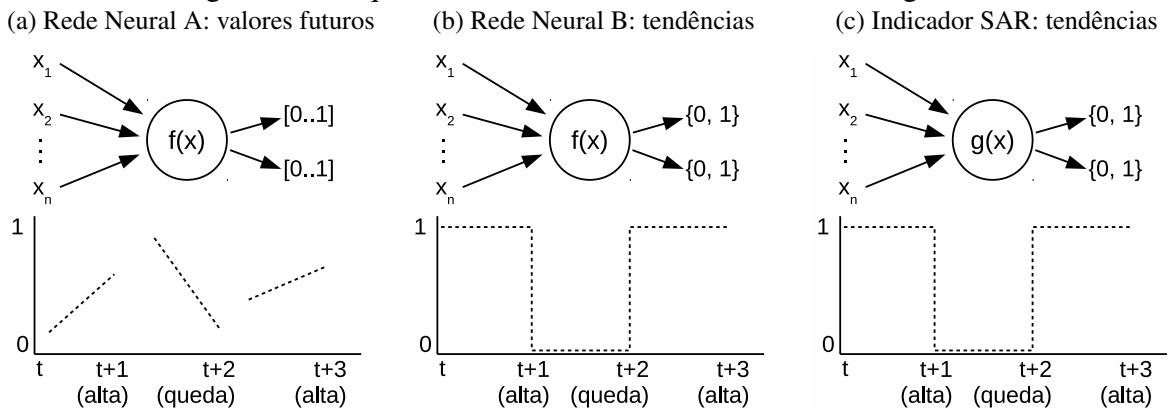
Fonte: Autor

Ao contrário do *ensemble* moderado, como o número de elementos do *ensemble* agressivo é ímpar, nunca haverá um empate no Módulo e Votação, fazendo com que o *ensemble* seja capaz de retornar previsões para qualquer combinação de entradas que vier a receber. Como todos os elementos do *ensemble* devem retornar um sinal de *compra* ou de *venda*, suas funções internas devem ser adaptadas para retornarem estes valores também. A Figura 4.5 mostra como as saídas dos elementos do *ensemble* são adaptadas para retornar os sinais desejados.

O primeiro elemento, chamado daqui em diante de rede neural A (Figura 4.5a) é a rede neural mais utilizada na literatura. A rede neural tenta prever os valores futuros exatos da série temporal analisada, transformando a previsão resultante uma classe (alta ou queda). Para fazer essa transformação, as previsões de abertura e fechamento são comparadas para inferir se a rede neural está prevendo uma alta ou queda nos preços para o próximo período. O segundo elemento (Figure 4.5b) possui uma rede neural (daqui em diante chamada de rede neural B) que é treinada para retornar 0 ou 1 se prever uma queda ou alta nos preços, respectivamente. Nessa rede neural, os valores de retorno são independentes do tamanho da variação nos preços, ou seja: a variação mais suave retorna o mesmo valor que uma mais intensa, desde que suas direções sejam as mesmas. Para ambas as redes neurais A e B, previsões de variação zero são mapeadas para previsões de alta. O terceiro elemento (Figura 4.5c) é o indicador técnico SAR, que possui como uma de suas saídas a direção do mercado. Esse indicador, como todos os outros

indicadores técnicos, não prevê valores futuros exatos: ao invés disso, mostra a tendência que os dados passados estão seguindo. Para adaptar este comportamento para um ambiente de previsão, é coletada a direção do SAR no último período de tempo e se assume que esta direção vai se manter no próximo período de tempo, transformando-a na própria previsão desse elemento. O indicador técnico SAR foi escolhido por que, além de ter obtido os melhores resultados em nossos experimentos empíricos, sua natureza permite que a sua saída seja facilmente mapeada para um conjunto binário de alta ou queda nos preços.

Figura 4.5: Arquiteturas das redes neurais do *ensemble* agressivo



Fonte: Autor

4.4 Implementação

Para a implementação das redes neurais propostas em ambos os *ensembles* propostos foi utilizado o *framework* Encog (HEATON; REASEARCH, 2010), que permitiu a implementação de redes neurais do tipo MLP com *feed foward*. O Encog é um *framework* disponibilizado em Java, .Net e C++ para a criação de redes neurais. Escolheu-se este *framework* porque é o que possui mais classes para a implementação de redes neurais, possibilitando ao programador que utilize funções e otimizações que outras ferramentas não oferecem (como por exemplo o *pruning* de uma rede neural, ou seja, a retirada de conexões com pesos muito baixos e que fazem pouca ou nenhuma diferença no resultado final, com o objetivo de melhorar o desempenho da mesma). Adicionalmente, o Encog possui classes para a criação de redes neurais voltadas especificamente para a previsão de séries temporais financeiras, o que vem ao encontro da pesquisa deste trabalho.

Para as redes neurais propostas, foi escolhido como algoritmo de treinamento a *resilient propagation* (RIEDMILLER; BRAUN, 1993). Este algoritmo já está implementado no *framework* escolhido e se diferencia do *backpropagation* no sentido de que não usa valores fixos para taxa de treinamento e *momentum*. Na verdade, na *resilient propagation* a atualização nos pesos e *bias* dos nodos da rede neural são determinados pelo sinal da derivativa da mudança de peso em cada passo da fase de treinamento, fazendo com que estes valores não precisem ser definidos inicialmente pelo usuário. Uma das grandes vantagens da *resilient propagation* é maior determinante para a escolha desse algoritmo é que, como a taxa de treinamento é variável, essa taxa se comporta de forma que seu valor seja alto no início do treinamento e baixo no final, fazendo com que a rede neural chegue mais rapidamente a um resultado com o índice de erro desejado.

Todas as redes neurais implementadas possuem a mesma arquitetura: três camadas (sendo uma oculta), *resilient propagation* como algoritmo de treinamento, e a função de ativação tangente sigmóide em todas as camadas. No *ensemble* agressivo, o cálculo do SAR e o Módulo de Votação foram implementados usando um banco de dados SQL Server.

4.4.1 Considerações

Como nosso objetivo é realizar uma classificação de séries temporais, tentamos usar também outros tipos de redes neurais nas primeiras implementações do método, porém os resultados apresentados foram inferiores aos resultados obtidos com redes neurais do tipo MLP. Um dos tipos de algoritmo de rede neural avaliado foi a otimização por enxame de partículas (PSO - *particle swarm optimization*) (EBERHART; KENNEDY, 1995). Este tipo de rede neural não usa o algoritmo de descida em gradiente como os MLPs, mas sim uma aproximação de valores em um espaço multidimensional. Foi desenvolvido especialmente para tarefas de classificação e já foi utilizado para prever o valor futuro de séries temporais financeiras em vários estudos (PULIDO; MELIN; CASTILLO, 2014; WANG; PHILIP; CHEUNG, 2014; WANG; YU; CHEUNG, 2012). Outro tipo de algoritmo avaliado foi a função de ativação Softmax (MCCULLAGH, 1984), que garante que a soma de todos os valores de saída dos nodos de uma camada seja igual a 1. Este comportamento pode ser usado para previsão de valores futuros, mas é mais útil para tarefas de classificação, onde é necessário escolher o nodo com o maior valor, e já foi utilizado em diversos trabalhos na literatura (XU; TANG; TIAN, 2014; PENG; JIANG, 2015; DONATE et al., 2013).

Em nossos experimentos, a capacidade de generalização das redes neurais não melhorou

quando foram adicionadas às suas entradas séries temporais exógenas, como valores de moedas estrangeiras (e.g., dólar americano e euro) e índices de mercados financeiros diferentes (e.g., DAX, NASDAQ, etc.). Este comportamento está de acordo com os conceitos da análise técnica, que defende que toda informação referente a determinada ação já está contida no seu preço. Adicionalmente, a adição de indicadores técnicos como entradas das redes neurais também não impactou no desempenho do *ensemble* em geral. Acreditamos que esse comportamento aconteceu devido à natureza inerente das redes neurais, que durante o período de treinamento aprendem a relação entre as suas entradas, o que de certa forma é o que um indicador técnico faz. Talvez adicionar um indicador técnico às entradas de uma rede neural crie uma redundância nos dados, tornando este tipo de informação desnecessária.

5 EXPERIMENTOS

O objetivo deste capítulo é avaliar o método proposto através da definição de uma metodologia de experimentos e posterior comparação com outros métodos de previsão de tendência de séries temporais financeiras. A Seção 5.1 mostra detalhes da montagem da base de dados utilizada e das métricas de avaliação dos resultados obtidos pelo método. A Seção 5.2 define a metodologia usada para os experimentos, e explica como as saídas dos *ensembles* propostos são transformadas em operações automatizadas para que possamos avaliar seu rendimento. A avaliação do método foi dividida em dois experimentos principais: a Seção 5.3 avalia o método proposto pela sua capacidade de acertar previsões, e a Seção 5.4 avalia o método proposto pela sua capacidade de gerar lucro para o operador que seguir suas recomendações.

Os resultados serão considerados satisfatórios se o operador que realiza suas operações de acordo com as saídas recomendadas pelo método obtiver lucro. Pode-se dizer que, quanto maior o ganho de capital, melhor o método. Adicionalmente, é desejável que o índice de acertos das previsões seja superior a 50% (pois caso contrário o método proposto não seria melhor do que um modelo aleatório, como o lançamento de uma moeda) e que o lucro obtido pelo operador seja maior do que a variação da série temporal durante o período de testes.

5.1 Preparação dos experimentos

Esta seção descreve o processo de preparação dos dados e métricas para avaliação do método proposto. A Seção 5.1.1 mostra todas as séries temporais escolhidas e o período de testes, além de mostrar tratamentos feitos no conjunto de dados. A Seção 5.1.2 introduz as métricas de avaliação escolhidas para serem comparadas com o método proposto.

5.1.1 Base de dados

Para os dados reais utilizados nos experimentos, foram escolhidas séries temporais de dois grupos distintos: os mercados de ações norte-americano e brasileiro, com granularidade de tempo de um dia e de 15 minutos, respectivamente. O histórico de valores diários das ações do mercado norte-americano foi obtido gratuitamente no site Yahoo! Finance¹. Como cotações com granularidade inferior a um dia não são disponibilizadas gratuitamente, o histórico de

¹<http://finance.yahoo.com>

valores de 15 minutos para ações brasileiras foi obtido através de um projeto de pesquisa em parceria com a Universidade Federal de Minas Gerais (UFMG).

Foram escolhidas as nove ações mais negociadas dos mercados norte-americano (S&P 500) e brasileiro (Bovespa). A lista completa das séries temporais utilizadas é apresentada na Tabela 5.1. Na montagem do conjunto de experimento, o mercado norte-americano foi escolhido devido ao fato de ser o maior mercado do mundo e, portanto, menos propenso a ser influenciado por fatores externos (por exemplo, desvalorizações em bolsas de valores de outros países). Adicionalmente, como esse mercado possui um volume maior de operações diárias do que os outros, não apresenta tantas variações em seus valores (uma vez que mais pessoas precisam estar envolvidas em um movimento de alta e queda para que esse movimento ganhe força), tornando previsões desses valores mais fáceis de serem realizadas por ferramentas automatizadas. O mercado de ações brasileiro também foi escolhido porque, além do fato de ser o nosso país de origem e onde nossa pesquisa foi feita, trata-se de um mercado emergente, que se comporta de maneira diferente dos mercados desenvolvidos. Mercados emergentes possuem maiores variações e mudam de direção mais vezes, às vezes sem razão aparente. Se nosso método obtiver bons resultados nestes dois tipos de mercados, tão diferentes entre si, uma alta confiabilidade poderá ser atribuída ao mesmo. Outra vantagem em se avaliar o método em mercados diferentes é que ações diferentes do mesmo país possuem uma tendência de compartilharem os mesmos movimentos, uma vez que as influências econômicas que essas ações sofrem são as mesmas. Ao se expandir os experimentos para dois mercados diferentes, é possível avaliar o método em séries temporais com tendências totalmente diferentes entre si.

Para as séries temporais de empresas norte-americanas, foi escolhida a granularidade diária por duas razões: primeiro porque é o tipo de granularidade mais usada pelos operadores e, segundo, devido ao fato dos preços diários destas ações estarem disponíveis gratuitamente. Para as séries temporais de empresas brasileiras, por outro lado, foi escolhida a granularidade de 15 minutos porque neste nível de granularidade a análise dos valores da série temporal é bem diferente da análise feita na granularidade diária, já que séries temporais com granularidades diferentes exibem movimentos diferentes (uma ação pode estar subindo durante o dia mas caindo durante os últimos 15 minutos, por exemplo) e de intensidades diferentes (pois a variação de preços é menor em períodos de granularidades menores). Esta diferença de comportamento das séries temporais em granularidades diferentes permite que o método seja avaliado em dois cenários bem distintos um do outro.

Foram coletados dados diários das séries temporais norte-americanas de 19/05/2008 a 14/01/2015, totalizando 1.677 períodos de um dia para cada série temporal. Para cada uma

Tabela 5.1: Séries temporais utilizadas na validação dos *ensembles* propostos

	Nome (Símbolo)	Segmento de atuação	Período
Ações norte-americanas	Standard & Poor's 500 (S&P 500)	Índice de ações	diário
	Alcoa Inc (AA)	Produção de alumínio	diário
	Bank of America Corp (BAC)	Financeiro	diário
	Citigroup Inc (C)	Financeiro	diário
	Ford Motor Co (F)	Automotivo	diário
	Freeport-McMoRan Inc (FCX)	Extração de ouro e cobre	diário
	General Electric Co (GE)	Conglomerado multinacional	diário
	JPMorgan Chase and Co (JPM)	Financeiro	diário
	Southwestern Energy Co (SWN)	Exploração de gás natural	diário
Ações brasileiras	Bovespa (BOVA11)	Índice de ações	15 min
	Banco do Brasil (BBAS3)	Financeiro	15 min
	Bradesco (BBDC4)	Financeiro	15 min
	BB Seguridade (BBSE3)	Seguros	15 min
	BRF Foods (BRFS3)	Alimentos	15 min
	BMF Bovespa (BVMF3)	Mercado de ações	15 min
	Itaú (ITSA4)	Financeiro	15 min
	Petrobras (PETR4)	Extração de petróleo	15 min
	Vale (VALE5)	Mineiração	15 min

das séries temporais brasileiras, foram coletados dados a cada 15 minutos de 01/07/2014 a 18/09/2014, totalizando uma média de 1.914 períodos de 15 minutos para cada série temporal. Os números de dados coletados em cada série temporal deste último caso são diferentes entre si devido ao fato de que, neste nível de granularidade, termos que considerar as negociações que ocorreram durante o *after-market*, que é o momento após o fechamento da bolsa em que alguns ativos continuam sendo negociados, porém com um volume de operações bem menor.

Todos os conjuntos de dados foram divididos em dois subconjuntos: um para treinamento e outro para teste das redes neurais, contendo, respectivamente, 90% e 10% dos dados disponíveis. O alto percentual de dados no conjunto de treinamento foi escolhido para evitar o risco de *overfitting* na rede neural, que é o fenômeno da rede neural “decorar” as respostas ao invés de aprender o relacionamento entre as variáveis de entrada. Outras distribuições de percentual entre os conjuntos de treino e teste mostraram resultados inferiores em nossos experimentos. A exemplo de vários outros trabalhos (O’CONNOR; MADDEN, 2006; JASEMI; KIMIAGARI; MEMARIANI, 2011), não utilizamos conjunto de validação em nossa abordagem. A razão é que, para utilizar este tipo de conjunto nos experimentos, ou se tira dados do conjunto de treinamento ou se utiliza dados mais antigos para manter o número de dados

no mesmo. Em nossos experimentos, ambos os casos pioraram os resultados das previsões: o primeiro porque, com menos dados para serem treinadas, as redes neurais não conseguiram generalizar com a mesma eficácia (o que também justifica porque escolheu-se usar um conjunto de treinamento com 90% dos dados). A segunda também piorou porque, na nossa avaliação, os mercados de ações estão constantemente se desenvolvendo e evoluindo, logo os padrões de comportamento e variação que um mercado tinha 10 anos atrás não vão necessariamente se repetir atualmente. Finalmente, optamos por não fazer validação cruzada dos dados para manter o caráter sequencial da série temporal.

Para cada período de dados (que pode ser de 1 dia ou de 15 minutos, dependendo da granularidade escolhida), foram coletadas todas as informações presentes no *candlestick* (apresentados na Seção 2.1.3) da ação sendo analisada durante o período: valores de abertura, máximo, mínimo e de fechamento. Todas essas entradas usaram uma janela de tempo de cinco períodos cada uma (em outras palavras, foram utilizados dados dos últimos cinco *candlesticks*), totalizando 20 entradas para cada rede neural. Tamanhos de janela de tempo diferentes poderiam ter sido utilizadas em redes neurais diferentes do mesmo *ensemble*, mas nossos experimentos mostraram melhores resultados quando todas as redes neurais do *ensemble* utilizaram este tamanho de janela de tempo. O treinamento das redes neurais é supervisionado: para cada conjunto de cinco períodos fornecidos à rede neural, a saída resultante é comparada com o valor do período seguinte (que seria o sexto período, no caso).

Antes de fornecer os dados de entrada às redes neurais, o conjunto de dados foi normalizado usando a Interpolação Linear Clássica, definida na Equação (5.1), onde N é o valor final normalizado, O é o valor original a ser normalizado, e Min e Max são, respectivamente, os valores máximo e mínimo do conjunto de dados a ser normalizado.

$$N = \frac{O - Min}{Max - Min} \quad (5.1)$$

Como o interesse deste trabalho é prever movimentos direcionais no mercado financeiro, é mostrado na Tabela 5.2 a distribuição de movimentos em todas as séries temporais avaliadas. Nessa tabela, é possível visualizar que os dados estão平衡ados entre altas e quedas nos conjuntos de treino, teste e total. A maior disparidade de dados acontece no conjunto de treino para a série temporal da ação ITSA4, que possui 60% de altas e 40% de quedas. De fato, embora o equilíbrio entre altas e quedas nas séries temporais do mercado norte-americano seja bem grande (indicando um período sem tendência definida), no mercado brasileiro existe uma média de aproximadamente 15% mais altas do que quedas em suas séries temporais (indicando um período de leve alta durante a coleta dos dados). Este percentual, contudo, não é considerado

Tabela 5.2: Quantidades de altas e quedas nos valores diários em cada uma das séries temporais de ações avaliadas

	Símbolo	Altas/Quedas Conjunto de Treino	Altas/Quedas Conjunto de Teste	Altas/Quedas Conjunto Total	Proporção Total em %
Ações norte-americanas	S&P 500	832/679	81/85	925/752	55/45
	AA	766/745	92/74	858/819	51/49
	BAC	758/753	94/72	852/825	50/50
	C	758/753	85/81	843/834	50/50
	F	789/722	89/77	878/799	52/48
	FCX	762/749	81/85	843/834	50/50
	GE	785/726	83/83	868/809	51/49
	JPM	754/757	96/70	850/827	50/50
	SWN	751/760	72/94	823/854	49/51
Ações brasileiras	BOVA11	900/729	91/87	991/816	55/45
	BBAS3	949/785	96/96	1045/881	54/46
	BBDC4	970/767	95/97	1065/864	55/45
	BBSE3	916/820	103/89	1019/909	53/47
	BRFS3	936/796	99/93	1035/889	54/46
	BVMF3	1027/709	111/81	1138/790	59/41
	ITSA4	1048/688	110/82	1158/770	60/40
	PETR4	940/796	101/91	1041/887	54/46
	VALE5	949/788	90/102	1039/890	54/46

alto o suficiente para causar *overfitting* nas redes neurais e não torna o modelo inválido. Na verdade, mesmo se os dados fossem desbalanceados a base de dados poderia ser utilizada nos experimentos, porém seria necessário alterar a interpretação da comparação dos resultados do método proposto com as métricas de avaliação.

5.1.2 Métricas de avaliação

Duas métricas de avaliação foram escolhidas para avaliar quantitativamente o método proposto: a relação entre o número de erros que são obtidos através das recomendações retornadas, e o ganho de capital que seria teria sido obtido se um operador tivesse estritamente seguido todas essas recomendações. Esta última métrica adicionalmente é comparada ao ganho de capital de cinco outras estratégias, listadas abaixo:

- **Buy And Hold:** conforme descrito na Seção 2.1.4, consiste em comprar a ação no início do intervalo de teste e vendê-la apenas ao final deste período. Nessa estratégia, o capital investido cresce (ou diminui) na mesma proporção da variação da ação comprada durante o período. A vantagem desta estratégia sobre as outras é que, como apenas duas operações são feitas durante todo o período de testes, o valor gasto com corretagem praticamente não influencia no resultado final. Esta é a única estratégia que não é um previsor;
- **Estratégia Trivial:** esta é a estratégia de previsão mais simples possível. Assume que se uma ação subiu (ou caiu) durante o período t , a ação também irá subir (ou cair) no período $t+1$. Este tipo de estratégia funciona bem em períodos com tendências longas e bem definidas, porém falha quando a tendência de uma ação muda constantemente ou não está bem definida;
- **Rede neural para Previsão da Tendência:** esta métrica usa as previsões da rede neural A, definida nas seções 4.2 e 4.3, que é treinada para prever a tendência da série temporal, ou seja, apenas se a série temporal vai subir ou descer no próximo período de tempo;
- **Rede neural para Previsão dos Próximos Valores:** esta métrica usa as previsões da rede neural B, também definida nas seções 4.2 e 4.3, que é treinada para prever o valor exato da série temporal no próximo período de tempo. A partir da previsão desse valor, é possível inferir se haverá uma alta ou queda nos preços e ajustar a operação a ser executada de acordo com este resultado.
- **Indicador SAR:** funciona como uma Estratégia Trivial “melhorada”. Essa estratégia repete para o período $t+1$ o resultado que o indicador SAR (definido na Seção 2.1.5) apresentou no período t . Como indicadores não fazem previsões futuras, este é o único meio de usar os resultados de indicadores financeiros como comparativos no quesito previsibilidade.

Alguns destes classificadores são os componentes que formam os *ensembles*. O uso destes classificadores na comparação torna possível comparar o desempenho dos *ensembles* com os desempenhos de suas partes formadoras isoladamente, o que permitirá avaliar se a união de diferentes classificadores realmente dá origem a um classificador mais eficiente.

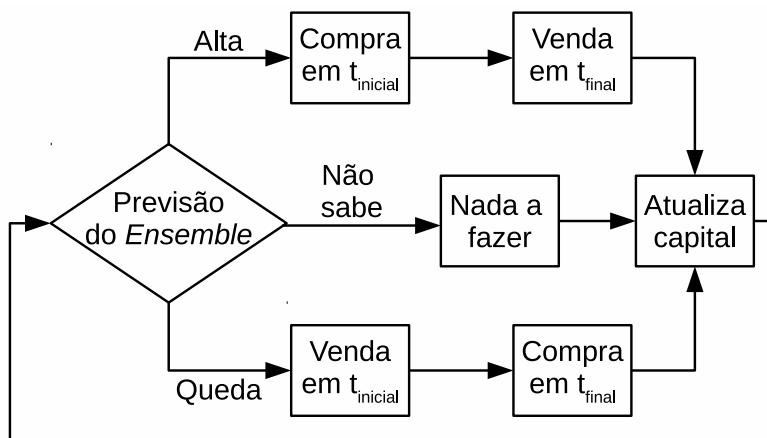
Para a avaliação do método proposto, o ideal seria comparar seu desempenho com outros métodos disponíveis na literatura, mas isso não foi possível. Mesmo em trabalhos similares da área, que transformam a saída de seus métodos em operações reais (como os vistos no Capítulo 2), a comparação com o nosso método deveria usar as mesmas séries temporais que estes estudos usaram, que estão geralmente em períodos de tempo anteriores ao deste estudo ou com

dados muito específicos para serem utilizados pelo nosso método.

5.2 Metodologia de Experimentos

Para avaliar a capacidade dos *ensembles* moderado e agressivo para gerar lucro, foi adotada a metodologia ilustrada na Figura 5.1. Os passos dessa metodologia são descritos a seguir:

Figura 5.1: Metodologia de Experimentos



Fonte: Autor

- Se o *ensemble* prevê uma alta nos preços para o próximo período de tempo (que pode ser o próximo dia ou próximo período de 15 minutos, dependendo do conjunto sendo avaliado), uma operação de compra é efetuada no primeiro instante deste período, bem como uma operação de venda exatamente no último instante deste mesmo período. Se o valor da ação realmente subir durante o período em questão, o lucro da operação ao fim do período é adicionado ao capital final. Caso contrário, se a previsão estiver errada e o valor da ação cair, o prejuízo da operação é descontado do capital final;
- Inversamente, se o *ensemble* prevê uma queda no próximo período de tempo, uma venda a descoberto (definida na Seção 2.1.4) é realizada: uma operação de venda é efetuada no primeiro instante deste período, bem como uma operação de compra exatamente no último instante deste mesmo período. Se o valor da ação realmente cair durante o período em questão, o lucro da operação ao fim do período é adicionado ao capital final. Caso contrário, se a previsão estiver errada e o valor da ação subir, o prejuízo da operação é descontado do capital final;

- Se o *ensemble* moderado não for capaz de prever o que vai acontecer, nenhuma operação é executada e espera-se pelo próximo período de tempo. Essa opção nunca acontece para o *ensemble* agressivo, uma vez que nele uma operação de compra e venda é feita a cada período de tempo, sem a opção de não operar.

Ao contrário de outros métodos presentes na literatura, nunca mantemos a ação comprada de um dia para o outro, mesmo que as previsões do *ensemble* sejam de duas altas (ou quedas) consecutivas. Embora pareça ser a escolha óbvia, essa abordagem foi evitada por duas razões:

- Os mercados de ações podem ser muito voláteis às vezes. Se existirem notícias negativas, por exemplo, durante o período em que o mercado estiver fechado, uma ação poderia iniciar o dia com um valor de abertura muito menor do que o valor de fechamento do dia anterior. Ao executar operações apenas durante os períodos em que o mercado está aberto, estes momentos arriscados onde o operador não tem controle sobre o que pode ser feito são evitados;
- De um ponto de vista prático, não é possível fazer isso na vida real. Para implementar a abordagem de manter a ação comprada ou vendida de um dia para outro, no exato último momento do período, o operador teria que rodar o *ensemble* inteiro para ter posse de toda a informação relativa ao período anterior, necessária para fornecer de entrada ao *ensemble* para que o mesmo calcule a previsão para o próximo período. Isto acontece devido ao preço de fechamento, que só está disponível no último momento do período. O processo de captar dados, executar o *ensemble* e avaliar a saída gerada teria que ser feito em pouquíssimos milissegundos, o que é impossível de se alcançar em computadores comuns.

Estratégias de gerência de capital defendem que apenas uma parte do capital total deve ser investido para diminuir o risco do investimento. Contudo, como o objetivo deste trabalho é avaliar o método proposto e não propor uma estratégia de gerência de capital, por simplicidade foi assumido que 100% do capital disponível é investido em todas as operações recomendadas pelos *ensembles*. Isso significa que, em nosso cenário de avaliação, o operador hipotético seguindo as orientações do *ensemble* sempre consegue comprar todas as ações que solicitou e sempre consegue vender todas as ações que possui. Também se assume que os preços de compra e venda (não necessariamente nesta ordem) foram exatamente os preços de abertura e fechamento.

Finalmente, em um cenário real existem custos de corretagem envolvidos nas opera-

ções. As corretoras cobram uma taxa para cada operação de compra ou venda de ações que é descontada diretamente do saldo em conta do cliente. Algumas corretoras cobram o valor de corretagem em função do percentual investido, mas a grande maioria oferece a possibilidade de cobrança de um valor fixo. Para este trabalho, vamos considerar que as operações de compra e venda foram feitas considerando uma taxa de corretagem igual a \$10,00 (dez unidades monetárias). Este é um custo cobrado por várias corretoras atualmente, tanto americanas, que cobram 10 dólares por operação², quanto brasileiras, que cobram 10 reais por operação³.

5.2.1 Organização das Redes Neurais

Para os experimentos, cada uma das redes neurais dos *ensembles* foi implementada com três camadas: uma camada de entrada com 20 nodos, uma camada oculta com seis nodos, e uma camada de saída com dois nodos. São 20 nodos de entrada porque fornecemos cinco dias de dados para quatro informações (abertura, fechamento, máximo e mínimo). A camada oculta possui 6 nodos porque foi a quantidade de nodos ocultos que forneceu os melhores resultados. A razão do número de nodos de saída ser o mesmo em todas as redes neurais é que, embora as redes neurais que formam os *ensembles* retornem valores que significam coisas diferentes (como especificado nas seções 4.2 e 4.3), todas as redes neurais precisam ter este número de saídas para serem interpretadas corretamente pelo *ensemble*. Todas as redes neurais foram treinadas para um máximo de 50.000 iterações a não ser que o erro mínimo fosse alcançado ou a rede neural parasse de convergir durante o treinamento. Devido ao comportamento diferente que cada ação tem, para cada ação analisada foi feito um novo treinamento da rede neural, totalizando 18 treinamentos. Cada treinamento durou em média uma hora e meia, mas as redes neurais são treinadas apenas uma vez para cada série temporal.

5.3 Avaliação das Classificações dos *Ensembles*

Nesta seção são avaliadas as classificações feitas pelos dois *ensembles* propostos. Após uma análise individual de cada *ensemble*, é feita uma análise coletiva dos mesmos.

²<http://www.tradestation.com/products/stocks-and-etfs/pricing#lb2>

³<https://www.mycap.com.br/Produtos.aspx>

5.3.1 Avaliação das Classificações do *Ensemble* Moderado

Aqui é avaliada a distribuição das previsões feitas pelo *ensemble* moderado. O interesse está em medir a quantidade de dias em que o *ensemble* fornece uma previsão válida (i.e., uma saída diferente de *não sabe*) e a distribuição entre previsões de alta e de queda. De posse dessa informação, é possível ter um melhor entendimento do padrão de previsões feito pelo *ensemble* e de quais correções poderiam ser feitas no mesmo.

Após a execução do *ensemble* em cada uma das séries temporais, os resultados exibidos na Tabela 5.3 foram alcançados. Primeiramente, a tabela mostra o número de elementos do período de testes para cada série temporal, onde os elementos são as instâncias do conjunto de dados de teste e as séries temporais são os grupos de instâncias desses conjuntos de dados. Embora todas as séries temporais tivessem seus conjuntos de entrada balanceados, os números de recomendações dada para cada uma dessas séries não foram semelhantes entre si. As séries temporais AA e GE, por exemplo, tiveram recomendações de compra ou de venda em mais do que 75% dos dias. BVMF3 e ITSA4, por outro lado, tiveram recomendações de operações em menos de 12% dos períodos, o que significa que na maioria das vezes as redes neurais internas do *ensemble* não concordaram em suas classificações. Esta diferença de comportamento em séries temporais diferentes indica que para o *ensemble* moderado é mais fácil fazer previsões para algumas séries temporais do que para outras. Isto não é visto como um problema, uma vez que para séries temporais com poucas previsões é preferível que o *ensemble* não forneça nenhuma previsão do que uma previsão errada. Adicionalmente, um comportamento surpreendente que é mostrado nesta tabela é que, mesmo com a paridade entre altas e quedas mostrada na Tabela 5.2, não existe um padrão definido no balanço das previsões feitas pelo *ensemble* moderado. As séries temporais BAC, C, F e BBDC4 possuem muito mais previsões de altas do que previsões de quedas, ao passo que as séries temporais AA, GE, BBAS3 e BVMF3 possuem mais previsões de quedas do que previsões de altas. Como séries temporais diferentes possuem padrões de comportamento diferentes, o *ensemble* moderado possui mais facilidade ao fazer tipos específicos de previsão dependendo da série temporal. Também é possível ver nessa tabela que a proporção de previsões corretas de altas e de quedas sempre segue a proporção das previsões totais de alta e de queda, indicando que embora exista um desbalanço entre o número de previsões de alta e queda, este desbalanço não existe ao analisar o índice de acerto para cada direção. Finalmente, o *ensemble* moderado fez mais previsões para as séries temporais do mercado norte-americano, o que aponta para uma maior previsibilidade deste mercado, provavelmente por ser mais estável do que o brasileiro, conforme discutido na Seção 5.1.1.

Tabela 5.3: Sumário das classificações feitas pelo *ensemble* moderado

	Símbolo	# Elementos do Período de Testes	# Total Previsões	% Elementos com Previsão	# Elementos com Previsão de Alta	# Elementos com Previsão de Queda	# Previsões de Alta Corretas	# Previsões de Queda Corretas
Ações norte-americanas	S&P 500	166	39	23%	34	5	19	3
	AA	166	128	77%	13	115	7	58
	BAC	166	26	15%	25	1	17	1
	C	166	101	60%	101	0	57	0
	F	166	32	19%	31	1	17	1
	FCX	166	89	53%	33	56	17	33
	GE	166	127	76%	10	117	6	68
	JPM	166	106	63%	93	13	61	4
	SWN	166	78	46%	24	54	14	33
Ações Brasileiras	BOVA11	192	100	52%	75	25	43	17
	BBAS3	192	58	30%	0	58	0	34
	BBDC4	192	72	37%	68	4	39	3
	BBSE3	192	81	42%	51	30	34	15
	BRFS3	192	37	19%	9	28	4	17
	BVMF3	192	21	11%	0	21	0	13
	ITSA4	192	10	05%	7	3	6	0
	PETR4	192	74	38%	27	47	13	30
	VALE5	192	97	50%	70	27	38	22

5.3.2 Avaliação das Classificações do *Ensemble* Agressivo

Esta seção avalia o desempenho das classificações realizadas pelo *ensemble* agressivo. Devido à característica que o *ensemble* agressivo tem de operar todos os dias, contudo, algumas informações da Tabela 5.3 não fazem sentido aqui: o número total de previsões e o percentual de períodos com previsão, por exemplo, seriam sempre os mesmos para todas as séries temporais avaliadas uma vez que este *ensemble* fornece previsões todos os dias.

Optou-se por mostrar apenas o índice de acertos em suas previsões (tanto de alta quanto de queda) e a comparação destes índices com os atingidos pelas abordagens comparativas apre-

sentadas na Seção 5.1.2. O *ensemble* moderado também foi inserido nas abordagens comparativas, possibilitando a comparação dos dois *ensembles* propostos ao mesmo tempo.

O índice de acertos da classificação feita por cada abordagem comparativa está mostrado na Tabela 5.4, onde é possível ver o percentual de previsões corretas obtidas no conjunto de testes para cada um dos *ensembles* avaliados e para cada uma das abordagens comparativas. A estratégia *Buy and Hold* não possui um índice de acertos porque não faz previsões efetivamente, uma vez que opera apenas no início e no final do período de testes. Os melhores resultados para cada série temporal estão destacados em negrito. É possível ver que o *ensemble* agressivo obteve os melhores resultados classificatórios em 14 de 18 ações, e dos quatro restantes, o *ensemble* foi o segundo melhor em três ações. Dessas quatro ações restantes, em três o *ensemble* moderado obteve o melhor desempenho, mostrando que os melhores desempenhos em classificações são obtidos em sua grande maioria pelos *ensembles* em geral. Adicionalmente, na única série temporal em que o melhor resultado não foi atingido por um *ensemble* (FCX), a diferença percentual dos acertos obtidos é de apenas dois pontos para o *ensemble* moderado e de três pontos para o *ensemble* agressivo. Finalmente, nesta tabela também é possível visualizar que as métricas de avaliação (apresentadas na Seção 5.1.2) quando, utilizadas isoladamente, possuem os piores desempenhos. Porém, quando são unidas em grupos mesmo que pequenos (como no *ensemble* moderado) seu desempenho geralmente melhora, como aconteceu em todas as séries temporais analisadas com exceção da série temporal que representa a ação FCX.

5.3.3 Avaliação Geral das Classificações

Dividir a análise dos resultados obtidos entre os dois conjuntos de testes utilizados (mercados norte-americano e brasileiro) melhora o entendimento de como o método proposto se comporta em cenários diferentes. Entre as ações de empresas norte-americanas, o melhor resultado do *ensemble* moderado foi obtido pela série temporal referente à ação S&P 500, com 64% de acerto nas classificações. Já o melhor resultado do *ensemble* agressivo foi obtido pela série temporal BAC, com 73% de acerto. Para ambos os *ensembles*, os únicos casos em que não consideramos o índice de acertos satisfatório foram nas classificações feitas pelo *ensemble* moderado na série temporal AA, onde o índice de acertos foi levemente superior a 50%. Embora este índice não seja desejável para um classificador, ainda assim o ganho de capital para essa série temporal utilizando as previsões do *ensemble* moderado foi o segundo maior de todos, como pode ser visto mais adiante na Tabela 5.5.

Tabela 5.4: Sumário das classificações corretas feitas pelos *ensembles* moderado e agressivo, e comparação com outras abordagens

	Símbolo	# <i>Buy and Hold</i>	# Estratégia Trivial	RN Tendência	RN Próximos valores	SAR	<i>Ensemble</i> moderado	<i>Ensemble</i> agressivo
Ações norte-americanas	S&P 500	-	54%	57%	50%	47%	64%	57%
	AA	-	52%	49%	51%	47%	50%	54%
	BAC	-	53%	52%	51%	49%	69%	73%
	C	-	54%	55%	52%	49%	56%	59%
	F	-	51%	51%	49%	56%	56%	71%
	FCX	-	44%	58%	49%	56%	56%	55%
	GE	-	45%	56%	56%	52%	58%	65%
	JPM	-	60%	55%	59%	54%	61%	62%
	SWN	-	44%	55%	54%	51%	60%	62%
Ações brasileiras	BOVA11	-	53%	54%	52%	49%	60%	65%
	BBAS3	-	51%	47%	49%	46%	59%	57%
	BBDC4	-	51%	52%	51%	52%	58%	60%
	BBSE3	-	53%	53%	49%	48%	60%	60%
	BRFS3	-	48%	47%	50%	44%	57%	63%
	BVMF3	-	50%	44%	43%	36%	62%	71%
	ITSA4	-	53%	40%	42%	41%	60%	57%
	PETR4	-	54%	46%	54%	49%	58%	72%
	VALE5	-	43%	51%	54%	49%	57%	60%

Quanto às series temporais do mercado brasileiro, as classificações feitas pelos *ensembles* em geral foram melhores que no mercado norte-americano. Aqui, o desempenho de ambos os *ensembles* foi sempre igual ou superior a 57%. Estes números indicam que, além do método proposto conseguir ser eficaz em cenários diferentes, o método tem uma confiabilidade maior neste tipo de cenário. O melhor resultado do *ensemble* moderado foi na série temporal BVMF3, com 62% de acertos. Para o *ensemble* agressivo, o melhor desempenho foi obtido na série temporal PETR4, com 72% de acertos. Por se distanciarem da barreira dos 50%, estes resultados são excelentes, pois mostram que é possível prever a direção dos mercados com certo grau de certeza. De posse destes índices de acertos para cada série temporal, um operador pode montar uma estratégia que dê preferência às operações com índices de acertos maiores, de acordo com o risco que esteja disposto a assumir.

5.4 Análise do Desempenho dos *Ensembles*

O objetivo desta seção é medir o desempenho financeiro dos *ensembles* moderado e agressivo em operações de compra e venda as mais próximas possíveis da realidade. Se os *ensembles* forem capazes de gerar lucro a partir das classificações, significa que o método proposto pode ser utilizado por operadores de mercado em suas operações diárias. Para analisar a capacidade dos *ensembles* de gerar lucro, foi simulado um capital inicial de \$100.000,00 (cem mil unidades monetárias, que poderiam ser reais, dólares ou qualquer outra moeda, visto que estamos avaliando apenas o rendimento do capital investido) para cada ação e comparou-se esta quantia com o capital que um operador hipotético teria obtido se tivesse seguido rigorosamente todas as recomendações dos *ensembles*. A cada operação, é descontado o valor de \$10 (referente à corretagem) na compra e na venda de cada ação. Finalmente, os resultados atingidos foram comparados com os resultados que teriam sido obtidos se o mesmo operador tivesse seguido as estratégias definidas pelas abordagens comparativas, como foi feito na Seção 5.3.3

A Tabela 5.5 mostra os resultados financeiros obtidos pelos *ensembles* moderado e agressivo para os dois conjuntos de testes especificados, bem como os resultados obtidos pelas abordagens comparativas. Os melhores índices atingidos em cada série temporal estão destacados em negrito para que se tenha uma visualização melhor de quais métodos possuem os maiores índices de sucesso. Por possuírem variações de valores diferentes entre cada período, estes dois conjuntos são analisados separadamente. Gráficos com a evolução do capital obtida tanto pelo *ensemble* moderado quanto pelo *ensemble* agressivo a cada ordem realizada, bem como a comparação com a evolução de capital da estratégia *Buy and Hold* para cada uma das séries temporais testadas são mostrados do Apêndice A deste trabalho.

5.4.1 Ações norte-americanas

Entre as ações de empresas norte-americanas, o melhor resultado do *ensemble* moderado foi obtido na série temporal referente à ação SWN, com um lucro de 55% e um índice de acertos de 60%. A série temporal referente à ação S&P 500, onde o *ensemble* moderado obteve o maior índice de acertos em suas classificações, também foi a série temporal onde o *ensemble* moderado teve o melhor desempenho entre todas as estratégias de comparação. O lucro obtido foi baixo na comparação com outros (apenas de 6%) devido ao fato de que, conforme foi visto na Tabela 5.3, um número bem pequeno de previsões foi feito para esta série temporal. Para a série temporal

Tabela 5.5: Lucros finais obtidos por todas as abordagens comparativas considerando um capital inicial de \$100,000.00 para cada ação e considerando corretagem de \$10. Valores em negrito indicam os melhores desempenhos para cada série temporal

	Símbolo	# <i>Buy and Hold</i>	# Estratégia Trivial	RN Tendência	RN Próximos valores	SAR	<i>Ensemble</i> moderado	<i>Ensemble</i> agressivo
Ações norte-americanas	S&P 500	101k	100k	101k	105k	95k	106k	102k
	AA	118k	90k	119k	135k	93k	128k	106k
	BAC	120k	116k	108k	116k	96k	115k	118k
	C	116k	102k	116k	97k	98k	107k	95k
	F	99k	113k	89k	129k	119k	111k	135k
	FCX	68k	95k	140k	76k	135k	105k	147k
	GE	96k	101k	108k	111k	110k	110k	113k
	JPM	116k	86k	102k	119k	98k	112k	100k
	SWN	57k	155k	154k	151k	104k	155k	164k
	Total	891k	958k	1037k	1039k	945k	1049k	1080k
Ações brasileiras	BOVA11	97k	100k	102k	98k	100k	102k	103k
	BBAS3	91k	95k	99k	102k	101k	103k	103k
	BBDC4	99k	96k	96k	104k	97k	102k	100k
	BBSE3	97k	108k	109k	100k	97k	107k	107k
	BRFS3	101k	103k	93k	105k	97k	102k	99k
	BVMF3	98k	104k	94k	100k	92k	100k	92k
	ITSA4	97k	101k	97k	98k	95k	101k	97k
	PETR4	99k	97k	96k	104k	102k	102k	101k
	VALE5	93k	95k	100k	107k	101k	105k	106k
	Total	872k	899k	886k	918k	882k	924k	908k
	Total Geral	1763k	1857k	1923k	1957k	1827k	1973k	1988k

AA, embora o índice de acertos do *ensemble* moderado tenha sido levemente superior a 50%, o ganho de capital para essa série temporal foi o segundo maior entre as outras estratégias de comparação. Cabe ressaltar também que, de acordo com o comportamento esperado de uma estratégia moderada de investimento, onde o risco deve ser menor, o *ensemble* moderado foi a única abordagem que não obteve prejuízo em nenhuma série temporal.

O *ensemble* agressivo teve um desempenho superior ao *ensemble* moderado nas séries temporais do mercado de ações norte-americano. Seu melhor resultado foi na série temporal referente à ação SWN, onde obteve um lucro de 64%, um valor bem acima da média das outras abordagens para esta mesma série temporal. Além disso, das nove séries temporais avaliadas, o *ensemble* agressivo teve o melhor desempenho mais vezes, vencendo as outras abordagens em quatro das nove séries temporais. O *ensemble* agressivo teve prejuízo apenas na série temporal C, indicando uma alta confiabilidade das suas previsões neste mercado, apesar de seu perfil agressivo. Ao final dos testes, o objetivo de uma estratégia agressiva, que é obter lucros altos ao custo de eventuais prejuízos, foi alcançado: na soma de todos os lucros, como pode ser visto na coluna Total da Tabela 5.3, o *ensemble* agressivo foi o que mais lucrou entre todas as abordagens.

5.4.2 Ações brasileiras

Quanto às séries temporais do mercado brasileiro, no *ensemble* moderado o melhor desempenho foi obtido pela série temporal BBSE3, com 7% de lucro. Esse *ensemble* teve o melhor desempenho entre todas as abordagens comparativas em duas das nove séries temporais avaliadas (BBAS3 e ITSA4). Assim como aconteceu no mercado norte-americano, o *ensemble* moderado cumpriu seu objetivo e foi a única abordagem que obteve lucro em todas as séries temporais. Conforme pode ser visto na soma de todos os rendimentos, este comportamento fez com que esse *ensemble* também tivesse a maior lucratividade total para o mercado brasileiro.

O *ensemble* agressivo também obteve os melhores resultados em 2 de 9 séries temporais para o mercado brasileiro: BOVA11 e BBAS3, com 3% de lucro. Seu maior rendimento foi com a série BBSE3, onde obteve 7% de rendimento. Por ter lucrado em 6 de 9 séries temporais, consideramos que o *ensemble* agressivo também cumpriu seu objetivo no mercado brasileiro, pois sua lucratividade total (somando todas as séries temporais) foi positiva.

O preditor que teve por mais vezes o melhor índice de lucro para este mercado foi a rede neural que prevê valores futuros, porém como essa rede neural obteve prejuízo em duas séries temporais, na soma total dos rendimentos ainda assim ficou atrás do *ensemble* moderado. Se ao

invés de analisarmos apenas quem teve o melhor desempenho considerarmos os três melhores desempenhos em cada uma das séries temporais de empresas brasileiras, o *ensemble* moderado sempre está entre os três melhores desempenhos, enquanto o *ensemble* agressivo esteve entre os três melhores em 5 de 9 séries temporais. Como o *ensemble* agressivo obteve a terceira melhor lucratividade total no mercado brasileiro, consideramos que esse *ensemble* possa ser considerado uma abordagem eficaz para este mercado também.

Nas séries temporais brasileiras, é possível perceber que em todos os métodos de avaliação os lucros para essas ações foram menores que os obtidos pelas ações norte-americanas apesar do índice de acerto superior em alguns casos. A principal razão deste comportamento é que a granularidade de 15 minutos, utilizada nestas séries temporais, não possui uma variação de preços tão grande quanto a granularidade diária. Logo, os lucros obtidos por operações neste nível de granularidade tendem a ser bem menores. Adicionalmente, conforme foi visto na Tabela 5.3, o *ensemble* moderado fez menos previsões para as ações brasileiras, o que implicou em menos operações que possibilitariam um aumento de capital. Por último, vale observar que o lucro obtido pelas ações norte-americanas foi obtido em 166 dias de experimento, enquanto o lucro obtido pelas ações brasileiras usou 192 períodos de 15 minutos, o que é equivalente a apenas sete dias de experimento. Se um operador usasse a granularidade de 15 minutos durante 166 dias, muito provavelmente os ganhos seriam maiores.

5.4.3 Estratégias comparativas

Das estratégias comparativas, a *Buy and Hold*, a Trivial e a rede neural de tendência obtiveram o melhor resultado em apenas duas ações, mostrando que não são estratégias confiáveis de compra e venda de ações. O melhor desempenho entre as estratégias comparativas foi o da rede neural que calcula os próximos valores, com o melhor desempenho em 6 das 18 séries temporais. Contudo, esta estratégia também obteve grandes prejuízos em algumas séries temporais, como C e FCX. Esses prejuízos colocaram esse tipo de rede neural atrás dos dois *ensembles* propostos no lucro total obtido. Finalmente, o SAR não obteve o melhor desempenho em nenhuma série temporal, além de ter tido prejuízo em 10 das 18 séries temporais analisadas, indicando que apesar de ser um bom componente para o *ensemble* agressivo, o SAR não deve ser usado isoladamente na hora de operar.

5.4.4 Avaliação Geral

Para fazer uma comparação do desempenho total dos *ensemble* moderado e agressivo com outras abordagens, na última linha da Tabela 5.5 foi adicionada a soma dos lucros de todas as séries temporais. Nela, é possível ver que os maiores lucros gerais foram obtidos pelos *ensembles* propostos. O *ensemble* agressivo obteve os maiores rendimentos e o *ensemble* moderado ficou em segundo lugar, ficando de acordo com os resultados esperados para o tipo de perfil de investimento de cada *ensemble*.

Se a estratégia *Buy and Hold* tivesse sido utilizada em todas as séries temporais, teríamos lucrado em cinco dessas séries no mercado norte-americano e em apenas uma série no mercado brasileiro, dando a essa estratégia um índice de sucesso de 55% e 11%, respectivamente. Isso indica que enquanto o mercado norte-americano estava em uma fase de estabilidade nos preços durante o período de teste, o mercado brasileiro estava passando por um período de queda. A estratégia trivial teve um desempenho melhor, pois conseguiu lucrar 66% e 55% nas séries temporais dos mercados norte-americano e brasileiro, respectivamente. A rede neural de tendência obteve sucesso de 88% e 33% para estes mesmos mercados e a rede neural de próximos valores obteve de lucro em 77% nos dois mercados. O indicador técnico SAR obteve lucro em 44% das ações norte-americanas e brasileiras. O *ensemble* moderado obteve lucro em todas as séries temporais tanto no mercado norte-americano quanto no brasileiro, com uma taxa de sucesso final de 100%. Finalmente, o *ensemble* agressivo obteve lucro em 88% das ações do mercado norte-americano e em 66% do mercado brasileiro.

O *ensemble* moderado se mostrou, a partir da análise desses resultados, que não é um método que obtém sempre os melhores resultados, mas que fornece um certo grau de segurança em entregar resultados bons e consistentes. Investidores em geral preferem técnicas que lhes proporcionem rendimentos pequenos e constantes em detrimento de estratégias arriscadas que podem gerar grandes ganhos de capital mas que também geram perdas de capital com uma certa frequência.

Os resultados obtidos nos experimentos também mostram que o *ensemble* agressivo fez as melhores classificações para a maioria das séries temporais e teve o melhor desempenho geral quando estas classificações foram transformadas em operações reais. Baseado nestes resultados, pode-se considerar que o *ensemble* agressivo poderia ser usado em uma estratégia agressiva de investimentos, uma vez que esse *ensemble* fornece recomendações todos os dias e obteve boas lucratividades na maioria dos casos. Para investidores mais conservadores, talvez o *ensemble* moderado seja realmente o mais recomendado.

6 CONCLUSÃO

Este trabalho apresentou dois *ensembles* de redes neurais com o objetivo de prever a direção futura de séries temporais de duas formas diferentes: uma moderada, e a outra agressiva. A maioria dos estudos da área tenta prever os valores exatos no futuro destas séries temporais, mas existem problemas que podem ser resolvidos apenas com a previsão da direção destas mesmas séries temporais. Um exemplo de problema deste tipo é a previsão de valores futuros de ações em bolsas de valores, já que apenas a previsão da direção destas séries é suficiente para a montagem de uma estratégia de operação. Para resolver este tipo de problema, o clássico problema de previsão de valores foi transformado em um problema de classificação. O método proposto e seus *ensembles* resultantes foram avaliados em dois mercados de ações completamente diferentes: o norte-americano com granularidade diária e o brasileiro com granularidade de 15 minutos. Foram medidos, em ambos os cenários, os índices de acertos dos movimentos desses mercados e a quantidade de capital que o método proposto poderia ter lucrado quando comparado às estratégias *Buy and Hold* e *Trivial*. Os resultados finais mostraram índices bastante satisfatórios em todas as bases de dados avaliadas, mostrando que o método proposto é robusto e suficiente e que pode ser utilizado em diferentes cenários, uma vez que foi o que obteve os melhores retornos financeiros na maioria das vezes quando comparados às outras abordagens comparativas.

Os *ensembles* propostos neste trabalho são formados ou por duas redes neurais, o que formava um *ensemble* indicado para um perfil moderado de investimento, ou por duas redes neurais adicionadas de um indicador técnico, formando um *ensemble* mais adequado a investidores com perfil mais agressivo. Isto porque o primeiro foi concebido de forma a apenas fornecer previsões futuras quando um certo nível de certeza é atingido, se abstendo de opinar quando não tem certeza o suficiente do próximo movimento da série temporal, enquanto o segundo fornece previsões para todos os períodos futuros, sem exceção.

Recomendamos usar o método proposto em estratégias de negociação moderadas ou agressivas através do desenvolvimento de uma ferramenta algorítmica de operações na bolsa. O método proposto preenche uma necessidade nesta área da economia, pois permite a implantação de um método de compra e venda que poderia ser adotada por qualquer investidor com acesso aos *ensembles* propostos.

Nosso método poderia também ser usado na criação de novas estratégias para a automatização de operações em mercados de ações, ou para realizar gerenciamento de portfólio de ações, alterando automaticamente as ações negociadas de acordo com as tendências previstas

pelo modelo. Como o nosso método se mostrou eficaz em diferentes mercados e granularidades, a estratégia criada pode ter uma abrangência muito grande, envolvendo tanto ações quanto mercados diferentes, e diferentes granularidades de acordo com a fase pela qual o mercado sendo analisado está passando.

A maior contribuição deste trabalho para o campo da IA é o desenvolvimento de um classificador que é capaz de atingir um alto percentual de acertos nos mais diversos cenários. Já no campo das contribuições literárias, tivemos dois artigos publicados em conferências internacionais (GIACOMEL; PEREIRA; GALANTE, 2015b; GIACOMEL; PEREIRA; GALANTE, 2015a), ambos especificando apenas o *ensemble* moderado. Planejamos para os próximos meses submeter o método proposto contendo também o *ensemble* agressivo em algum periódico ou revista da área de inteligência artificial.

Com relação a trabalhos futuros, nossa intenção é avaliar o método proposto em operações reais, através da escolha automática de algumas ações e posterior negociação das mesmas através de alguma ferramenta de operações, como por exemplo o MetaTrader¹. Outra possibilidade de extensão para este trabalho é a adoção de outras técnicas de aprendizagem de máquina (como SVMs ou redes neurais com funções de ativação de base radial), adicionando novos elementos ou substituindo os elementos existentes nos *ensembles* propostos.

¹<http://www.metatrader5.com/>

REFERÊNCIAS

- ADLER, J. Raging bulls: How wall street got addicted to light-speed trading. **Wired Magazine**, 2012.
- ARNOLD, D. J.; QUELCH, J. A. New strategies in emerging markets. **MIT Sloan Management Review**, Massachusetts Institute of Technology, v. 40, n. 1, p. 7, 1998.
- ATSALAKIS, G. S.; VALAVANIS, K. P. Surveying stock market forecasting techniques—part ii: Soft computing methods. **Expert Systems with Applications**, Elsevier, v. 36, n. 3, p. 5932–5941, 2009.
- BERNAL, A.; FOK, S.; PIDAPARTHI, R. Financial market time series prediction with recurrent neural networks. [S.l.:s.n], 2012.
- BOEHMER, E.; FONG, K. Y.; WU, J. J. International evidence on algorithmic trading. In: **AFA – Meetings Paper**. [S.l.: s.n.], 2014.
- BOLLEN, J.; MAO, H.; ZENG, X. Twitter mood predicts the stock market. **Journal of Computational Science**, Elsevier, v. 2, n. 1, p. 1–8, 2011.
- BRYSON, A. E.; DENHAM, W. F.; DREYFUS, S. E. Optimal programming problems with inequality constraints. **AIAA journal**, v. 1, n. 11, p. 2544–2550, 1963.
- CAO, Q.; LEGGIO, K. B.; SCHNIEDERJANS, M. J. A comparison between fama and french's model and artificial neural networks in predicting the chinese stock market. **Computers & Operations Research**, Elsevier, v. 32, n. 10, p. 2499–2512, 2005.
- CHEN, Y.; YANG, B.; ABRAHAM, A. Flexible neural trees ensemble for stock index modeling. **Neurocomputing**, Elsevier, v. 70, n. 4, p. 697–703, 2007.
- DONATE, J. P. et al. Time series forecasting using a weighted cross-validation evolutionary artificial neural network ensemble. **Neurocomputing**, Elsevier, v. 109, p. 27–32, 2013.
- EBERHART, R. C.; KENNEDY, J. A new optimizer using particle swarm theory. In: **International symposium on micro machine and human science**, 6. New York, NY: [s.n.], 1995. v. 1, p. 39–43.
- ELDER, A. **Trading for a living: psychology, trading tactics, money management**. [S.l.]: John Wiley & Sons, 1993.
- ELDER, A. **Come into my trading room: A complete guide to trading**. [S.l.]: John Wiley & Sons, 2002.
- FARIA, E. D. et al. Predicting the brazilian stock market through neural networks and adaptive exponential smoothing methods. **Expert Systems with Applications**, Elsevier, v. 36, n. 10, p. 12506–12509, 2009.
- GIACOMEL, F.; PEREIRA, A.; GALANTE, R. An algorithmic trading agent based on a neural network ensemble: a case of study in north american and brazilian stock markets. In: **IEEE. IEEE/WIC/ACM International Conference on Web Intelligence and Intelligent Agent Technology**. [S.l.], 2015.

- GIACOMEL, F.; PEREIRA, A.; GALANTE, R. Improving financial time series prediction through output classification by a neural network ensemble. In: SPRINGER. **Database and Expert Systems Applications**. [S.I.], 2015.
- HANSEN, L. K.; LIISBERG, C.; SALAMON, P. Ensemble methods for handwritten digit recognition. In: IEEE. **Neural Networks for Signal Processing**, 2. [S.I.], 1992. p. 333–342.
- HEATON, J.; REASEARCH, H. Encog java and dotnet neural network framework. **Heaton Research, Inc.**, v. 20, p. 2010, 2010.
- HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. **International journal of forecasting**, Elsevier, v. 22, n. 4, p. 679–688, 2006.
- JASEMI, M.; KIMIAGARI, A. M.; MEMARIANI, A. A modern neural network model to do stock market timing on the basis of the ancient investment technique of japanese candlestick. **Expert Systems with Applications**, Elsevier, v. 38, n. 4, p. 3884–3890, 2011.
- KARA, Y.; BOYACIOGLU, M. A.; BAYKAN, Ö. K. Predicting direction of stock price index movement using artificial neural networks and support vector machines: The sample of the istanbul stock exchange. **Expert systems with Applications**, Elsevier, v. 38, n. 5, p. 5311–5319, 2011.
- KIM, K.-j. Financial time series forecasting using support vector machines. **Neurocomputing**, Elsevier, v. 55, n. 1, p. 307–319, 2003.
- KOURENTZES, N.; BARROW, D. K.; CRONE, S. F. Neural network ensemble operators for time series forecasting. **Expert Systems with Applications**, Elsevier, v. 41, n. 9, p. 4235–4244, 2014.
- MARTINEZ, L. C. et al. From an artificial neural network to a stock market day-trading system: A case study on the bm&f bovespa. In: IEEE. **International Joint Conference on Neural Networks**. [S.I.], 2009. p. 2006–2013.
- MCCULLAGH, P. Generalized linear models. **European Journal of Operational Research**, Elsevier, v. 16, n. 3, p. 285–292, 1984.
- MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The bulletin of mathematical biophysics**, Springer, v. 5, n. 4, p. 115–133, 1943.
- NETO, A. et al. Improving financial time series prediction using exogenous series and neural networks committees. In: IEEE. **International Joint Conference on Neural Networks**. [S.I.], 2010. p. 1–8.
- O'CONNOR, N.; MADDEN, M. G. A neural network approach to predicting stock exchange movements using external factors. **Knowledge-Based Systems**, Elsevier, v. 19, n. 5, p. 371–378, 2006.
- OLIVEIRA, F. A. de et al. The use of artificial neural networks in the analysis and prediction of stock prices. In: IEEE. **IEEE International Conference on Systems, Man, and Cybernetics**. [S.I.], 2011. p. 2151–2155.
- PENG, Y.; JIANG, H. Leverage financial news to predict stock price movements using word embeddings and deep neural networks. **arXiv preprint arXiv:1506.07220**, 2015.

- PULIDO, M.; MELIN, P.; CASTILLO, O. Particle swarm optimization of ensemble neural networks with fuzzy aggregation for time series prediction of the mexican stock exchange. **Information Sciences**, Elsevier, v. 280, p. 188–204, 2014.
- RIEDMILLER, M.; BRAUN, H. A direct adaptive method for faster backpropagation learning: The rprop algorithm. In: IEEE. **IEEE International Conference on Neural Networks**. [S.I.], 1993. p. 586–591.
- ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological review**, American Psychological Association, v. 65, n. 6, p. 386, 1958.
- SAAD, E. W.; PROKHOROV, D. V.; WUNSCH, D. C. Comparative study of stock trend prediction using time delay, recurrent and probabilistic neural networks. **Neural Networks, IEEE Transactions on**, IEEE, v. 9, n. 6, p. 1456–1470, 1998.
- SCHWAGER, J. D. **A complete guide to the futures markets: fundamental analysis, technical analysis, trading, spreads, and options**. [S.I.]: John Wiley & Sons, 1984.
- SILVA, E. et al. A neural network based approach to support the market making strategies in high-frequency trading. In: IEEE. **International Joint Conference on Neural Networks**. [S.I.], 2014. p. 845–852.
- TAYLOR, B.; KIM, M.; CHOI, A. Automated stock trading algorithm using neural networks. In: SPRINGER. **International Conference on Intelligent Technologies and Engineering Systems**, 2. [S.I.], 2014. p. 849–857.
- TICKNOR, J. L. A bayesian regularized artificial neural network for stock market forecasting. **Expert Systems with Applications**, Elsevier, v. 40, n. 14, p. 5501–5506, 2013.
- WANG, F.; PHILIP, L.; CHEUNG, D. W. Combining technical trading rules using particle swarm optimization. **Expert Systems with Applications**, Elsevier, v. 41, n. 6, p. 3016–3026, 2014.
- WANG, F.; YU, P. L.; CHEUNG, D. W. Complex stock trading strategy based on particle swarm optimization. In: IEEE. **IEEE Conference on Computational Intelligence for Financial Engineering & Economics**. [S.I.], 2012. p. 1–6.
- WEST, D.; DELLANA, S.; QIAN, J. Neural network ensemble strategies for financial decision applications. **Computers & operations research**, Elsevier, v. 32, n. 10, p. 2543–2559, 2005.
- WILDER, J. W. **New concepts in technical trading systems**. [S.I.]: Trend Research Greensboro, NC, 1978.
- WU, Z.-H. Z. J.-X.; CHEN, Y. J. S.-F. Genetic algorithm based selective neural network ensemble. In: CITESEER. **International Joint Conference on Artificial Intelligence**, 17. Seattle, WA, 2001. v. 2, p. 797–802.
- XU, Z. Y.; TANG, L. N.; TIAN, C. P. Prediction of stock trend based on deep belief networks. In: TRANS TECH PUBL. **Applied Mechanics and Materials**. [S.I.], 2014. v. 644, p. 5538–5541.

ZHAI, Y.; HSU, A.; HALGAMUGE, S. K. Combining news and technical indicators in daily stock price trends prediction. In: **Advances in Neural Networks – ISNN**. [S.l.]: Springer, 2007. p. 1087–1096.

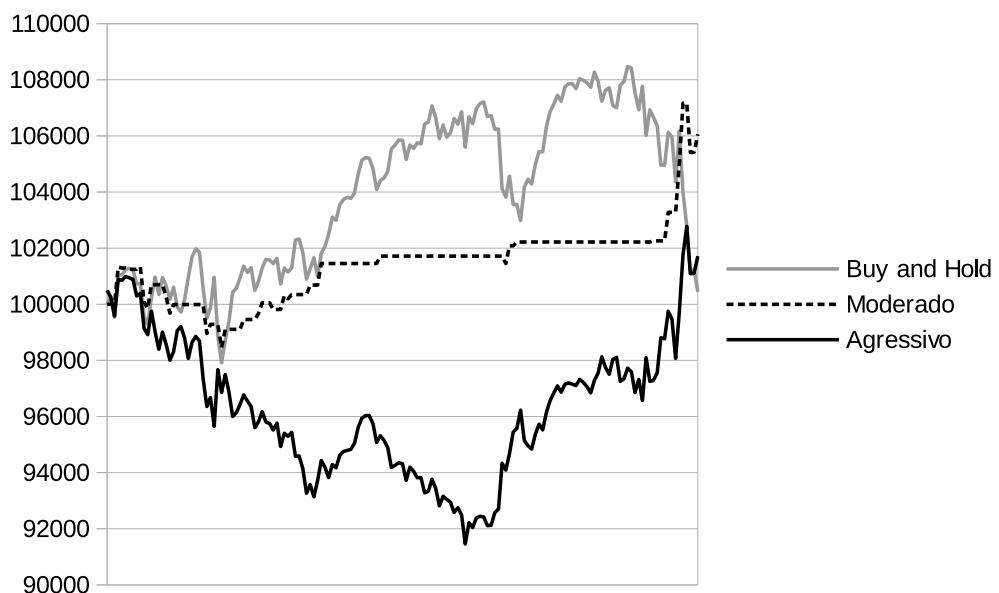
ZHOU, Z.-H.; WU, J.; TANG, W. Ensembling neural networks: many could be better than all. **Artificial intelligence**, Elsevier, v. 137, n. 1, p. 239–263, 2002.

APÊNDICE A — GRÁFICOS DOS RENDIMENTOS

Aqui são apresentados o histórico de rendimento dos métodos propostos (comparados com o *Buy and Hold*, que é o rendimento da própria ação) durante o período de experimentos.

A.1 Standard & Poor's 500 (S&P 500)

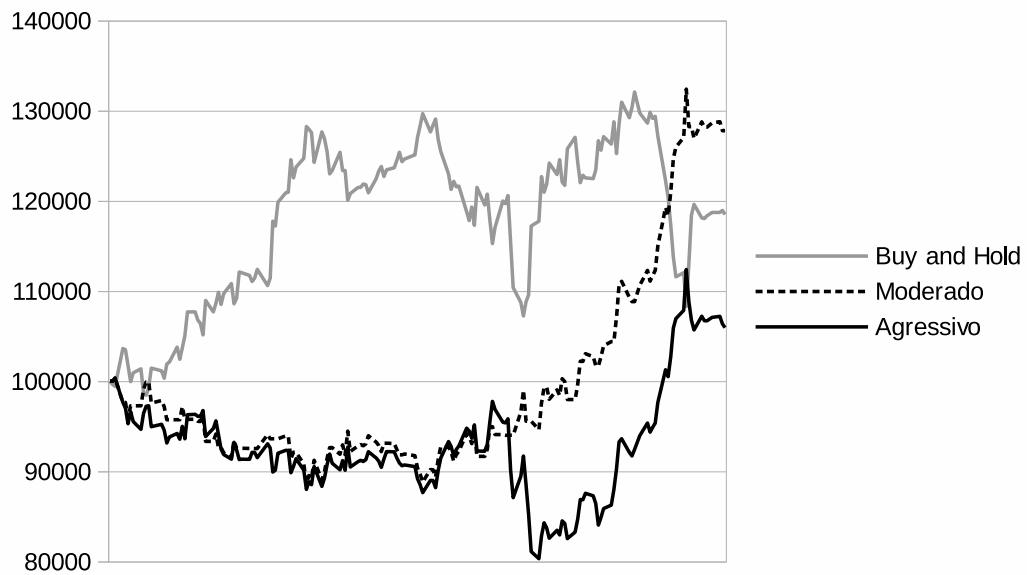
Figura A.1: Desenvolvimento do capital para S&P 500



Fonte: Autor

A.2 Alcoa Inc (AA)

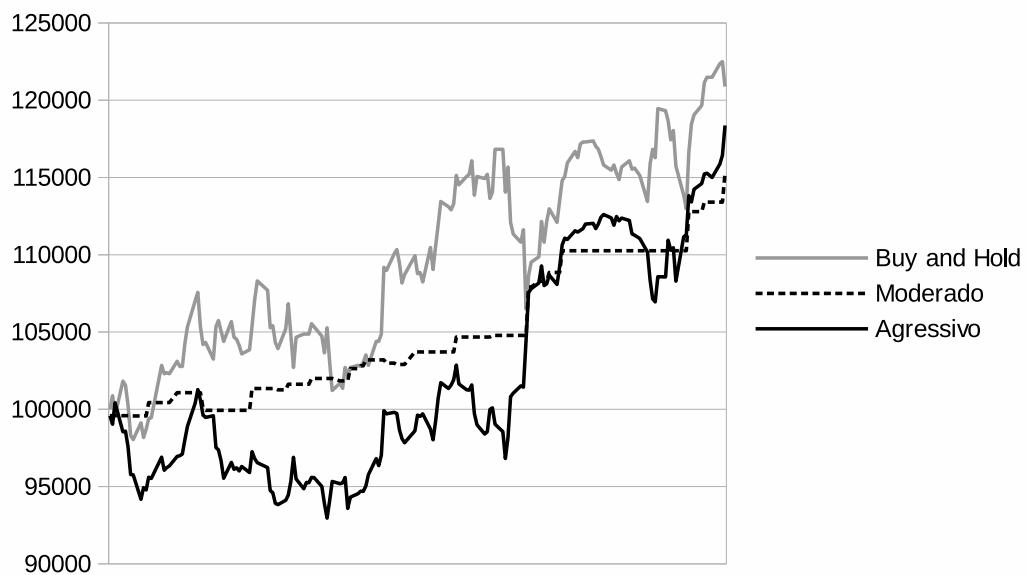
Figura A.2: Desenvolvimento do capital para AA



Fonte: Autor

A.3 Bank of America Corp (BAC)

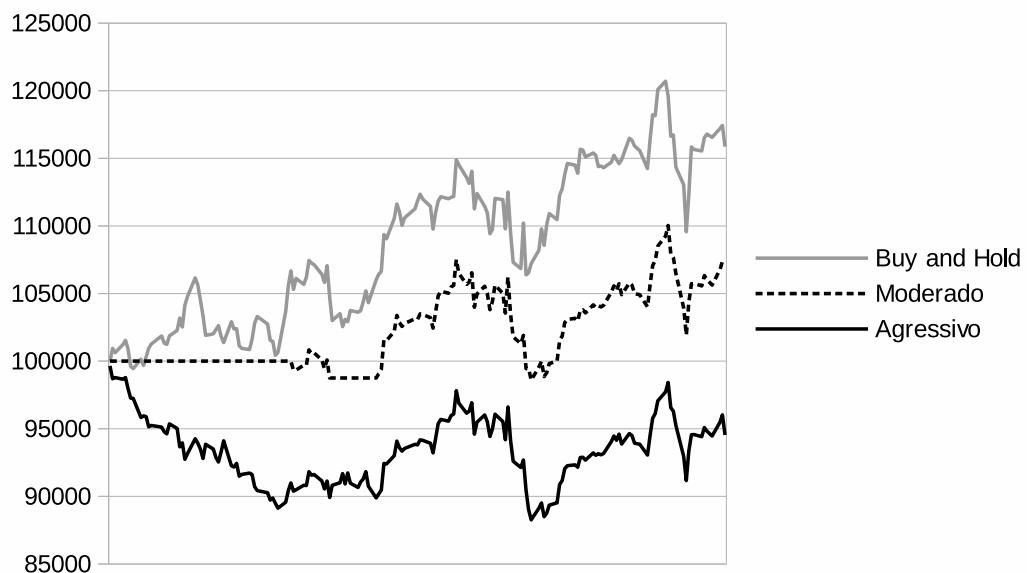
Figura A.3: Desenvolvimento do capital para BAC



Fonte: Autor

A.4 Citigroup Inc (C)

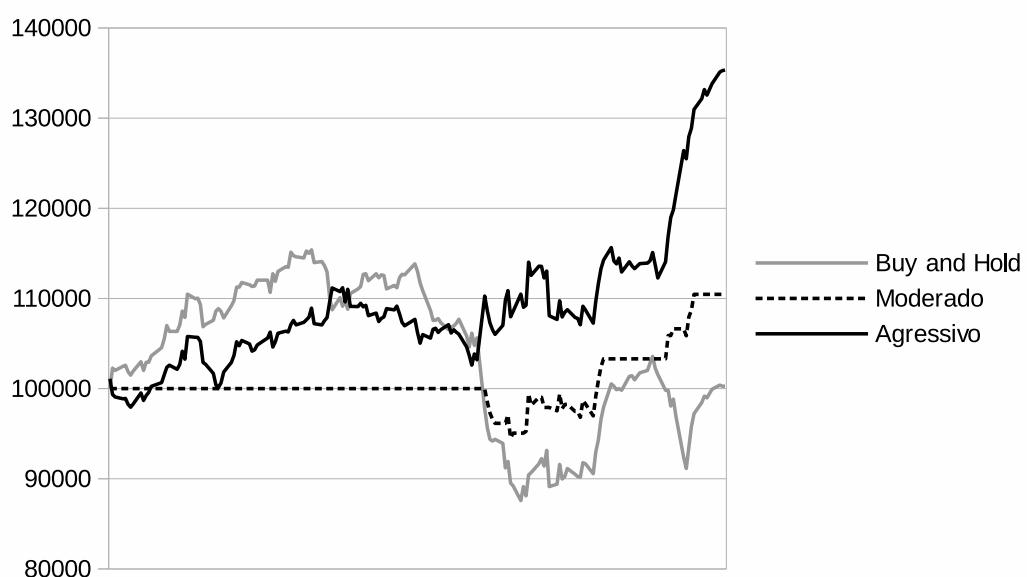
Figura A.4: Desenvolvimento do capital para C



Fonte: Autor

A.5 Ford Motor Co (F)

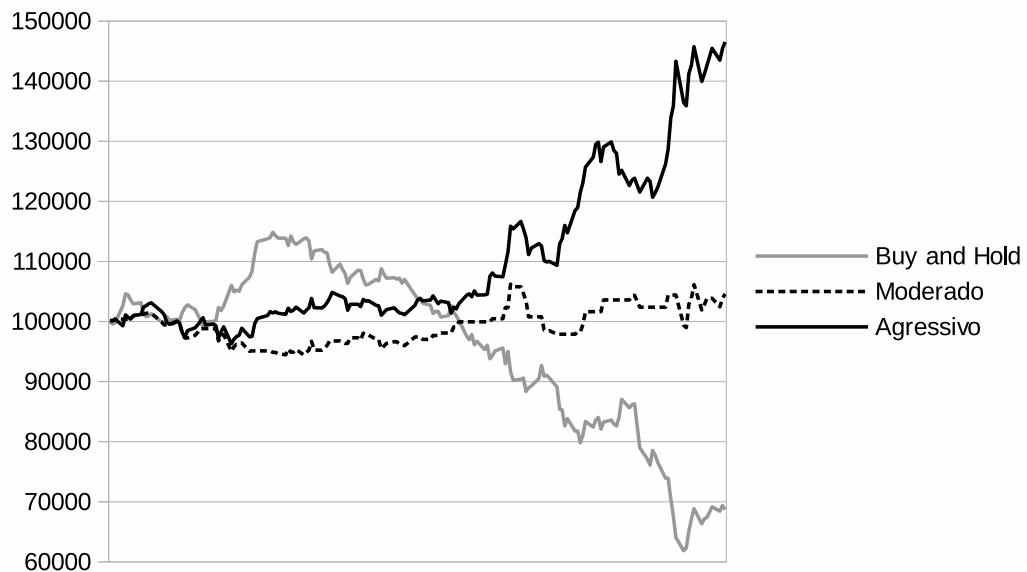
Figura A.5: Desenvolvimento do capital para F



Fonte: Autor

A.6 Freeport-McMoRan Inc (FCX)

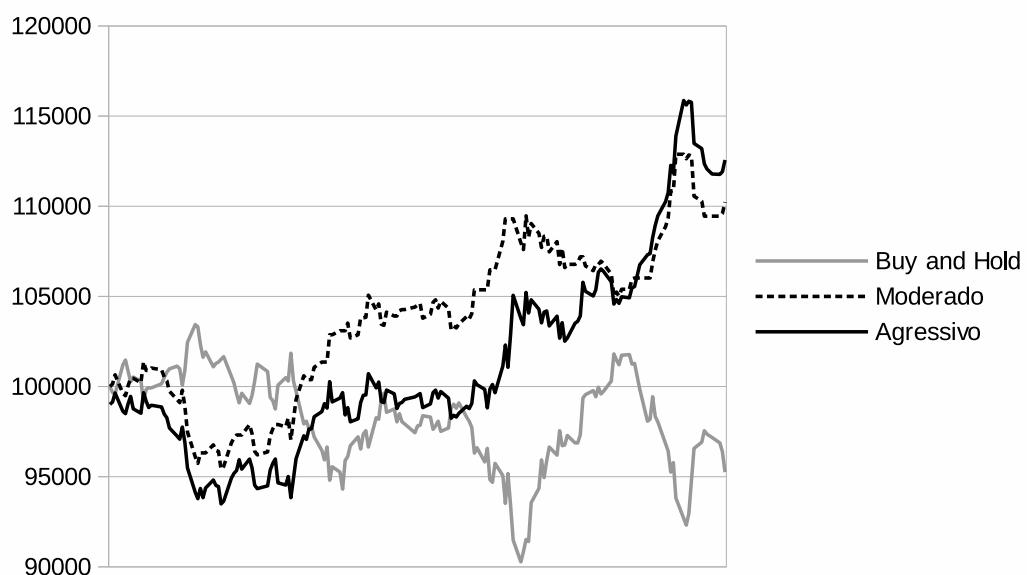
Figura A.6: Desenvolvimento do capital para FCX



Fonte: Autor

A.7 General Electric Co (GE)

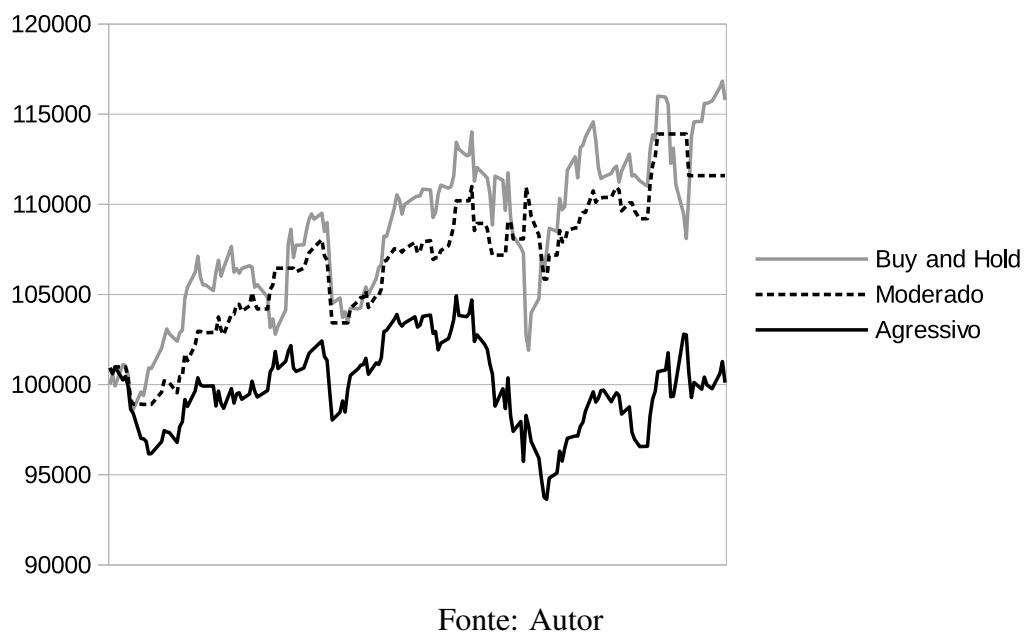
Figura A.7: Desenvolvimento do capital para GE



Fonte: Autor

A.8 JPMorgan Chase and Co (JPM)

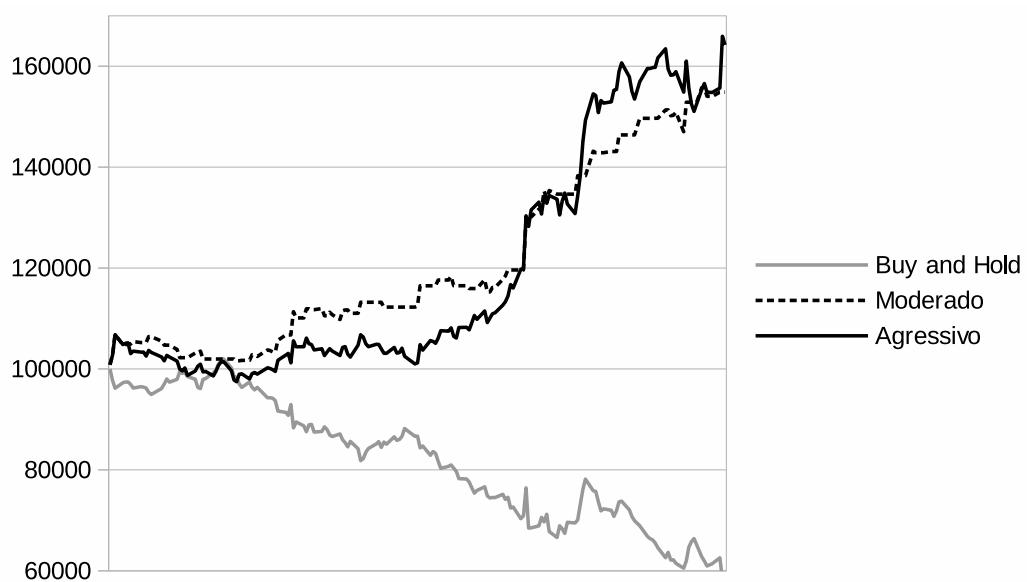
Figura A.8: Desenvolvimento do capital para JPM



Fonte: Autor

A.9 Southwestern Energy Co (SWN)

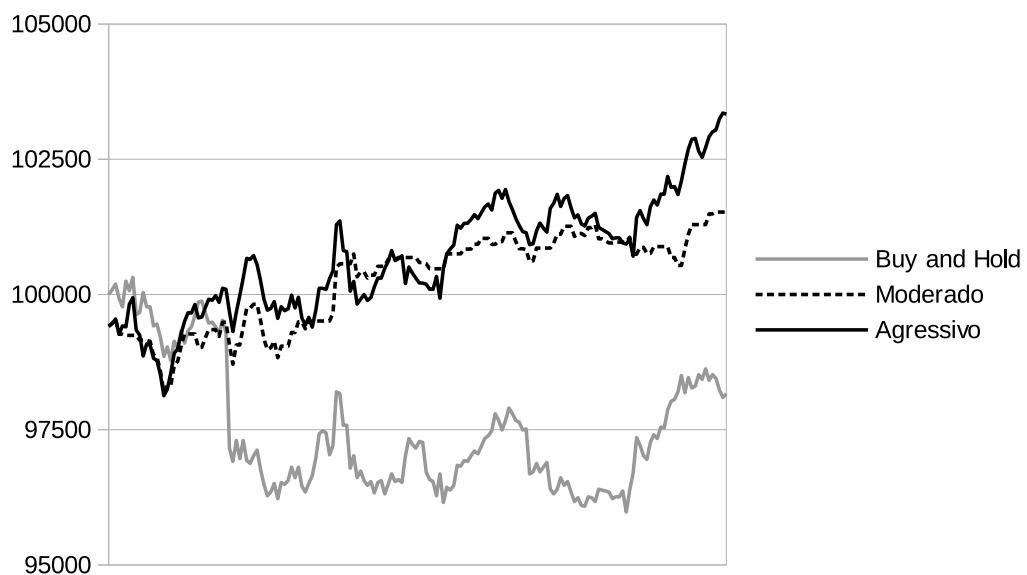
Figura A.9: Desenvolvimento do capital para SWN



Fonte: Autor

A.10 Bovespa (BOVA11)

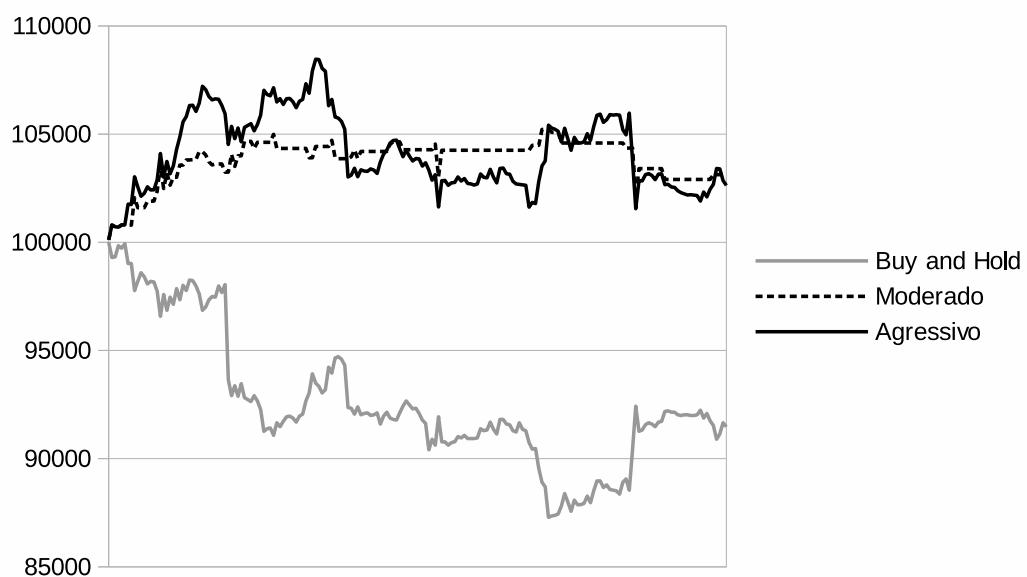
Figura A.10: Desenvolvimento do capital para BOVA11



Fonte: Autor

A.11 Banco do Brasil (BBAS3)

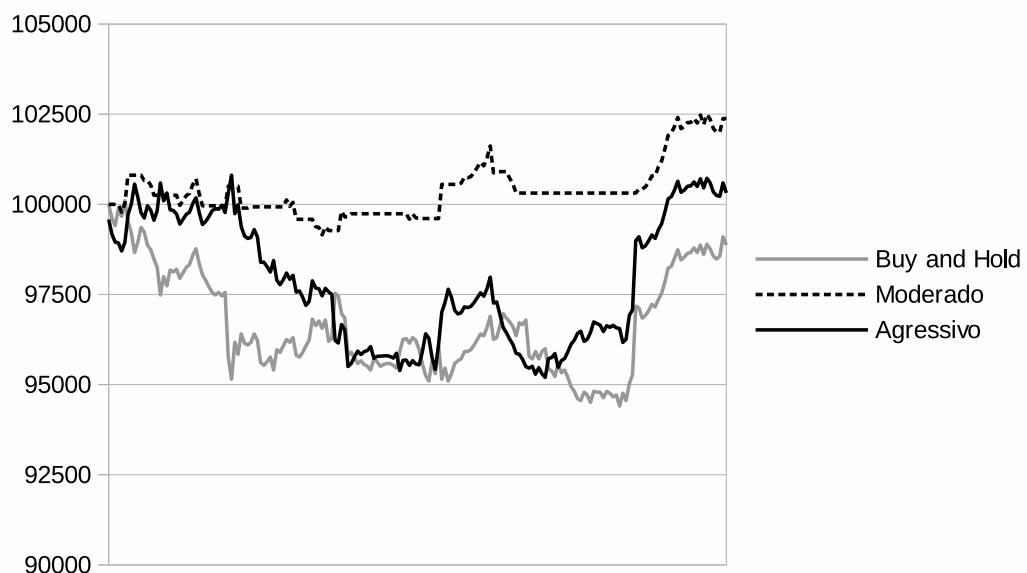
Figura A.11: Desenvolvimento do capital para BBAS3



Fonte: Autor

A.12 Bradesco (BBDC4)

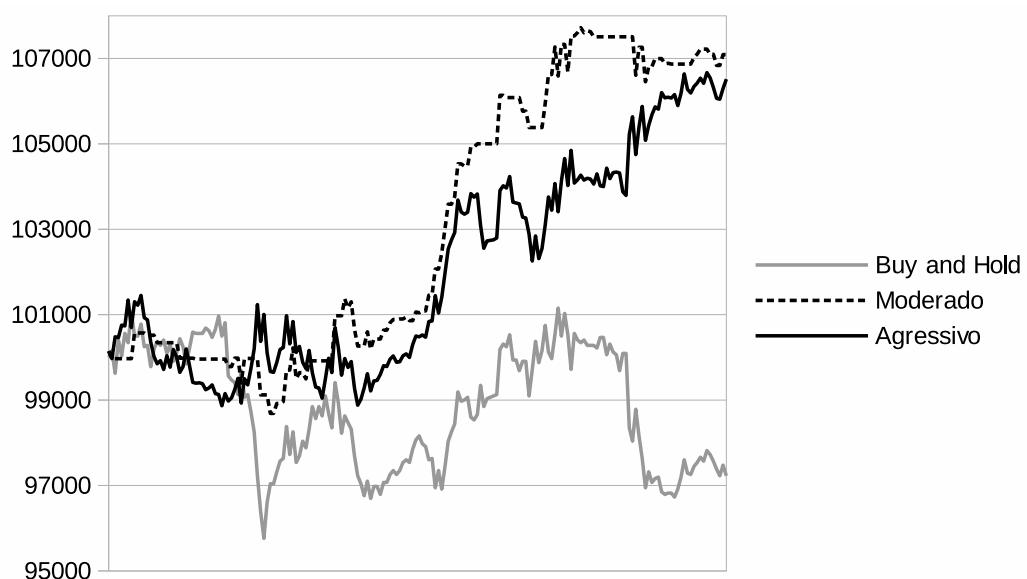
Figura A.12: Desenvolvimento do capital para BBDC4



Fonte: Autor

A.13 BB Seguridade (BBSE3)

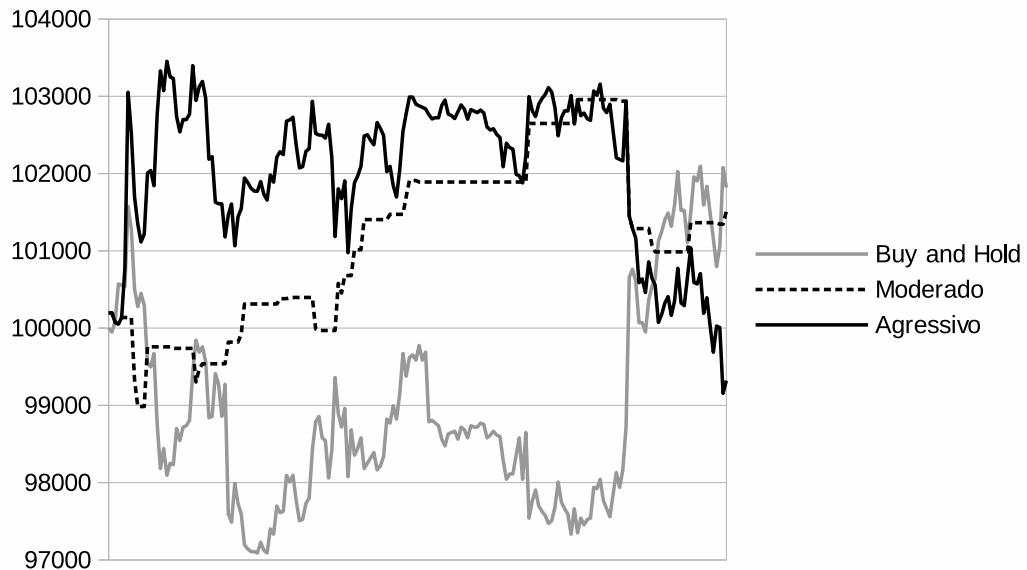
Figura A.13: Desenvolvimento do capital para BBSE3



Fonte: Autor

A.14 BRF Foods (BRFS3)

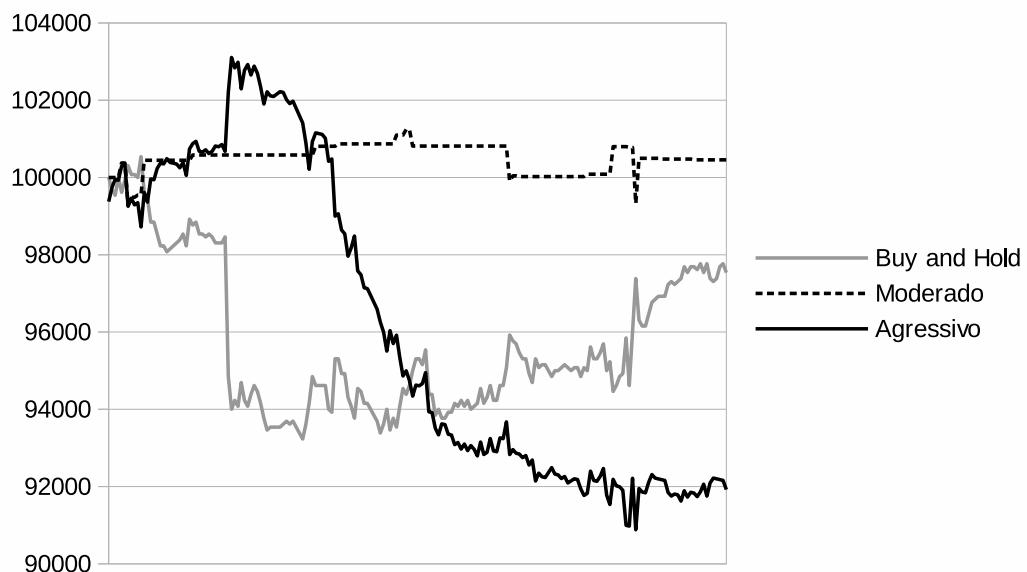
Figura A.14: Desenvolvimento do capital para BRFS3



Fonte: Autor

A.15 BMF Bovespa (BVMF3)

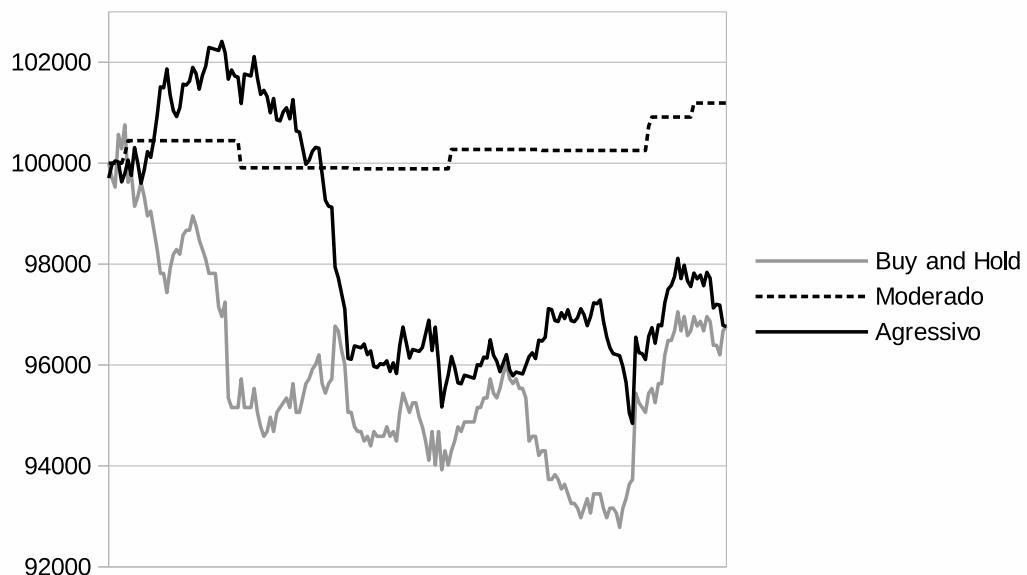
Figura A.15: Desenvolvimento do capital para BVMF3



Fonte: Autor

A.16 Itaú (ITSA4)

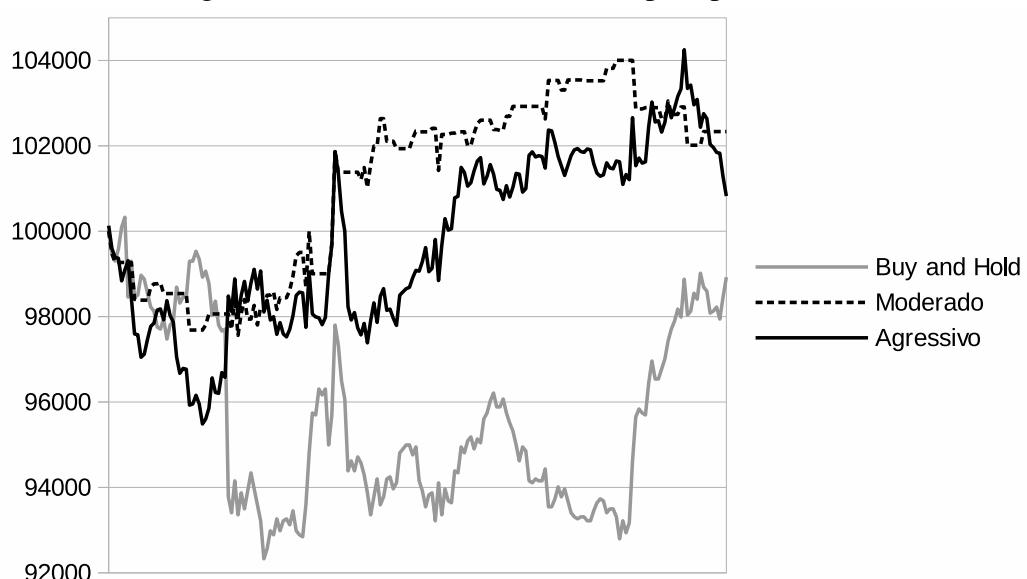
Figura A.16: Desenvolvimento do capital para ITSA4



Fonte: Autor

A.17 Petrobras (PETR4)

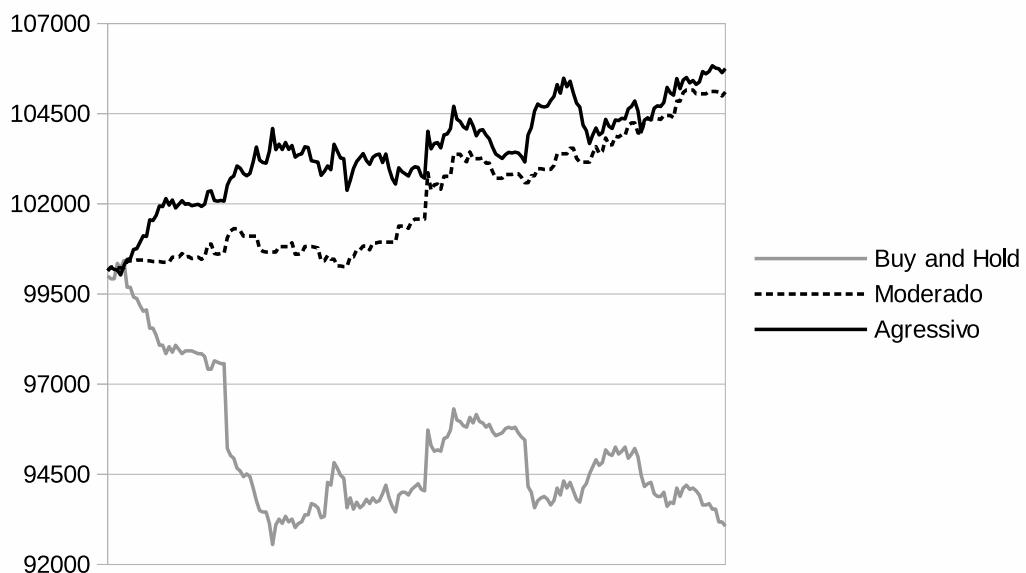
Figura A.17: Desenvolvimento do capital para PETR4



Fonte: Autor

A.18 Vale (VALE5)

Figura A.18: Desenvolvimento do capital para VALE5



Fonte: Autor