

Universidade Federal de Goiás
Regional Catalão
Unidade Acadêmica Especial de Biotecnologia
Curso de Bacharelado em Ciências da Computação

Predição Automática de Indicativos Financeiros
para Bolsa de Valores Considerando o Aspecto
Temporal

Rafael da Silva Melo

Catalão – GO
2025

Rafael da Silva Melo

Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal

Monografia apresentada ao Curso de
Bacharelado em Ciências da Computação da
Universidade Federal de Goiás – Regional Catalão,
como parte dos requisitos para obtenção do
grau de Bacharel em Ciências da Computação.
EXEMPLAR DE DEFESA I

Orientador: Prof. Dr. Márcio de Souza Dias

Catalão – GO
2025

Ficha de identificação da obra elaborada pelo autor, através do
Programa de Geração Automática do Sistema de Bibliotecas da UFG.

Melo, Rafael da Silva

Predição Automática de Indicativos Financeiros para Bolsa de
Valores Considerando o Aspecto Temporal [manuscrito] / Rafael
da Silva Melo. – 2025.

53 p.: il.

Orientador: Prof. Dr. Márcio de Souza Dias

Monografia (Graduação) – Universidade Federal de Goiás, Uni-
dade Acadêmica Especial de Biotecnologia, Ciências da Computa-
ção, 2025.

Bibliografia.

1. predição. 2. indicadores financeiros. 3. séries temporais.
4. bolsa de valores. 5. aprendizado profundo. I. Dias, Márcio de
Souza, orient. II. Título.

CDU 004

Rafael da Silva Melo

Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal

Monografia apresentada ao curso de Bacharelado em Ciências da Computação da Universidade Federal de Goiás – Regional Catalão.

Trabalho aprovado em 01 de Agosto de 2025.

Márcio de Souza Dias

Orientador

Marcio Antonio Duarte

Universidade Federal de Catalão

Thiago Jabur Bittar

Universidade Federal de Catalão

Catalão – GO
2025

RESUMO

MELO, R. S.. **Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal**. 2025. 53 p. Monografia (Graduação) – Unidade Acadêmica Especial de Biotecnologia, Universidade Federal de Goiás – Regional Catalão, Catalão – GO.

O trabalho introduz um modelo híbrido de aprendizado profundo, utilizando uma combinação de redes neurais LSTM + CNN para prever indicadores financeiros da bolsa brasileira B3 — Brasil, Bolsa, Balcão — com base em dados de séries temporais intradiárias.

A análise incorpora dados de liquidez, volatilidade e volume negociado, juntamente com engenharia de características e uma metodologia de validação cruzada temporalmente consciente para melhorar a robustez e a repetibilidade dos resultados.

Sua arquitetura foi construída para inferir cenários de estresse e choques de mercado, algo fora do alcance de métodos clássicos como ARIMA ou Prophet. Um importante marco é que produz valores muito precisos, o que importa muito mais para negociantes da bolsa e gerentes de risco.

Um pipeline baseado em Python será construído para ser usado na reprodução e geração de dados, além da agregação de dados e análise subsequente na qual este estudo se baseia. Essas contribuições implicam em uma maior estabilidade em ambientes voláteis e insights que podem ser transferidos para vários ativos financeiros.

Palavras-chave: predição, indicadores financeiros, séries temporais, bolsa de valores, aprendizado profundo.

ABSTRACT

MELO, R. S.. **Predição Automática de Indicativos Financeiros para Bolsa de Valores Considerando o Aspecto Temporal**. 2025. 53 p. Monografia (Graduação) – Unidade Acadêmica Especial de Biotecnologia, Universidade Federal de Goiás – Regional Catalão, Catalão – GO.

The paper introduces a hybrid deep learning model that combines LSTM and CNN neural networks to predict financial indicators of the Brazilian exchange B3 — Brasil, Bolsa, Balcão — based on intraday time-series data.

The analysis incorporates liquidity, volatility, and traded volume data, together with feature engineering and a time-aware cross-validation methodology to improve the robustness and replicability of the results.

Its architecture was designed to infer stress scenarios and market shocks, something beyond the reach of classical methods such as ARIMA or Prophet. A key advantage is that it produces highly accurate values, which matters much more to stock traders and risk managers.

A Python-based pipeline will be built to support reproducibility and data generation, as well as data aggregation and the subsequent analysis on which this study relies. These contributions imply greater stability in volatile environments and insights that can be transferred to multiple financial assets.

Keywords: prediction, financial indicators, time series, stock exchange, deep learning.

SUMÁRIO

Lista de ilustrações	1
Lista de tabelas	1
1	INTRODUÇÃO 5
1.1	Contextualização 5
1.2	Limitações dos modelos clássicos 7
1.3	Problema de Pesquisa 8
1.3.1	<i>Justificativa 10</i>
1.4	Objetivos 10
1.4.1	<i>Objetivo geral 10</i>
1.4.2	<i>Objetivos específicos 11</i>
1.4.3	<i>Contribuição Esperada 11</i>
2	FUNDAMENTAÇÃO TEÓRICA 13
2.1	Mercado financeiro em geral 13
2.1.1	<i>Regulação e Estrutura da B3 como Infraestrutura de Mercado . . . 13</i>
2.1.2	<i>Conectividade e Ambientes de Negociação 14</i>
2.1.3	<i>Ativos 14</i>
2.1.4	<i>Principais conceitos utilizados no mercado financeiro 15</i>
2.1.5	<i>Indicadores técnicos 15</i>
2.1.6	<i>Preço real, o que acontece 16</i>
2.1.6.1	<i>Representação dos preços em Candlesticks 17</i>
2.2	Estacionariedade e transformações usuais 18
2.2.1	<i>Volatilidade e Liquidez Intradiária 18</i>
2.2.2	<i>Componente Temporal em Predição de Séries Financeiras 19</i>
2.2.3	<i>Séries Temporais e a Aplicação de Deep Learning em Finanças . . 20</i>
2.2.3.1	<i>Redes Recorrentes Long Short-Term Memory (LSTM) 21</i>
2.2.3.2	<i>Arquitetura Transformer e o Mecanismo de Atenção 22</i>
3	TRABALHOS RELACIONADOS 25
3.1	Modelos Clássicos e Estatísticos 25
3.2	Aprendizado de Máquina e Modelos Híbridos 25
3.3	Redes Neurais Profundas 27

3.4	Transformers para Séries Temporais	28
3.5	LLMs atuais aplicados a Séries Temporais Financeiras	29
3.6	Síntese Crítica	31
4	PRÓXIMOS PASSOS	35
4.1	Aquisição e Descrição dos Dados	36
4.2	Pré-processamento e Engenharia de Atributos	36
4.3	Arquitetura dos Modelos	36
4.4	Desenho Experimental e Treinamento	37
4.5	Métricas de Avaliação	37
4.5.1	<i>Backtests e Custos de Transação</i>	38
4.5.2	<i>Testes de Robustez e Significância</i>	38
4.5.3	<i>Reprodutibilidade</i>	38
4.6	Ameaças à Validade	38
4.7	Cronograma PFC2	39
5	CONSIDERAÇÕES FINAIS	41
	REFERÊNCIAS	43
6	GLOSSÁRIO	49
7	SIGLAS	53

LISTA DE ILUSTRAÇÕES

Figura 1	– Explicação visual sobre cada serie temporal. Fonte: (LEONUNESBIO, 2014).	6
Figura 2	– Delimitação da tarefa: previsão direcional intradiária (+1 barra, 15 min). Fonte: autor.	10
Figura 3	– Mini-chart de 15 minutos da ação PETR4 (Petrobras), com candles, Médias Móveis de 9, 21 e 50 períodos, Bandas de Bollinger (20x2) e RSI de 9, 21 e 50. Fonte: Yahoo Finance, adaptado pelo autor.	16
Figura 4	– Candlesticks. Fonte: Giacomel (2016).	18
Figura 5	– <i>Trade-off</i> do tamanho da janela. Fonte: o autor	20
Figura 6	– Arquitetura de uma célula de memória LSTM, ilustrando o estado de célula e os três portões (esquecimento, entrada e saída) que regulam o fluxo de informação. Fonte: Adaptado de (OLAH, 2015).	22
Figura 7	– A arquitetura do modelo Transformer, destacando os blocos de codificador e decodificador, as camadas de atenção multi-cabeças e as redes feed-forward. Fonte: Adaptado de Vaswani et al. (2017) (VASWANI <i>et al.</i> , 2017).	23
Figura 8	– Validação temporal walk-forward com seleção bayesiana de hiperparâmetros. Fonte: autor.	27
Figura 9	– Guia adotado para construção de modelo. Fonte: o autor.	35

LISTA DE TABELAS

Tabela 1	– Exemplo de Série Temporal Multivariada da Ação PETR4 (intervalo de 15 minutos)	21
Tabela 2	– Método vs. Dados exigidos. Fonte: o autor.	32
Tabela 3	– Método vs. Custo computacional. Fonte: o autor.	32
Tabela 4	– Método vs. Pontos fortes. Fonte: o autor.	32
Tabela 5	– Método vs. Fragilidades. Fonte: o autor.	33
Tabela 6	– Cronograma de Execução do PFC2 (Set/2025–Jan/2026)	39

LISTA DE ALGORITMOS

INTRODUÇÃO

1.1 Contextualização

As bolsas de valores são infraestruturas de mercado onde compradores e vendedores negociam valores mobiliários sob regras claras e supervisão, promovendo formação de preços, liquidez e alocação eficiente de recursos (MISHKIN; EAKINS, 2018; FABOZZI; MODIGLIANI, 2009). No Brasil, esse papel é desempenhado pela B3 — Brasil, Bolsa, Balcão —, que integra ambientes de negociação, registro, compensação e liquidação, operando sob marcos legais como a Lei do Mercado de Valores Mobiliários e a Lei das Sociedades por Ações (B3, 2025b; BRASIL, 1976a; BRASIL, 1976b). Em mercados acionários, os preços refletem expectativas sobre fluxos de caixa futuros e risco, mas também exibem forte volatilidade e variação de liquidez (BODIE; KANE; MARCUS, 2021).

No horizonte intradiário, emergem problemas clássicos de microestrutura — periodicidades sistemáticas ao longo do dia, espaçamento irregular entre negócios e impacto de ordens (inclusive via *spread*¹ e custo de imediatismo) — que condicionam a dinâmica de preços e a interpretação de sinais de curto prazo (ANDERSEN; BOLLERSLEV, 1997; ENGLE; RUSSELL, 1998; HASBROUCK, 2007; AMIHUD, 2002; DUFOUR; ENGLE, 2000). Além disso, choques macroeconômicos e eventos exógenos podem deslocar rapidamente as cotações, elevando a incerteza (BANK, 2020). Esse contexto motiva a investigação de métodos preditivos sensíveis ao tempo e às nuances operacionais do ambiente de negociação brasileiro.

Com os avanços da tecnologia, a complexidade e a volatilidade dos ativos negociados em bolsa de valores aumentaram de forma significativa. Embora o mercado de ações não seja teoricamente previsível, muitos investidores identificam padrões que motivam a busca por estratégias de previsão (LO, 2017). No mundo, ativos fortemente correlacionados com mercados internacionais e fluxo de notícias, bem como a crescente participação de investidores individuais e institucionais, reforçam a necessidade de ferramentas que esclareçam sinais de curto, médio e longo prazo.

Neste estudo, considera-se explicitamente um modelo híbrido baseado em redes recorrentes do tipo LSTM combinadas a convoluções unidimensionais (CNN+LSTM), visando capturar simultaneamente dependências de longo prazo e padrões locais em séries intradiárias da B3. Essa escolha se apoia em evidências de que LSTMs representam melhor relações não lineares e dependências temporais prolongadas, enquanto camadas convolucionais extraem motivos de

¹ Diferença entre o preço de compra (bid) e o de venda (ask) de um ativo.

curto prazo a partir de janelas deslizantes; em conjunto, busca-se maior robustez frente a ruído e a mudanças de regime de mercado. Para assegurar comparabilidade, os resultados serão confrontados com baselines estatísticos (ARIMA, Prophet) e com variantes baseadas em Transformers reportadas nas literaturas (DING; QIN, 2020; NASCIMENTO; SANTOS; FERREIRA, 2023; ZENG *et al.*, 2022; WEN *et al.*, 2022).

No entanto, como Zvi Bodie and Alex Kane and Alan J. Marcus (BODIE; KANE; MARCUS, 2021) dizem em seu livro, o mercado de ações é impulsionado por variáveis econômicas (taxas de juros, taxas de câmbio, indicadores de inflação), fatores corporativos (demonstrações financeiras da empresa e mudanças na governança) e também eventos externos (crises políticas, pandemias, choques de oferta) como diz (BANK, 2020). Estes quesitos permitem que, em cada série temporal, sejam produzidas componentes como tendência, sazonalidade e ciclos, conforme a decomposição tradicional proposta em Box e Jenkins (BOX *et al.*, 2015) e amplamente discutida em Hyndman e Athanasopoulos (HYNDMAN; ATHANASOPOULOS, 2018):

- **Tendência:** define se os preços atuais estão subindo ou caindo a curto prazo.
- **Sazonalidade:** é qualquer tipo de padrão repetitivo entre ciclos diários a anuais.
- **Ciclos:** um movimento de oscilação de médio a longo prazo, que não segue um calendário fixo, mas decorre de condições econômicas, corporativas e externas.
- **Ruído aleatório:** variações imprevisíveis, que não podem ser explicadas por tendência, sazonalidade ou ciclos, geralmente decorrentes de choques ou flutuações aleatórias.

A figura 1 apresenta diferentes combinações dos componentes básicos de uma série temporal: tendência, ciclos e ruído. Cada gráfico mostra isoladamente ou em conjunto esses elementos, evidenciando como eles moldam o comportamento dos dados ao longo do tempo. A tendência representa o movimento de longo prazo (aumento ou queda contínua), os ciclos mostram padrões repetitivos de médio prazo ligados a fatores econômicos ou sazonais, e o ruído corresponde a flutuações aleatórias sem padrão definido. Assim, ao combinar esses elementos, observamos séries mais complexas e realistas, aproximando-se do que ocorre em dados empíricos.




Figura 1 – Explicação visual sobre cada serie temporal. Fonte: (LEONUNESBIO, 2014).

É aqui que avanços arquitetônicos recentes entram em cena — como o *Temporal Fusion Transformer* (TFT) (LIM; ZOHREN; ROBERTS, 2021), variantes Transformers voltadas à não-estacionaridade (LIU *et al.*, 2022), mecanismos de atenção por “patches” (PatchTST) (NIE *et al.*, 2023) e redes temporais dedicadas como o *TimesNet* (WU *et al.*, 2023). Além disso, modelos fundacionais e abordagens baseadas em **Grandes Modelos de Linguagem (LLMs)** vêm sendo aplicados a séries temporais, como o *TimesFM* (GOEL *et al.*, 2025) e o *TimeGPT* (LATHUILÈRE *et al.*, 2024), juntamente com métodos que alinham LLMs à tarefa de previsão (LLM4TS; Time-LLM) (CHANG *et al.*, 2023; JIN *et al.*, 2023) e aplicações no domínio financeiro (ALONSO; FRANKLIN, 2024). Há também um debate quanto à efetividade prática dos Transformers em séries temporais (ZENG *et al.*, 2022; WEN *et al.*, 2022). Para cenários com dados multimodais, destacam-se propostas como o *Hidformer* (LIANG *et al.*, 2025). Apesar desses avanços, contextos intradiários permanecem desafiadores — periodicidade intradiária e efeitos de microestrutura (ANDERSEN; BOLLERSLEV, 1997; HASBROUCK, 2007), irregularidade temporal/duração entre negócios (ENGLE; RUSSELL, 1998) e custo computacional — tema que será retomado na seção de Trabalhos Relacionados.

A própria natureza do comércio, marcada por negociações frequentes e pelo uso de estratégias algorítmicas — isto é, sistemas automatizados que executam ordens de compra e venda com base em regras predefinidas, muitas vezes em alta frequência —, enfatiza a importância de modelos capazes de capturar rapidamente padrões transitórios sem perder de vista o horizonte de médio prazo de maneira rigorosa (SUNKI *et al.*, 2024).

Outras pesquisas já propuseram modelos híbridos para previsão de preços de ações — por exemplo, o modelo proposto por (JUNIOR, 2013), que combina redes neurais, técnicas estatísticas e indicadores técnicos via comitê de aprendizado. Entretanto, tais propostas, em geral, não exploram esquemas de agregação mais sofisticados (como metaclassificação em dois estágios) nem avaliam de forma sistemática a robustez a mudanças súbitas de regime (SOUZA *et al.*, 2022; TSAY, 2010).

Coerente com o título desta monografia, explicitamos os **alvos preditivos (indicativos financeiros)** a serem modelados: direção do return na próxima barra, medida de volatilidade intradiária (p.ex., amplitude/variação realizada) e sinais de liquidez, como volume negociado e spread efetivo (TSAY, 2010; DACOROGNA *et al.*, 2001; WOOD; MCINISH; ORD, 1985; MISHKIN; EAKINS, 2018; JR; OUTROS, 2014; NASCIMENTO; SANTOS; FERREIRA, 2023).

Portanto, este trabalho avança a linha dos híbridos ao empregar um modelo CNN+LSTM com camadas convolucionais para padrões locais, validação temporal walk-forward e uma avaliação realista pós-custos no contexto da B3, com foco em estabilidade e reprodutibilidade dos resultados.

1.2 Limitações dos modelos clássicos

Métodos estatísticos tradicionais, como ARIMA e seus desdobramentos sazonais, oferecem boa interpretabilidade e desempenho em séries estacionárias ou de baixa não linearidade. Todavia, como demonstram estudos recentes, esses modelos tendem a perder eficácia quando confrontados com mercados “barulhentos”, em que pequenos choques (notícias inesperadas, decisões judiciais, compras ou vendas grandes em pouco tempo) podem alterar radicalmente as projeções (SUNKI *et al.*, 2024).

Ding e Qin (DING; QIN, 2020) demonstraram o modelo associado de rede baseada em

Long Short-Term Memory - LSTM² é capaz de prever simultaneamente preço de abertura, mínima e máxima, alcançando acurácia superior a 95% em dados históricos de bolsa. (NASCIMENTO; SANTOS; FERREIRA, 2023) compararam modelos ARIMA, Prophet e LSTM para séries financeiras, mostraram que arquiteturas baseadas em redes recorrentes capturam melhor dependências de tempo mais longas. Já propostas de *ensembles* híbridos (por exemplo, um comitê que combina múltiplas LSTMs paralelas) sugerem ganhos de robustez e precisão. Diante do cenário dos modelos híbridos e *ensembles*, que combinam redes profundas, métodos estatísticos e indicadores técnicos, a fim de aproveitar as vantagens de cada abordagem e mitigar suas fragilidades, tem-se o exemplo promissor que é o uso de metaclassificadores, em que vários algoritmos (e.g., redes LSTM, SVM, random forest) produzem previsões independentes que são então combinadas por um modelo adicional, responsável por aprender como integrar essas saídas e gerar uma decisão final mais consistente (SOUZA *et al.*, 2022).

Ao mesmo tempo, a inclusão de indicadores técnicos, como médias móveis, índice de força relativa (RSI) ou bandas de Bollinger, tem se mostrado útil para modelos de ML no enriquecimento de informações de tendência e volatilidade marcadas por janelas de preços históricos. Isso melhora a capacidade das redes neurais de discriminar entre sinais reais e ruído (DING; QIN, 2020). Se a volatilidade for suficientemente alta, esses comitês têm se mostrado mais estáveis e confiáveis na previsão do que qualquer um desses métodos usados isoladamente.

Embora vários estudos tenham afirmado precisões acima de 90% no caso de previsões diárias, análises subsequentes mostraram um viés de "falsa segurança": muitos resultados não são muito úteis em cenários reais de mercado porque ignoram a dependência temporal real entre treinamento e teste.

1.3 Problema de Pesquisa

Resultados de previsão intradiária frequentemente não se sustentam em uso real porque violam a ordem temporal, ignoram regimes de liquidez/volatilidade e desconsideram custos de transação. Nesse cenário, permanece incerto se modelos de aprendizado profundo — em especial arquiteturas híbridas CNN+LSTM — geram sinais direcionais realmente utilizáveis (horizonte +1 barra/15 min) para ações líquidas da B3 entre 2020–2025, quando avaliados sob um protocolo rigoroso de validação walk-forward e comparados a baselines clássicos e arquiteturas com atenção.

Delimitação do escopo:

Este estudo situa-se no universo de bolsas de valores e mercados organizados, em que a negociação se dá sob regras de listagem, leilões, formação de preço e procedimentos operacionais definidos (no caso brasileiro, pela B3) (B3, 2025). Em janelas intradiárias, o comportamento do preço é influenciado por aspectos de *microestrutura* (ex.: liquidez, *spread*, intensidade de ordens, periodicidades intradiárias), o que afeta diretamente a previsibilidade e a avaliação de modelos (HASBROUCK, 2007; ANDERSEN; BOLLERSLEV, 1997; DUFOUR; ENGLE, 2000; ENGLE; RUSSELL, 1998). À luz dessa dinâmica, explicitamos a seguir as delimitações adotadas.

- **Ativos:** Consideramos ações líquidas negociadas na B3 (e.g., PETR4, VALE3, ITUB4) e, quando pertinente, a carteira do Ibovespa como referência de mercado. A escolha por alta

² rede recorrente com memória de longo prazo

liquidez visa mitigar efeitos de microestrutura adversos (como slippage e spread amplos) que distorcem sinais intradiários (HASBROUCK, 2007).

- **Período e granularidade:** Os experimentos cobrem jan/2020–jul/2025 em barras de 15 minutos, com análises de sensibilidade em 5 e 30 minutos. Essa granularidade equilibra ruído e sinal em alta frequência e captura periodicidades intradiárias conhecidas (picos de volatilidade na abertura/fechamento, padrões de almoço, etc.) (ANDERSEN; BOLLERSLEV, 1997; HYNDMAN; ATHANASOPOULOS, 2018).
- **Tarefa:** Prever a **direção do movimento de preço** na próxima vela (horizonte +1 barra), formulada como classificação probabilística. Tal formulação permite avaliar calibração e qualidade probabilística, não apenas acerto bruto (BRIER, 1950; GUO *et al.*, 2017) — ver também a interpretação visual da tarefa na Figura 2.
- **Validação e treinamento:** Para evitar viés temporal (look-ahead) e superestimação de desempenho, adotamos validação walk-forward com janelas sequenciais, seleção de hiperparâmetros por otimização Bayesiana e controle de sementes/versionamento para reprodutibilidade. Esse arranjo segue boas práticas de validação em séries temporais e backtesting (BERGMEIR; BENÍTEZ, 2012; PRADO, 2018).
- **Métricas:** Aferimos:

- I. *acurácia direcional com banda morta*, para robustez a microvariações;
- II. Brier Score e Log-Loss, para qualidade das probabilidades e calibração (BRIER, 1950; GUO *et al.*, 2017);
- III. métricas pós-custos de trading (retorno líquido, drawdown e índice de Sharpe), refletindo utilidade prática sob custos de transação (SHARPE, 1994)

Para comparar previsores quando necessário, usamos testes de acurácia preditiva como Diebold–Mariano (DIEBOLD; MARIANO, 1995).

- **Comparadores (baselines):** Contrastamos o modelo proposto com referências clássicas e modernas:
- I. ARIMA/Box–Jenkins como baseline estatístico canônico (BOX *et al.*, 2015; HYNDMAN; ATHANASOPOULOS, 2018; JR; OUTROS, 2014);
 - II. Prophet, representando um decompositor aditivo com sazonalidades/mudanças de nível (TAYLOR; LETHAM, 2018);
 - III. arquiteturas modernas para séries temporais, incluindo variantes baseadas em Transformers, dada sua capacidade de capturar dependências de longo alcance (WEN *et al.*, 2022; ZENG *et al.*, 2022).

A ilustração 2 sintetiza a tarefa: em uma série de preços intradiária (barras de 15 min), cada ponto no tempo gera um vetor de atributos (preço, volume, indicadores técnicos e variáveis de contexto) e o modelo estima a probabilidade de a próxima barra encerrar acima (ou abaixo) da atual. O horizonte é de +1 barra (curto prazo), e as janelas de treino/teste avançam sequencialmente no tempo (esquema walk-forward), refletindo o fluxo real de mercado e evitando contaminação temporal.




Figura 2 – Delimitação da tarefa: previsão direcional intradiária (+1 barra, 15 min). Fonte: autor.

Pergunta central do estudo:

Em que condições (janelas, regimes de volatilidade e custo) um modelo CNN+LSTM supera comparadores clássicos (Naive, ARIMA, Prophet) e variantes com atenção na tarefa de previsão direcional intradiária (+1 barra/15 min) em ações líquidas da B3 (2020–2025), sob avaliação walk-forward e métricas pós-custos?

1.3.1 Justificativa

A previsão intradiária de movimentos de preços na B3 apresenta relevância prática para apoio à decisão em ambientes voláteis e com custos de transação não desprezíveis. Do ponto de vista acadêmico, persiste uma lacuna entre resultados reportados em ambientes controlados e o desempenho sob *walk-forward*³, com avaliação pós-custos e controle de deriva de conceito. Este estudo busca reduzir essa lacuna ao (i) delimitar um cenário intradiário realista, (ii) empregar validação temporal adequada e (iii) comparar um modelo híbrido (CNN+LSTM) a *baselines* consolidados. O potencial impacto inclui melhores critérios de avaliação para tarefas direcionais, evidências sobre robustez em diferentes regimes de volatilidade e um *pipeline* reproduzível que pode ser replicado e estendido por outros pesquisadores.

1.4 Objetivos

1.4.1 Objetivo geral

Avaliar de forma quantitativa e reproduzível, a capacidade de modelos de aprendizado de máquina sensíveis ao tempo em prever o comportamento direcional de indicadores financeiros intradiários, comparando seu desempenho a *baselines* estatísticos e neurais sob um protocolo experimental realista (validação walk-forward e backtest⁴) pós-custos.

³ Método em que o treino e o teste avançam em janelas sequenciais, mantendo a ordem temporal.

⁴ Simulação histórica de uma estratégia sob regras e dados passados.

1.4.2 Objetivos específicos

1. Construir e documentar o conjunto de dados intradiários (OHLCV e indicadores técnicos) para o período definido (2020–2025) e frequência fixa (15 minutos), especificando fontes, regras de limpeza, critérios de inclusão de ativos e prevenção de vazamento temporal.
2. Definir o desenho experimental com validação walk-forward (janelas deslizantes, embargo temporal e padronização dentro de cada janela), estratégia de seleção de hiperparâmetros e controle de variáveis (sementes, versões e ambiente).
3. Treinar e comparar *baselines* representativos com o(s) modelo(s) proposto(s) sensíveis à ordem temporal, mantendo critérios comparáveis de otimização.
4. Mensurar a qualidade preditiva por múltiplas métricas: acurácia direcional com banda morta, F1/recall para a classe positiva, Brier score e AUC-PR, incluindo análise de calibração das probabilidades.
5. Avaliar desempenho operacional convertendo sinais em regras simples de negociação e realizando backtests com custos de transação e slippage, reportando retorno, Sharpe, max drawdown e turnover, além de cortes por regimes de volatilidade.
6. Testar significância e robustez dos resultados por meio do teste de Diebold-Mariano, bootstrap em blocos e análises de sensibilidade (janelas temporais, subconjuntos de ativos, horizonte de previsão e feature sets).
7. Garantir reprodutibilidade com repositório versionado, manifesto de dependências, *scripts* de preparo/treino/avaliação, diários de experimento e registro explícito de ameaças à validade interna e externa.

1.4.3 Contribuição Esperada

Este trabalho busca contribuir em quatro frentes principais:

Primeiro, com o desenvolvimento de um modelo híbrido (CNN+LSTM) capaz de combinar padrões locais e dependências de longo prazo em séries temporais financeiras, adequando-se às particularidades do mercado intradiário da B3.

Em segundo lugar, ao realizar uma avaliação empírica comparativa com *baselines* estabelecidos (ARIMA, Prophet, LSTM puro e variantes Transformer), sob um protocolo realista de validação walk-forward e backtests pós-custos.

A terceira contribuição está na análise da robustez do modelo em diferentes condições de mercado, explorando regimes de volatilidade e choques pontuais.

Finalmente, planeja-se lançar um pipeline reproduzível com a fonte organizada, bem como documentação detalhada, não apenas para apoiar a futura replicação de experimentos, mas também para facilitar a adaptação e extensão por outros pesquisadores interessados nessas abordagens.

Este trabalho promoverá e eliminará barreiras técnicas à comunidade científica e, desencadeará a co-construção do conhecimento. Além disso, a natureza aberta do pipeline permite que novas metodologias sejam testadas em igualdade de condições, tornando os resultados mais comparáveis e, portanto, contribuindo para conclusões mais robustas.

FUNDAMENTAÇÃO TEÓRICA

2.1 Mercado financeiro em geral

Em primeiro lugar, é preciso compreender que o mercado financeiro é um espaço institucionalizado no qual diversos agentes econômicos negociam diferentes tipos de ativos, como títulos de dívida, *commodities*, derivativos e moedas (MISHKIN; EAKINS, 2018).

As ações também fazem parte desses ativos, frações adequadas do capital social de empresas de capital aberto cuja negociação é realizada regularmente por meio das bolsas de valores (BRASIL, 1976b). Investidores que comprem uma ação tornam-se acionistas, ou proprietários parciais das corporações que emitiram tais ações, e, conseqüentemente, têm certos direitos legais (o direito de receber sua parte proporcional dos dividendos distribuídos pela corporação e, muitas das vezes, o direito de votar em decisões corporativas indiretamente). Isso significa que as ações não são apenas sobre como a empresa ganha dinheiro na realidade, mas também sobre o que os investidores acham que ela gerará no futuro — portanto, a negociação de ações nada mais é do que uma percepção entre as pessoas e as dinâmicas econômicas gerais.

A B3 opera em um ambiente regulado que garante segurança jurídica e transparência às operações realizadas pelos participantes, permitindo que investidores forneçam recursos às empresas ou ao governo em troca de remuneração futura, geralmente sob forma de juros, dividendos ou ganhos de capital advindos da valorização dos ativos adquiridos de acordo com a (BRASIL, 1976a).

Existem muitas bolsas de valores espalhadas por todo o mundo, cada uma operando sob regulamentações específicas, negociando ativos próprios e refletindo as particularidades econômicas e culturais das regiões onde estas estão inseridas. Exemplos notórios incluem a Bolsa de Nova York (New York Stock Exchange, s.d.), a Nasdaq (NASDAQ, s.d.) nos Estados Unidos, a Bolsa de Londres no Reino Unido (London Stock Exchange, s.d.), e a Bolsa de Valores de São Paulo no Brasil (B3, s.d.).

2.1.1 Regulação e Estrutura da B3 como Infraestrutura de Mercado

Considerando o funcionamento do mercado financeiro brasileiro, é essencial destacar o papel central da B3 (B3, 2025b). A B3 é reconhecida como uma das principais empresas de infraestrutura de mercado financeiro no mundo, atuando nos ambientes de bolsa e de balcão organizado (B3, 2025b).

Neste contexto, a B3 atua como contraparte central, integrando funções de registro, custódia, liquidação e supervisão em uma cadeia verticalmente estruturada. Essa estrutura assegura a formação adequada de preços e a ampla divulgação das ofertas no livro central, com o objetivo de proteger os investidores e garantir eficiência ao mercado (B3, 2025a; B3, 2025b).

Logo, os participantes do mercado — corretoras, formadores de mercado, provedores de tecnologia e emissores — devem operar conforme os procedimentos estabelecidos pela B3, incluindo padrões de conexão como DMA, co-location e PNP, além da manutenção de sistemas de auditoria e controles internos descritos no Manual de Procedimentos Operacionais de Negociação (B3, 2025).

2.1.2 Conectividade e Ambientes de Negociação

Para que os modelos de predição sejam robustos, é essencial compreender os diferentes tipos de conexão ao ambiente de negociação da B3. Segundo o Manual de Procedimentos Operacionais de Negociação da B3, as conexões ao ambiente de negociação são classificadas conforme sua origem e hospedagem — incluindo acesso via mesa de operações, assessores e conexão direta patrocinada (DMA) (B3, 2025). Essa última, conhecida como DMA (Direct Market Access), permite que investidores ou provedores enviem ordens diretamente ao sistema de negociação, sem intermediação manual, reduzindo latência e aumentando a eficiência na execução de trades (B3, 2025).

Além do mais, a B3 oferece o serviço de *co-location*, onde servidores de corretoras ou investidores são instalados fisicamente em data centers da bolsa (como COLO0/COLO1), diminuindo ainda mais a latência em relação ao DMA tradicional fora do centro de dados da B3 (B3, 2025). Essa configuração é especialmente importante para estratégias de alta frequência (HFT), nas quais milissegundos influenciam diretamente os retornos.

Portanto, ao lidar com dados de alta frequência em seu modelo de predição é fundamental considerar que os atrasos (latência) e o tipo de conexão (DMA, co-location ou assessor) impactam a qualidade e a reprodutibilidade dos resultados no ambiente real de negociação.

2.1.3 Ativos

Os ativos financeiros são instrumentos ou contratos negociados no mercado financeiro, com características e funções específicas, permitindo aos investidores diversificar seus investimentos de acordo com diferentes perfis de risco e expectativas de retorno (MISHKIN; EAKINS, 2018; FABOZZI; MODIGLIANI, 2009). Conforme introduzido na seção 2.1, esses ativos incluem **ações, títulos públicos e privados, moedas, derivativos e commodities** (FABOZZI; MODIGLIANI, 2009). Cada categoria apresenta particularidades quanto ao comportamento dos preços, liquidez e risco associado, tornando imprescindível uma análise detalhada antes de qualquer decisão de investimento.

Os preços desses ativos são influenciados por fatores variados, desde condições climáticas e ambientais até eventos geopolíticos e econômicos globais (BANK, 2020), o que faz deles ativos voláteis, cujos preços podem oscilar significativamente em curtos períodos. Além disso, muitos desses ativos são interligados, e variações no preço de um deles podem influenciar diretamente os demais, aumentando a complexidade das análises financeiras e exigindo dos investidores estratégias consistentes e informações atualizadas para tomadas de decisão mais assertivas (MISHKIN; EAKINS, 2018).

2.1.4 Principais conceitos utilizados no mercado financeiro

Descrever a direção predominante do movimento dos preços ao longo do tempo caracteriza o que chamamos de **tendência**. Quando um ativo apresenta uma sequência consistente de preços ascendentes, diz-se que há uma **tendência de alta**; quando ocorre o inverso, com preços descendentes de forma persistente, trata-se de uma **tendência de baixa**. Se os preços não manifestam uma direção clara, oscilando em faixas relativamente estáveis, caracteriza-se como ausência de tendência ou **mercado lateralizado** (BODIE; KANE; MARCUS, 2021).

Além do conceito de tendência, outros termos importantes são frequentemente utilizados para descrever os movimentos e comportamentos observados na bolsa de valores. Um desses termos é a **volatilidade**, que representa o grau de oscilação dos preços dos ativos ao longo de um determinado período, refletindo a instabilidade ou a incerteza do mercado naquele momento (MISHKIN; EAKINS, 2018). Quando se fala em **liquidez**, refere-se à facilidade com que um ativo pode ser convertido em dinheiro sem causar grande impacto no seu preço. Um ativo com alta liquidez pode ser negociado rapidamente, enquanto um ativo com baixa liquidez possui menos compradores e vendedores, dificultando sua negociação imediata (FABOZZI; MODIGLIANI, 2009).

Outro termo amplamente utilizado é o *dividendo*, que corresponde a uma parcela dos lucros que as empresas distribuem periodicamente aos acionistas como forma de remuneração pelo investimento realizado (BRASIL, 1976b; BODIE; KANE; MARCUS, 2021).

É comum ouvir falar em **bear market** e **bull market**. O primeiro descreve períodos prolongados de queda nos preços das ações e pessimismo generalizado no mercado. Por outro lado, um **bull market** refere-se a fases caracterizadas por aumentos contínuos e generalizados dos preços dos ativos financeiros, acompanhados por otimismo dos investidores em relação ao futuro econômico (BODIE; KANE; MARCUS, 2021).

Por fim, **Índice de mercado** diz respeito a indicadores que medem o desempenho médio de um conjunto de ativos negociados em bolsa (DAYCOVAL, 2024), como o Ibovespa no Brasil ou o S&P 500 nos Estados Unidos, servindo como referência para avaliar o comportamento geral do mercado financeiro.

2.1.5 Indicadores técnicos

Além dos índices de mercado, existem também os chamados indicadores técnicos. Eles são muito usados na análise gráfica, justamente para tentar entender como os preços se comportam e, a partir disso, decidir o melhor momento de comprar ou vender um ativo. A diferença é que, enquanto os índices de mercado mostram o desempenho geral de um grupo de ações ou ativos, os indicadores técnicos olham para cada ativo separadamente. Eles funcionam com base em cálculos matemáticos feitos sobre o histórico de preços e sobre o volume de negociações, tentando transformar esses números em sinais que ajudem o investidor a agir com mais segurança.

Além dos índices de mercado tradicionais, existem outros tipos de indicadores, denominados indicadores técnicos, utilizados principalmente na análise gráfica para avaliar o comportamento dos preços e tomar decisões relacionadas à compra e venda de ativos. Diferentemente dos índices de mercado, que avaliam o desempenho geral de um conjunto específico de ativos, os indicadores técnicos são aplicados individualmente em cada ativo, com base em cálculos matemáticos realizados sobre os preços históricos e volumes de negociação (MURPHY, 1999).

Entre os indicadores técnicos mais utilizados, destacam-se:

- **Bandas de Bollinger**: indicam a volatilidade e possíveis níveis de suporte e resistência dos preços (BOLLINGER, 2001);
- **Médias Móveis**: suavizam os dados históricos e ajudam a identificar a direção predominante dos preços (MURPHY, 1999);
- **Índice de Força Relativa (RSI)**: mede a força e a velocidade dos movimentos dos preços para avaliar possíveis situações de sobrecompra ou sobrevenda;
- **MACD (Moving Average Convergence Divergence)**: busca identificar mudanças nas tendências por meio das interações entre médias móveis.

A Figura 3 ilustra apenas como exemplo didático a aplicação prática desses indicadores em um gráfico de candles com periodicidade de 15 minutos. As **Médias Móveis de 9, 21 e 50 períodos** suavizam o comportamento dos preços e ajudam a identificar tendências de curto, médio e longo prazo (MURPHY, 1999). Em torno das velas estão as **Bandas de Bollinger (20x2)**, que se expandem ou se contraem conforme a volatilidade do mercado, sinalizando possíveis regiões de suporte e resistência (BOLLINGER, 2001). Na parte inferior do gráfico, as **janelas do Índice de Força Relativa (RSI) com 9, 21 e 50 períodos** medem a força do movimento dos preços, indicando potenciais situações de sobrecompra ou sobrevenda (MURPHY, 1999).



Figura 3 – Mini-chart de 15 minutos da ação PETR4 (Petrobras), com candles, Médias Móveis de 9, 21 e 50 períodos, Bandas de Bollinger (20x2) e RSI de 9, 21 e 50. Fonte: Yahoo Finance, adaptado pelo autor.

Esses indicadores são ferramentas essenciais para investidores e analistas técnicos, permitindo uma melhor compreensão dos movimentos de preços e auxiliando na definição de estratégias para investimentos em curto, médio ou longo prazo. (MURPHY, 1999)

2.1.6 Preço real, o que acontece

Normalmente, ao acompanharmos o mercado financeiro, prestamos atenção no preço final das ações. Aliás, é exatamente esse valor que vemos estampado nos jornais e sites especializados

após o fechamento da bolsa (MISHKIN; EAKINS, 2018). Só que, enfim, esse número por si só conta apenas parte da história do que realmente aconteceu durante o pregão. A verdade é que, ao longo do dia, acontecem inúmeras transações de compra e venda, fazendo com que o preço oscile diversas vezes—às vezes, até bruscamente—antes de chegar ao valor definitivo no encerramento do dia (MURPHY, 1999).

Suponha-se que uma ação abra o pregão com preço elevado devido a notícias positivas divulgadas no dia anterior. Isso não garante que ela vá continuar assim durante todo o período. Na verdade, pode ocorrer o oposto: em poucas horas, influenciada por novas informações ou pela movimentação de grandes investidores, o preço pode despencar (BODIE; KANE; MARCUS, 2021). Por isso, apenas olhar o preço final é insuficiente para entender o comportamento completo da ação. É aí que surgem métricas mais especializadas.

O **preço de abertura**, por exemplo, revela o ponto inicial do dia e pode já sinalizar tendências imediatas devido a transações realizadas antes do pregão oficial—o chamado pre-market. Já o preço máximo alcançado durante o dia nos diz muito sobre a força compradora, sendo um sinal claro do otimismo momentâneo dos investidores (MURPHY, 1999). Se esse preço máximo estiver muito distante do fechamento, talvez seja sinal de alerta, indicando uma possível reversão de tendência. O inverso ocorre com o preço mínimo, que reflete o maior nível de pessimismo momentâneo. Caso esteja próximo ao preço de fechamento, talvez seja sinal de recuperação da confiança dos investidores no decorrer do dia (PRING, 2014).

Além disso, o volume de negociação também é uma parte integrante de toda essa narrativa. Em suma, é o total transacionado em reais durante o dia. Isso pode revelar muito sobre o interesse dos investidores naquela ação.

Uma grande empresa como a Vale ou a Petrobras pode movimentar milhões, enquanto uma pequena movimenta pouco. Por exemplo, um aumento repentino no volume geralmente indica a chegada de algum evento significativo. Por outro lado, uma diminuição no volume pode mostrar o interesse diminuindo e também implicar que a tendência pode estar se revertendo de sua direção atual.

Por fim, é essencial destacar que essas métricas podem e devem ser analisadas em conjunto. Cada uma delas fornece pistas importantes, mas é a combinação de todas que permite uma leitura mais precisa e rica sobre o que realmente aconteceu com os preços durante o dia na bolsa. Na prática, é esse conjunto completo de informações que possibilita aos investidores e analistas técnicos tomarem decisões mais assertivas e também ajuda redes neurais a preverem com mais acurácia os movimentos futuros do mercado (MURPHY, 1999; BODIE; KANE; MARCUS, 2021).

2.1.6.1 Representação dos preços em Candlesticks

O gráfico 4 de candlestick é uma das formas mais intuitivas de representar as oscilações de preço de ativos financeiros. Cada vela informa, em um determinado intervalo de tempo, os preços de abertura, fechamento, máxima e mínima, como dito na imagem.

Quando o fechamento é superior à abertura, a vela tende a ser clara, sinalizando valorização; se inferior, escura, indicando desvalorização. Essa configuração visual permite não apenas uma leitura rápida das tendências, mas também auxilia na identificação de possíveis reversões. De acordo com estudo recente de Phankokkruad e Worasuwanarak (2025), padrões como Doji e Hammer são usados como indicativos de mudança de direção nos preços e demonstram aplicabilidade em modelos preditivos baseados em redes neurais (PHANKOKKRUAD; WORASUWANNARAK, 2025).




Figura 4 – Candlesticks. Fonte: [Giacomel \(2016\)](#).

2.2 Estacionariedade e transformações usuais

Mesmo quando os preços compartilham uma raiz unitária, embora os níveis de preços sejam comumente referidos como não estacionários em pesquisas e práticas financeiras, as flutuações de curto prazo podem frequentemente ser modeladas adequadamente por processos aproximadamente estacionários. É por isso que é uma tradição já estabelecida na área trabalhar com retornos e não com preços de ações simples ([CAMPBELL; LO; MACKINLAY, 1997](#); [TSAY, 2010](#)). Neste texto, eles usam retornos logarítmicos definidos por $r_t = \ln(P_t) - \ln(P_{t-1})$, o que torna a série temporal estacionária em relação à escala e permite composições aditivas ao longo do tempo ([CAMPBELL; LO; MACKINLAY, 1997](#)).

Para avaliar a estacionariedade, podemos usar os seguintes testes complementares: o teste ADF (Augmented Dickey–Fuller), que tem como hipótese nula a existência de uma raiz unitária, e o KPSS, que assume como nula que os dados são estacionários em torno de um nível/tendência. Evita-se conclusões parciais através de uma leitura conjunta ([SAID; DICKEY, 1984](#)).

Para controle de escala e heterocedasticidade, são executadas transformações z-score móveis ou monotônicas (por exemplo, Box–Cox), ajustadas apenas nos dados de treinamento e depois aplicadas ao conjunto de validação/teste para evitar vazamento de dados (??).

Em algumas séries intradiárias, também se remove a tendência do efeito sazonal da periodicidade diária (abertura/fechamento), seja por meio de dummies intradiários ou subtraindo a média por faixa de tempo, removendo variações sistemáticas que não se generalizam fora do padrão diário ([DACOROGNA et al., 2001](#)).

2.2.1 Volatilidade e Liquidez Intradiária

Segundo o Manual de Procedimentos Operacionais de Negociação da B3 (2019), mecanismos como a atuação de formadores de mercado, a estruturação das fases de negociação e parâmetros de lote mínimo influenciam significativamente os padrões intradiários de liquidez e volatilidade ([B3, 2025](#)). Observa-se, por exemplo, que há picos de volatilidade na abertura e no fechamento da sessão, enquanto o período intermediário costuma apresentar menor atividade.

A volatilidade intradiária pode ser mensurada por indicadores como o desvio-padrão de retornos em janelas móveis de 1, 5 ou 15 minutos ([ANDERSEN; BOLLERSLEV, 1997](#)).

Andersen & Bollerslev (1997) demonstraram que a volatilidade não é constante ao longo do dia, concentrando-se em horários específicos e gerando efeitos de heterocedasticidade e autocorrelação nos retornos (ANDERSEN; BOLLERSLEV, 1997).

Por sua vez, a *liquidez* refere-se à facilidade de negociação de um ativo sem afetar substancialmente seu preço, sendo frequentemente avaliada por medidas como:

- Volume médio por minuto;
- Spread bid–ask, diferença entre o maior preço que alguém está disposto a pagar por um ativo e o menor preço pelo qual alguém está disposto a vendê-lo;
- Índice de iliquidez de Amihud, que relaciona o retorno absoluto ao volume negociado (AMIHUD, 2002);
- Profundidade do livro de ofertas, capturando o total de ordens disponíveis em níveis próximos ao melhor preço (HASBROUCK, 2007).

Estudos empíricos mostram que períodos de baixa liquidez tendem a apresentar maior volatilidade, o que prejudica a acurácia de modelos preditivos baseados em padrões técnicos (DUFOUR; ENGLE, 2000). Além disso, ativos com elevada liquidez exibem maior previsibilidade em horizontes de curtíssimo prazo, justificando a seleção desses papéis como base de dados para este trabalho.

Do ponto de vista metodológico, a variação intradiária de volatilidade e liquidez introduz dois principais desafios ao modelo:

1. **Heterocedasticidade** — volatilidade variável ao longo do dia requer o uso de modelos capazes de capturar regimes de alta e baixa variância (ex.: GARCH intradiário);
2. **Autocorrelação temporal** — séries de duração de ordens e inter-arrival times impactam a independência dos retornos, demandando abordagens como Autoregressive Conditional Duration (ENGLE; RUSSELL, 1998).

Dessa forma, a análise conjunta de volatilidade e liquidez intradiária fornece ao novo modelo, maior robustez e sensibilidade aos diferentes momentos da sessão, permitindo antecipar cenários de risco e otimizar as decisões de predição.

2.2.2 Componente Temporal em Predição de Séries Financeiras

Na predição de séries financeiras, o componente temporal é o elemento estruturante que vai além da simples ordem cronológica dos dados. Primeiro, efeitos sazonais e de calendário — como feriados, janelas de pré-abertura e fechamento — geram variações sistemáticas em volume e volatilidade que precisam ser modeladas explicitamente para evitar vieses sazonais (HYNDMAN; ATHANASOPOULOS, 2018). Em seguida, a escolha do tamanho da janela de análise (*rolling window*) implica em um *trade-off*: janelas muito longas diluem choques pontuais, enquanto janelas muito curtas amplificam ruídos e podem induzir sobreajuste (HYNDMAN; ATHANASOPOULOS, 2018).

No gráfico da Figura 5, esse equilíbrio é ilustrado visualmente: à medida que aumentamos o tamanho da janela de análise, reduzimos o impacto do ruído de curto prazo, mas também perdemos a capacidade de reagir rapidamente a mudanças repentinas no mercado. Por outro

lado, janelas muito curtas capturam com mais agilidade as variações recentes, porém amplificam flutuações aleatórias que podem induzir ao sobreajuste. Dessa forma, a figura evidencia o dilema central entre estabilidade e sensibilidade, que precisa ser considerado na escolha do horizonte temporal para modelagem de séries financeiras.




Figura 5 – *Trade-off* do tamanho da janela. Fonte: o autor

Para avaliar corretamente esse *trade-off* e estimar a performance out-of-sample, empregam-se técnicas de validação temporal avançada, tais como *time series cross-validation* com bloqueio por períodos e *backtesting walk-forward*, que previnem o *look-ahead bias* e fornecem indicadores realistas de acurácia (BERGMEIR; BENÍTEZ, 2012). Adicionalmente, modelos de mudança de regime (*regime-switching*), como o proposto por Hamilton (1989), capturam transições abruptas entre fases de mercado (e.g., bull vs. bear), ajustando a sensibilidade do algoritmo conforme o regime vigente (HAMILTON, 1989).

No contexto deste trabalho, integrar todos esses elementos temporais — sazonalidades, janelas de análise otimizadas, validação avançada, detecção de regimes e embeddings de tempo — torna o modelo mais sensível tanto a movimentos rápidos quanto a evoluções estruturais, garantindo previsões mais estáveis e acuradas em diferentes momentos da sessão de negociação.

2.2.3 Séries Temporais e a Aplicação de Deep Learning em Finanças

A modelagem de dados financeiros frequentemente se baseia no conceito de séries temporais, que consistem em uma sequência de observações coletadas em intervalos de tempo regulares. Uma série temporal é mais do que uma simples lista de números. A sua característica fundamental é a dependência temporal, onde o valor de uma observação em um determinado momento pode ser influenciado por valores passados. No contexto da bolsa de valores, uma série temporal pode ser composta pelos preços de fechamento diário de uma ação, pelo volume de negociações a cada minuto ou por qualquer outra métrica que evolua ao longo do tempo.

Para ilustrar, considere a Tabela 1, que apresenta uma série temporal multivariada hipotética para a ação PETR4, com dados intradiários coletados a cada 15 minutos. Cada linha representa um ponto no tempo, e as colunas (variáveis) representam diferentes métricas financeiras, como os preços de abertura, máxima, mínima, fechamento e o volume negociado. A análise dessa série busca identificar padrões, tendências e sazonalidades que possam ser utilizados para prever os movimentos futuros dos preços.

Tabela 1 – Exemplo de Série Temporal Multivariada da Ação PETR4 (intervalo de 15 minutos)

Timestamp	Abertura (R\$)	Máxima (R\$)	Mínima (R\$)	Fechamento (R\$)	Volume
2025-08-18 10:00	30,50	30,65	30,48	30,62	1.250.000
2025-08-18 10:15	30,62	30,70	30,55	30,68	890.000
2025-08-18 10:30	30,68	30,69	30,50	30,52	1.100.000
2025-08-18 10:45	30,52	30,58	30,45	30,55	950.000

A modelagem de séries temporais financeiras com aprendizado profundo avançou significativamente, com o surgimento de arquiteturas especializadas capazes de lidar com dependências complexas e padrões não estacionários. A seguir, detalham-se duas das arquiteturas mais influentes neste domínio: LSTM e Transformer.

2.2.3.1 Redes Recorrentes Long Short-Term Memory (LSTM)

As Redes Neurais Recorrentes (RNNs) foram projetadas para lidar com dados sequenciais, possuindo "loops" que permitem que a informação persista ao longo do tempo. Contudo, as RNNs tradicionais enfrentam o problema do desaparecimento do gradiente (vanishing gradient), o que as impede de aprender dependências de longo prazo, uma característica essencial para séries temporais financeiras.

Para superar essa limitação, Hochreiter e Schmidhuber (1997) propuseram a arquitetura Long Short-Term Memory (LSTM), uma variante sofisticada de RNN. A principal inovação da LSTM é sua unidade de memória, composta por um estado de célula (cell state) e três portões (gates) que regulam o fluxo de informação. O estado de célula atua como uma esteira rolante, transportando informações relevantes ao longo da sequência com poucas alterações. Os portões são estruturas neurais que, por meio de funções de ativação sigmoide, decidem qual informação deve ser adicionada ou removida do estado de célula.

A Figura 6 ilustra o funcionamento de uma célula LSTM. Seus componentes são:

- **Portão de Esquecimento (Forget Gate):** Decide qual informação do estado de célula anterior (C_{t-1}) deve ser descartada. Ele analisa a entrada atual (X_t) e o estado oculto anterior (h_{t-1}) para gerar um valor entre 0 (esquecer completamente) e 1 (manter completamente).
- **Portão de Entrada (Input Gate):** Determina quais novas informações serão armazenadas no estado de célula. Ele é composto por duas partes: uma camada sigmoide que decide quais valores serão atualizados e uma camada tanh que cria um vetor de novos valores candidatos.
- **Portão de Saída (Output Gate):** Define qual será a saída da célula. A saída é baseada no estado da célula filtrado, que passa por uma camada tanh para normalização e, em seguida, é multiplicado pela saída da camada sigmoide do portão.




Figura 6 – Arquitetura de uma célula de memória LSTM, ilustrando o estado de célula e os três portões (esquecimento, entrada e saída) que regulam o fluxo de informação. Fonte: Adaptado de (OLAH, 2015).

Essa estrutura de portões permite que a LSTM aprenda a reter informações por longos períodos, tornando-a particularmente eficaz na previsão de cotações, onde eventos passados podem influenciar significativamente os preços futuros.

2.2.3.2 Arquitetura Transformer e o Mecanismo de Atenção

Apesar de seu sucesso, as LSTMs e outras redes recorrentes possuem uma limitação inerente: seu processamento é sequencial. Isso significa que, para processar o décimo ponto de uma série, é preciso antes ter processado os nove anteriores, o que dificulta a paralelização e a captura de dependências entre pontos muito distantes na sequência.

Para resolver essas questões, (VASWANI *et al.*, 2017) introduziram a arquitetura Transformer, que abandona a recorrência e se baseia inteiramente no mecanismo de atenção (attention mechanism). A ideia central da atenção, especificamente da auto-atenção (self-attention), é permitir que o modelo pondere a importância de todas as outras posições da sequência de entrada ao processar uma única posição. Em vez de passar a informação sequencialmente, o Transformer pode "olhar" para toda a série temporal de uma só vez e identificar quais pontos do passado são mais relevantes para prever o futuro.

A arquitetura do Transformer, ilustrada na Figura 7, é composta por dois blocos principais: o Codificador (Encoder) e o Decodificador (Decoder). Seus componentes-chave incluem:

- **Auto-Atenção Multi-Cabeças (Multi-Head Self-Attention):** Em vez de calcular a atenção uma única vez, o modelo o faz múltiplas vezes em paralelo (as "cabeças"), permitindo que ele se concentre em diferentes aspectos da sequência. Por exemplo, uma cabeça pode focar na tendência de curto prazo, enquanto outra foca em padrões sazonais de longo prazo.
- **Codificação Posicional (Positional Encoding):** Como o modelo não processa os dados em ordem, a informação sobre a posição de cada ponto na sequência é adicionada aos dados de entrada. Isso garante que a ordem cronológica da série temporal seja preservada.

- **Camadas Feed-Forward:** Após as camadas de atenção, cada posição passa por uma rede neural feed-forward para processamento adicional.




Figura 7 – A arquitetura do modelo Transformer, destacando os blocos de codificador e decodificador, as camadas de atenção multi-cabeças e as redes feed-forward. Fonte: Adaptado de Vaswani et al. (2017) (VASWANI *et al.*, 2017).

A aplicação de Transformers em finanças é recente, porém bastante promissora. Modelos como o Temporal Fusion Transformer (TFT) proposto por (LIM; ZOHREN; ROBERTS, 2021), combinam múltiplas fontes de dados e camadas de atenção interpretáveis, adequando-se a dados financeiros complexos. Estudos recentes como esse, mostram que, em ambientes de alta frequência, os Transformers podem superar as LSTMs (WU *et al.*, 2020), principalmente devido à sua capacidade de modelar dependências de longo prazo de forma mais eficaz e estável.

Assim, a escolha arquitetural deve ser orientada não apenas pela natureza sequencial dos dados, mas também pelas características operacionais do mercado alvo, sendo o Transformer e suas variantes uma tendência crescente na modelagem de séries temporais financeiras.

TRABALHOS RELACIONADOS

A literatura sobre *forecasting* de séries temporais financeiras é vasta, com abordagens que evoluíram dos modelos estatísticos clássicos para arquiteturas híbridas integrando *machine learning*, redes neurais e indicadores técnicos.

3.1 Modelos Clássicos e Estatísticos

Os modelos estatísticos tradicionais, especialmente os da família ARIMA (Autoregressive Integrated Moving Average), baseiam-se na metodologia Box–Jenkins (BOX *et al.*, 2015), integrando componentes autoregressivo (AR), de média móvel (MA) e de diferenciação (I) para lidar com séries não estacionárias.

Rotela Jr. et al. (JR; OUTROS, 2014) ajustaram o modelo ARIMA para previsão usando uma longa série histórica mensal do Ibovespa (1995–2013), otimizando em relação ao erro MAPE, e obtiveram valores mais baixos, o que indica um bom ajuste nos dados agregados.

Outros estudos comparativos indicam que a precisão do ARIMA se deteriora à medida que o horizonte de previsão aumenta, enquanto outros modelos, como o LSTM, são mais robustos em cenários de janela mais longa e não lineares (SOUZA *et al.*, 2022).

A principal limitação do ARIMA reside em sua premissa de que todas as informações relevantes estão contidas em valores passados da própria série — o que ignora fontes externas, como indicadores técnicos, choques exógenos ou eventos de mercado súbitos. Além disso, sua sensibilidade a pontos de inflexão subestima impactos abruptos como crises e anúncios de política econômica — situações frequentes no contexto da B3 (B3, 2025).

Assim sendo, embora o ARIMA forneça boa interpretabilidade e seja eficiente para previsões de curto prazo em séries estacionárias, ele revela fragilidade frente à alta volatilidade, dependências não lineares e dinâmicas multivariadas típicas do mercado acionário brasileiro. Desse modo, para o ambiente da B3 — marcado por ruído, sazonalidade e eventos exógenos — esses modelos demonstram limitações relevantes que justificam a exploração de arquiteturas mais sofisticadas e híbridas.

3.2 Aprendizado de Máquina e Modelos Híbridos

Métodos de previsão híbridos unem instrumentos estatísticos tradicionais (por exemplo, ARIMA) com algoritmos de aprendizado de máquina ou aprendizado profundo (como LSTM,

XGBoost), a fim de colher os benefícios das características lineares e não lineares para dados de séries temporais financeiras.

Estes são alguns exemplos do padrão de complementação demonstrado em vários estudos recentes. Gonçalves (2023) analisou um modelo híbrido onde foram comparados modelos ARIMA e LSTM aplicados nos preços diários do índice IBX50 no Brasil, entre 2012 e 2022. ARIMA oferece boa previsão fora da amostra para o período próximo ao treinamento, mas LSTM é sempre melhor para horizontes de previsão mais longos (GONÇALVES, 2023). Já Kashif & Ślepaczuk (2024) propuseram o modelo LSTM-ARIMA, onde os resíduos gerados pelo ARIMA são incorporados como entrada adicional à LSTM, resultando em ganhos consistentes em múltiplos índices de ações globais (KASHIF MUHAMMAD E ŚLEPACZUK, 2024). Além disso, Nasir et al. (2025) introduziram uma estrutura híbrida que combina ARIMA, decomposição LMD (Local Mean Decomposition) e algoritmos clássicos de ML como XGBoost e Random Forest, demonstrando melhoria significativa em RMSE, MAE e acurácia direcional (NASIR; ZHANG; WANG, 2025).

Quanto aos resultados empíricos, Gonçalves (2023) observou que o desempenho do ARIMA diminui progressivamente conforme o horizonte de previsão se estende, enquanto o LSTM se mostra mais robusto em janelas maiores de predição (GONÇALVES, 2023). No trabalho de Kashif & Ślepaczuk, o modelo híbrido LSTM-ARIMA superou tanto o ARIMA quanto a LSTM isoladamente, alcançando métricas superiores em retorno ajustado ao risco em índices como S&P 500, FTSE 100 e CAC 40 (KASHIF MUHAMMAD E ŚLEPACZUK, 2024). Nasir et al. (2025) relataram que a combinação com LMD + XGBoost incrementou a precisão em torno de 10–15 % em comparação com modelos individuais, além de melhorar a consistência direcional das previsões (NASIR; ZHANG; WANG, 2025).

Do ponto de vista crítico, tais modelos híbridos oferecem vantagens claras, como conseguir aprender tanto as partes lineares — bem captadas pelo ARIMA — quanto as dependências temporais não lineares, padrões sazonais complexos, por meio de LSTM ou XGBoost. Contudo, apresentam alguns desafios relevantes:

- Dependência de grandes volumes de dados para treinar redes profundas, o que pode ser limitante nos ativos menos líquidos da B3.
- Complexidade computacional e necessidade de tuning rigoroso (por exemplo, validação temporal walk-forward), o que exige infraestrutura e expertise avançados.
- Risco de sobreajuste, especialmente em mercados voláteis ou com mudanças estruturais repentinas.

Como ilustra a Figura 8, aplica-se uma validação temporal do tipo walk-forward com embargo opcional h . Em cada *fold* i , o modelo é treinado apenas com dados passados e tem seus hiperparâmetros selecionados por busca bayesiana (Optuna) em uma validação interna contida no bloco de treino. Em seguida, impõe-se um período de embargo de h observações entre o fim do treino/validação e o início do conjunto de teste para mitigar vazamento de informação. O desempenho é então medido no próximo bloco temporal (*Teste* $i+1$), estritamente posterior. O procedimento se repete ao longo do tempo (folds $1, \dots, k$), produzindo uma sequência de avaliações fora da amostra; as métricas finais são agregadas sobre os blocos de teste, e o modelo pode ser retreinado no maior prefixo disponível com os hiperparâmetros selecionados. Esse protocolo é crucial para séries financeiras e, em especial, para modelos híbridos, pois respeita a causalidade temporal e reduz sobreajuste.




Figura 8 – Validação temporal walk-forward com seleção bayesiana de hiperparâmetros. Fonte: autor.

Dada a alta volatilidade, sazonalidade intradiária e nível de impacto exógeno da B3, incluindo política monetária e crises regionais (HASBROUCK, 2007; ANDERSEN; BOLLERS-LEV, 1997), modelos híbridos podem se tornar preferíveis, mas apenas com boa calibração e validação em seu próprio intervalo de tempo. Eles são superiores aos clássicos em trajetórias de médio e longo prazo e permitem captar padrões que são inalcançáveis para métodos lineares. Deve-se mostrar timidez na transformação de estratégias de investimento, avaliação de risco, estabilidade fora da amostra etc.

Em síntese, os modelos híbridos representam uma evolução lógica em relação aos modelos puramente estatísticos, conciliando interpretabilidade e robustez, e surgem como abordagem promissora para aplicações em predição de séries financeiras na B3.

3.3 Redes Neurais Profundas

As redes neurais profundas, especialmente aquelas com estrutura recorrente como as LSTM (Long Short-Term Memory), foram idealizadas por Hochreiter e Schmidhuber (HOCHREITER; SCHMIDHUBER, 1997). Essas arquiteturas superam os desafios do desvanecimento/explosão de gradiente em sequências longas por meio do “carrossel de erro” (constant error carousel), permitindo que a rede capte dependências tardias essenciais (HOCHREITER; SCHMIDHUBER, 1997).

Em aplicações financeiras, as LSTM têm sido amplamente adotadas para previsão de séries temporais não estacionárias. Estudos como Siarni-Namini & Siarni Namin (2018) demonstraram que LSTM supera ARIMA de forma consistente, reduzindo a taxa de erro em cerca de 84–87% nos dados analisados (SIARNI-NAMINI; NAMIN, 2018). Além disso, Fjellström (2022) utilizou um ensemble de LSTMs paralelos para classificação binária de movimentos de preço, obtendo resultados mais estáveis com menor volatilidade de previsão (FJELLSTRÖM, 2022).

Mais recentemente, Kabir et al. (2025) propuseram o modelo híbrido LSTM-mTrans-MLP, integrando LSTM com módulos Transformer e perceptron multicamada. Essa abordagem demonstrou desempenho robusto em diversos ativos (Bitcoin, índices chineses e ações globais), com melhorias substanciais em precisão e sensibilidade (KABIR; OUTROS, 2025).

Quanto aos resultados práticos, o trabalho original de Hochreiter & Schmidhuber (1997) mostrou que LSTM pode resolver tarefas com atrasos de tempo superiores a mil steps e aprender significativamente mais rápido que redes recorrentes tradicionais ou Elman nets ([HOCHREITER; SCHMIDHUBER, 1997](#)). No estudo de Siami-Namini, observa-se que a LSTM reduz drasticamente os erros em relação ao ARIMA — especialmente em mercados voláteis. Fjellström evidenciou que o ensemble de LSTMs reduz a variabilidade nos resultados, favorecendo previsões diretas de movimento de preço mais estáveis. Já Kabir et al. apresentaram melhoria de desempenho mesmo em mercados altamente não lineares e ruidosos ([KABIR; OUTROS, 2025](#)).

Crucialmente, as redes LSTM são uma escolha particularmente boa para séries temporais financeiras, pois podem modelar dependências não lineares e memória de longo prazo melhor do que RNNs convencionais. No entanto, elas exigem:

- **Aprendizado em Lote:** Um grande volume de dados é usado para jogar pelo seguro, porque a B3 possui valores mobiliários com baixa liquidez e o overfitting pode se tornar um problema.
- **Ajustes computacionais pesados e ajuste fino de hiperparâmetros** (portas, taxas de aprendizado, etc.) requerem uma infraestrutura robusta.
- **Risco em termos de perda de estabilidade contra dados ruidosos ou eventos exógenos inesperados.**

No contexto da B3 (alta volatilidade, sazonalidade intradiária e relação com eventos macroeconômicos), as LSTMs podem ter um bom desempenho, desde que seja utilizada validação temporal suficiente para evitar o overfitting, especialmente em um ambiente de conjunto ou com módulos Transformer.

Redes neurais profundas, especialmente LSTM e o modelo híbrido com variante Transformer mostrado neste trabalho, representam uma ampla evolução em relação aos modelos clássicos por duas razões principais: elas podem capturar relações temporais complexas a partir de grandes conjuntos de dados; e provam previsões mais estáveis em um ambiente de mercado real.

3.4 Transformers para Séries Temporais

Os modelos baseados em Transformer, originalmente propostos por Vaswani et al. (2017), têm sido adaptados para séries temporais graças ao mecanismo de atenção que captura dependências de longo alcance e interações multivariadas de forma eficiente ([WEN et al., 2022](#)).

No contexto financeiro e de séries temporais, trabalhos como Costa & Machado (2023) aplicaram o Transformer à predição de preços de ações do Ibovespa e concluíram que o modelo superou ARIMA e LSTM em cerca de 60% dos casos testados ([COSTA; MACHADO, 2023](#)). Em estudos mais gerais, Wen et al. (2022) apresentam uma revisão sistemática dos Transformers para análise temporal, destacando suas forças e limitações na parte estrutural e de aplicação ([WEN et al., 2022](#)). Outro avanço significativo foi o modelo Non-stationary Transformer (Liu et al., 2022), que propõe módulos de “series stationarization” e “de-stationary attention” para lidar eficazmente com dados não estacionários, reduzindo o MSE em até 49% em relação a outras variantes como Informer e Reformer ([LIU et al., 2022](#)).

Além disso, Nie et al. (2022) introduziram o PatchTST, que segmenta séries em "patches" temporais canal-independentes para reduzir complexidade e melhorar previsões de longo prazo, superando modelos Transformer convencionais em benchmarks públicos (NIE et al., 2023).

Os resultados empíricos demonstram que:

- Costa & Machado conseguiram maior precisão do Transformer em relação a modelos clássicos (ARIMA e LSTM) em séries do mercado brasileiro (COSTA; MACHADO, 2023).
- Liu et al. reduziram MSE em 49% comparando com Transformers tradicionais, Informer e Reformer, na tarefa de prever séries não estacionárias (LIU et al., 2022).
- Nie et al. relataram que o PatchTST oferece previsões robustas e mais acurácia em longo horizonte com menor carga computacional (NIE et al., 2023).

Sob análise crítica, os Transformers apresentam pontos fortes e limitações:

- Vantagem clara na modelagem de dependências de longo prazo e interações multivariadas sem recorrer à recursividade.
- Risco de perda de informação temporal devido à invariância à permutação na autoatenção, especialmente se o encoding posicional não for bem calibrado (ZENG et al., 2022).
- Complexidade computacional elevada, com necessidade de variantes modificadas como Informer, Autoformer ou PatchTST para tornar o modelo escalável em grandes horizontes temporais.
- Em cenários com títulos de baixa liquidez na B3, os Transformers exigem volume substancial de dados, o que pode ser desafiador.

Em síntese, os Transformers representam uma evolução promissora para o mercado da B3 pela capacidade de capturar padrões complexos e não estacionários. Entretanto, exigem adaptações específicas, validação robusta e infraestrutura computacional adequada para realmente superar métodos como LSTM e modelos híbridos em cenários reais da bolsa brasileira.

3.5 LLMs atuais aplicados a Séries Temporais Financeiras

Recentemente, os *Large Language Models* (LLMs) passaram a ser explorados como ferramentas de previsão de séries temporais financeiras, aproveitando sua capacidade de raciocínio sequencial e contextual. Em vez de operar diretamente sobre séries numéricas, esses modelos são adaptados por meio de técnicas como transformação de padrões temporais em tokens de linguagem, aprendido em poucos exemplos (*few-shot*) ou inferência sem ajuste (*zero-shot*) (ALONSO; FRANKLIN, 2024).

Um estudo conduzido por Nogueira I. Alonso & Franklin (2024/25) testou modelos como TimeGPT, NBEATS, NHITS, PatchTST e KAN em dados de ações de empresas globais (Google, Apple, Meta, entre outras), mostrando que variantes baseadas em LLMs, especialmente TimeGPT

Long Horizon, tiveram desempenho superior em cenários estáveis, enquanto modelos especializados como PatchTST se destacaram em condições mais voláteis (ALONSO; FRANKLIN, 2024).

Jiang et al. (2025), por meio do framework LLM-PS, integraram módulos de convolução multi-escala e um componente de “time-to-text”, permitindo ao LLM captar padrões semânticos e temporais de séries não estacionárias. O método obteve precisão de ponta tanto em previsões de curto quanto longo prazo, em regimes com poucos dados ou sem ajuste fino (TANG et al., 2025).

Além disso, trabalhos como LLM4TS (Chang et al., 2023) apresentaram esquema de alinhamento e fine-tuning adaptativo de LLMs pré-treinados para séries temporais, alcançando redução média de 6,8% no MSE em cenários few-shot em comparação com modelos treinados do zero (CHANG et al., 2023). Jin et al. (2023) criaram a arquitetura Time-LLM, que reprograma LLMs em tarefas de forecasting unificando prompts como prefixos, e demonstrou desempenho competitivo frente a modelos especializados, inclusive em cenários zero-shot (JIN et al., 2023).

Mais recentemente, o modelo **DeepSeek-TS+** foi proposto como uma estrutura unificada para previsão de séries multivariadas com múltiplos produtos, integrando atenção latente multi-cabeça (MLA) com uma política adaptativa de otimização por grupos (GRPO) (LI et al., 2025). Essa arquitetura apresentou ganhos significativos sobre GRUs e modelos ARMA em ambientes dinâmicos, com melhor capacidade de adaptação e robustez temporal. Em paralelo, o modelo **SMETimes**, baseado em LLMs leves com menos de 3 bilhões de parâmetros, demonstrou superioridade em relação a modelos maiores (7B), tanto em desempenho quanto em economia de recursos, sugerindo que arquiteturas otimizadas podem ser mais eficazes em contextos como o da B3 (FAN; OUTROS, 2025).

Os resultados indicam que:

- LLMs são eficazes em cenários com poucos dados (few-shot ou zero-shot), sendo úteis quando séries são curtas ou ativos têm baixa liquidez.
- Frameworks como LLM-PS e LLM4TS aprimoram o modelo com módulos que capturam padrões temporais e escrevem sequências numéricas em linguagem natural, resultando em previsão mais contextualizada.
- Modelos como Time-LLM e DeepSeek-TS+ oferecem versatilidade e capacidade adaptativa robusta, inclusive em cenários com múltiplas variáveis e dinâmicas não lineares.
- LLMs otimizados, como o SMETimes, viabilizam previsões precisas com menor custo computacional — um diferencial importante em aplicações reais.

Embora essas abordagens mostrem potencial sob escrutínio, elas também apresentam algumas deficiências:

- A conversão de dados numéricos em linguagem pode criar abstração de informações e perda de precisão sem a tokenização adequada.
- O desempenho tende a decair em séries sem padrão claro (ruído elevado, ausência de sazonalidade ou tendência), conforme evidenciado por Tang et al. (2024) (TANG; OUTROS, 2024).

- Extrapolar para alta frequência, uma característica comum do B3, exige uma reformulação em grande escala do pipeline de tokenização e das representações temporais.

Em conclusão, os LLMs otimizados fundidos e de cabeça dupla com módulos dinâmicos temporais especializados podem refletir um método promissor para o tipo de problema 3 com desequilíbrio extremo censurado e dados de séries temporais esparsas que poderiam ser complementares às abordagens típicas e híbridas ao lidar com o B3.

3.6 Síntese Crítica

Ao revisar os trabalhos relacionados, observa-se que a literatura documenta uma evolução das abordagens de previsão de séries financeiras, indo de modelos estatísticos clássicos a arquiteturas profundas e híbridas. Modelos tradicionais como a família ARIMA permanecem relevantes pela interpretabilidade e pelo desempenho observado em séries aproximadamente estacionárias (BOX *et al.*, 2015; HYNDMAN; ATHANASOPOULOS, 2018; JR; OUTROS, 2014). Por outro lado, há relatos de limitações quando a dinâmica é fortemente não linear, multivariada ou sujeita a mudanças de regime e elevada volatilidade (MAKRIDAKIS; SPILIOTIS; ASSIMAKOPOULOS, 2018; DERBENTSEV, 2020).

Abordagens híbridas que combinam modelos estatísticos com técnicas de aprendizado de máquina e profundo têm sido associadas, em determinados cenários, a ganhos de robustez e desempenho fora da amostra, ao custo de maior complexidade de modelagem e sensibilidade a hiperparâmetros (GONÇALVES, 2023; KASHIF MUHAMMAD E ŚLEPACZUK, 2024; NASIR; ZHANG; WANG, 2025). A literatura também recomenda validação temporal cuidadosa (por exemplo, esquemas específicos para séries) e procedimentos sistemáticos de ajuste para mitigar sobreajuste (BERGMEIR; BENÍTEZ, 2012; PRADO, 2018; AKIBA *et al.*, 2019).

No campo das redes neurais, LSTM e variantes correlatas têm sido empregadas para capturar dependências de longo prazo e padrões não lineares em séries financeiras, com resultados competitivos em diferentes horizontes de previsão (HOCHREITER; SCHMIDHUBER, 1997; SIAMI-NAMINI; NAMIN, 2018; FJELLSTRÖM, 2022). Há ainda propostas de ensembles e modelos híbridos que integram módulos recorrentes e atencionais (KABIR; OUTROS, 2025). Em termos práticos, a necessidade de dados e de recursos computacionais pode ser um fator restritivo em ativos de baixa liquidez, aspecto discutido na literatura de microestrutura e liquidez (AMIHUD, 2002).

Arquiteturas baseadas em *Transformers* vêm sendo adaptadas ao domínio temporal e reportam resultados competitivos em horizontes longos e séries multivariadas, incluindo estudos no contexto brasileiro (WEN *et al.*, 2022; COSTA; MACHADO, 2023). Diversas variantes propõem mecanismos de estabilização e estratégias para lidar com não estacionariedade e eficiência computacional, como módulos de “stationarization” e atenção modificada (LIU *et al.*, 2022) ou segmentação em *patches* temporais (NIE *et al.*, 2023). Ao mesmo tempo, análises críticas questionam condições em que tais modelos de atenção superam abordagens alternativas, sugerindo cautela na generalização de resultados (ZENG *et al.*, 2022).

Mais recentemente, modelos de linguagem de grande escala (LLMs) foram explorados como apoio à previsão de séries temporais por meio de reprogramação de tarefas, *few-shot* e integrações que capturam padrões semânticos e temporais (LATHUILÈRE *et al.*, 2024; CHANG *et al.*, 2023; JIN *et al.*, 2023; ALONSO; FRANKLIN, 2024; TANG *et al.*, 2025). A literatura também discute sensibilidades relacionadas à tokenização, alinhamento temporal e custos compu-

tacionais, recomendando atenção a limitações e preferências dos modelos nessas tarefas (TANG; OUTROS, 2024).

Em síntese, os estudos revisados não apontam consenso em torno de um modelo único e universalmente superior para os desafios de previsão no mercado acionário, especialmente em ambientes voláteis e sujeitos a eventos exógenos (MAKRIDAKIS; SPILIOTIS; ASSIMAKOPOULOS, 2018; WEN *et al.*, 2022). Nesse cenário, linhas de pesquisa sobre soluções híbridas e adaptativas aparecem como promissoras para conciliar interpretabilidade, flexibilidade e desempenho. Este trabalho, portanto, investigará uma abordagem que integra paradigmas estatístico, profundo e atencional, com foco em estabilidade, precisão e aplicabilidade prática a cenários representativos do mercado brasileiro.

Para uma visão de conjunto dos grupos de modelos discutidos, ver as Tabelas 2 a 5.

Tabela 2 – Método vs. Dados exigidos. Fonte: o autor.

Método	Dados exigidos
Modelos estatísticos (ARIMA/ARIMAX)	Série univariada; estacionária (ou diferenciada); histórico razoável (100–300+ pontos); regressores opcionais via ARIMAX.
LSTM	Muitos dados; normalização; janelas de <i>lookback</i> ; <i>tuning</i> de hiperparâmetros.
Transformers (PatchTST, Non-stationary)	Janelas longas; multivariadas; melhor com grande volume de dados. <i>Patching</i> reduz <i>tokens</i> ; módulos de estacionarização ajudam.
Híbridos (ARIMA+LSTM; LMD+XGBoost)	Dados para ambos os blocos; etapas de decomposição e resíduos; <i>pipeline</i> mais complexo.
LLMs s/ séries (Time-LLM, LLM4TS, Zero-shot)	Pré-processo <i>time-to-text/prompting</i> ; poucos dados funcionam (few/zero-shot); sem treino pesado.

Tabela 3 – Método vs. Custo computacional. Fonte: o autor.

Método	Custo computacional
Modelos estatísticos (ARIMA/ARIMAX)	Baixo (CPU). Ajuste Box–Jenkins/auto-ARIMA.
LSTM	Médio–alto (GPU recomendável).
Transformers (PatchTST, Non-stationary)	Alto (atenção quadrática). Variantes reduzem custo.
Híbridos (ARIMA+LSTM; LMD+XGBoost)	Alto (múltiplos modelos/etapas).
LLMs s/ séries (Time-LLM, LLM4TS, Zero-shot)	Alto na inferência; baixo/zero custo de treino adicional; modelos menores mitigam.

Tabela 4 – Método vs. Pontos fortes. Fonte: o autor.

Método	Pontos fortes
Modelos estatísticos (ARIMA/ARIMAX)	Interpretável; bom curto prazo; <i>baseline</i> sólido.
LSTM	Capta dependências longas e não-linearidades; bom para múltiplas <i>features</i> /indicadores.
Transformers (PatchTST, Non-stationary)	Modela dependências de longo alcance; bom em horizontes longos e séries multivariadas.
Híbridos (ARIMA+LSTM; LMD+XGBoost)	Combina linear e não-linear; ganhos consistentes em métricas e acurácia direcional.
LLMs s/ séries (Time-LLM, LLM4TS, Zero-shot)	Generalizam com pouco dado; integram sinais textuais (notícias) e numéricos.

Tabela 5 – Método vs. Fragilidades. Fonte: o autor.

Método	Fragilidades
Modelos estatísticos (ARIMA/ARIMAX)	Não-linearidades e quebras de regime; piora em horizontes longos; multivariadas limitadas.
LSTM	Exige dados; risco de <i>overfitting</i> ; sensível a mudanças de regime sem validação temporal.
Transformers (PatchTST, Non-stationary)	Custo elevado; risco de má codificação temporal; debate sobre ganhos vs. modelos lineares simples.
Híbridos (ARIMA+LSTM; LMD+XGBoost)	Complexidade; <i>tuning</i> pesado; risco de sobreajuste; manutenção mais difícil.
LLMs s/ séries (Time-LLM, LLM4TS, Zero-shot)	Tokenização pode perder precisão; maturidade menor; desempenho cai em ruído extremo/alta frequência.

PRÓXIMOS PASSOS

Este capítulo detalha os procedimentos que serão adotados para desenvolver e avaliar o modelo de predição de séries temporais financeiras proposto. Os próximos passos foram estruturados em cinco etapas principais: 1) Aquisição e Descrição dos Dados; 2) Pré-processamento e Engenharia de Atributos; 3) Arquitetura dos Modelos; 4) Desenho Experimental e Treinamento; e 5) Métricas de Avaliação.




Figura 9 – Guia adotado para construção de modelo. Fonte: o autor.

4.1 Aquisição e Descrição dos Dados

A seleção e a qualidade dos dados são determinantes para previsões intradiárias confiáveis. Para mitigar vieses comuns, adotamos três diretrizes: controle de survivorship bias, ajustes corporativos e consistência temporal. Para evitar vazamentos de informação entre janelas e avaliar desempenho de forma realista, estruturamos o histórico em partições temporais sequenciais com embargo entre treino e teste, conforme práticas recomendadas para séries financeiras (PRADO, 2018; BERGMEIR; BENÍTEZ, 2012). Além disso, respeitamos regras operacionais e fases de negociação da B3 ao longo do período analisado (B3, 2025).

- **Ativos:** Selecionamos um conjunto fixo de ações líquidas negociadas na B3 (ex.: PETR4, VALE3, ITUB4), mantido constante ao longo de todo o período (2020–2025) ou, alternativamente, utilizamos a composição histórica do Ibovespa por janelas mensais, preservando a representatividade de mercado. Liquidez reduz *spreads* e *gaps*, diminui *slippage* e tende a estabilizar métricas em *backtests*.
- **Ajustes e integridade:** As séries são ajustadas por desdobramentos e **grupamentos** (*reverse splits*) e por proventos (dividendos/JCP/bonificações). Conferimos fuso horário e horários de pregão; removemos barras com registros anômalos (preço/volume ausentes, zeros ou *spikes* espúrios). Para reduzir efeitos de microestrutura — como *bid–ask bounce* e periodicidades intradiárias — empregamos banda morta na rotulagem e checagens de consistência (HASBROUCK, 2007; ANDERSEN; BOLLERSLEV, 1997).
- **Período e frequência:** Utilizamos barras de 15 minutos entre janeiro/2020 e julho/2025. Realizamos análise de sensibilidade em 5m e 30m para avaliar robustez à granularidade, conciliando captação da dinâmica intradiária com redução do ruído de alta frequência (ANDERSEN; BOLLERSLEV, 1997).
- **Fontes:** Dados obtidos junto à B3/fornecedores com histórico consolidado e *timestamping* consistente (B3, 2025a).

4.2 Pré-processamento e Engenharia de Atributos

- **Normalização:** Aplicamos *Min–Max* (ou *Z–Score* em análise de sensibilidade), ajustada exclusivamente no conjunto de treino de cada etapa do *walk-forward* para evitar *data leakage*. O mesmo procedimento vale para quaisquer transformações ou imputações (PRADO, 2018; BERGMEIR; BENÍTEZ, 2012).
- **Criação de atributos:** Além de OHLCV, calculamos: (i) retornos logarítmicos e variações de volume; (ii) amplitude *high–low* e medidas de volatilidade móvel; (iii) indicadores consagrados como MME 9/21/50, Bandas de Bollinger e RSI, que auxiliam na captura de padrões locais e regimes de volatilidade (BOLLINGER, 2001; MURPHY, 1999).

4.3 Arquitetura dos Modelos

Adotamos uma abordagem que combina modelos de referência e arquiteturas modernas, em ordem crescente de complexidade, viabilizando comparações consistentes. A seleção foi guiada por literatura de previsão de séries temporais e pelas particularidades da negociação

eletrônica na B3, onde frequência dos dados, fases do pregão e tipos de ordens afetam a formação de preços (B3, 2025; HYNDMAN; ATHANASOPOULOS, 2018; BOX *et al.*, 2015; TAYLOR; LETHAM, 2018; HOCHREITER; SCHMIDHUBER, 1997; BOROVYKH; BOHTE; OOSTERLEE, 2017).

- **Naive / Drift (Baseline 0):** Regras simples (repetir a direção da última barra; regressão linear curta) para estabelecer piso de desempenho.
- **ARIMA (Baseline 1):** Modelo estatístico para dependências lineares; parâmetros (p, d, q) identificados via ACF/PACF, seguindo o procedimento Box–Jenkins (BOX *et al.*, 2015).
- **Prophet (Baseline 2):** Referência para sazonalidades diárias/semanais; incluído de forma crítica dado o contexto intradiário de 15m (TAYLOR; LETHAM, 2018).
- **LSTM Puro (Baseline 3):** Duas camadas LSTM empilhadas seguidas de camada densa para previsão; adequado a dependências de longo prazo (HOCHREITER; SCHMIDHUBER, 1997).
- **Híbrido CNN–LSTM (Proposta):** Convoluções 1D extraem padrões locais na janela temporal; camadas LSTM capturam dependências de maior alcance. A saída sigmoide gera probabilidade de alta no próximo intervalo, buscando equilibrar movimentos bruscos e tendências persistentes (BOROVYKH; BOHTE; OOSTERLEE, 2017).

4.4 Desenho Experimental e Treinamento

- **Validação *walk-forward*:** Dividimos o histórico em blocos sequenciais. Em cada etapa, treinamos no bloco k e avaliamos em $k+1$, aplicando **embargo temporal** de h barras (com h igual ao horizonte de previsão) para reduzir dependências geradas por janelas sobrepostas/rotulagem próxima (PRADO, 2018; BERGMEIR; BENÍTEZ, 2012). O processo se repete até o fim da série.
- **Seleção de hiperparâmetros:** Em cada etapa do *walk-forward*, realizamos otimização bayesiana (*Optuna*) no conjunto de validação interno para janela N , filtros da CNN, unidades LSTM, *dropout*, *learning rate* etc.; o melhor conjunto é re-treinado no bloco k e aferido em $k+1$ (AKIBA *et al.*, 2019).
- **Treinamento e estabilidade:** Utilizamos AdamW, *early stopping*, *gradient clipping* e *schedulers* (*one-cycle/cosine*). Fixamos sementes e versionamos dependências para reprodutibilidade (LOSHCHILOV; HUTTER, 2019).
- **Função de custo:** *Binary Cross-Entropy* para classificação probabilística da direção.
- **Ambiente:** Python 3.12; TensorFlow/Keras; Pandas/Scikit-learn.

4.5 Métricas de Avaliação

- **Acurácia direcional (foco):** Métrica alinhada à decisão prática (comprar/vender), com *banda morta* para amortecer ruído de microestrutura (HASBROUCK, 2007).

- **Qualidade probabilística:** *Brier Score* e *Log-Loss* capturam calibração e discriminação; curvas de confiabilidade (ECE) avaliam calibração global (BRIER, 1950; GUO *et al.*, 2017). Balanced Accuracy, F1-score e MCC auxiliam quando há desequilíbrio entre classes.
- **Métricas de trading:** Retorno líquido, índice de Sharpe e *max drawdown* quantificam impacto após custos e *slippage* (SHARPE, 1994).

A métrica principal é a **acurácia direcional** (*hit rate*) após banda morta. Para refletir qualidade probabilística e possível desbalanceamento, reportamos: Brier Score, Log-Loss, Balanced Accuracy, F1, MCC e AUC-PR; avaliamos **calibração** via curvas de confiabilidade (ECE). Para utilidade prática, executamos *backtests* simples (entrada/saída) com custos de transação e *slippage* explícitos, reportando retorno líquido, Sharpe, *max drawdown* e *profit factor*.

4.5.1 Backtests e Custos de Transação

Executamos *backtests long-only* e *long/short* condicionados às probabilidades previstas e a limiares calibrados. Custos fixos e proporcionais (corretagem, emolumentos) e *slippage* são descontados; também reportamos *turnover* e sensibilidade a custos (análise de estresse), em conformidade com as práticas e estruturas de custos divulgadas pela B3 (B3, 2025a).

4.5.2 Testes de Robustez e Significância

Comparamos a série de perdas/erros do modelo proposto contra os *baselines* por meio do teste de Diebold–Mariano, avaliando significância de diferenças de acurácia direcional e Brier. Segmentamos resultados por regimes de volatilidade (calmaria vs. choques) para verificar estabilidade (DIEBOLD; MARIANO, 1995).

4.5.3 Reprodutibilidade

Todo o fluxo é versionado (dados, código e artefatos). Publicamos scripts executáveis (`prepare_data.py`, `train.py`, `evaluate.py`, `backtest.py`) com sementes fixas e manifesto de dependências, permitindo replicação e extensão dos experimentos.

4.6 Ameaças à Validade

- **Qualidade de dados:** Inconsistências de *timestamp* ou *spikes* podem afetar métricas; mitigamos com filtros, ajustes e checagens de integridade.
- **Vazamento de informação:** Evitado com ajuste exclusivamente no treino, validação *walk-forward* e embargo temporal (PRADO, 2018; BERGMEIR; BENÍTEZ, 2012).
- **Seleção de ativos:** O viés de sobrevivência é mitigado ao fixar universo ou usar composição histórica do índice.
- **Sobreajuste de hiperparâmetros:** Otimização aninhada e regularização (*dropout*, *weight decay*) reduzem risco; relatamos sensibilidade.

4.7 Cronograma PFC2

O cronograma de execução do PFC2 foi elaborado com base nos próximos passos definidos no projeto, distribuindo as atividades em etapas mensais de setembro de 2025 a janeiro de 2026. A Tabela abaixo apresenta as principais tarefas, os períodos de realização e os entregáveis correspondentes.

Tabela 6 – Cronograma de Execução do PFC2 (Set/2025–Jan/2026)

Etapa (conforme Próximos Passos)	Set	Out	Nov	Dez	Jan/26	Entregáveis / Marcos
Aquisição e auditoria de dados (2020–2025, 15m); ajustes corporativos; integridade temporal	X					Dataset auditado; checklist de integridade; universo de ativos definido.
Pré-processamento e engenharia de atributos (retornos log, vol. móvel, MME 9/21/50, RSI, Bollinger)		X				
Particionamento e desenho experimental (<i>walk-forward</i> , embargo temporal, seeds, versionamento)		X				Folds definidos; protocolo de avaliação documentado; ambiente reprodutível.
Baselines: Naive/Drift, ARIMA, Prophet (execução nos 1–2 primeiros blocos)		X				Relatório curto com desempenho por bloco.
Modelo proposto (CNN–LSTM) e LSTM puro: implementação, treino e <i>tuning</i> por bloco			X			‘train.py’/‘evaluate.py’ funcionais; logs de hiperparâmetros.
Avaliação preditiva: hit rate (banda morta), Brier, Log-Loss, Balanced Acc., F1, MCC, AUC-PR; calibração (ECE)			X			Tabela consolidada por modelo/fold; curvas de confiabilidade.
Backtests (long-only e long/short) com custos e <i>slippage</i> ; sensibilidade a custos e <i>turnover</i>			X	X		‘backtest.py’; relatório operacional (retorno, Sharpe, drawdown).
Robustez e significância: Diebold–Mariano; regimes de volatilidade; sensibilidade (5/30m)				X		Tabelas de p-valores; gráficos por regime; nota técnica.
Reprodutibilidade: manifesto de dependências; organização de repositório/artefatos; README executável				X	X	Repositório final organizado; scripts e experimentos replicáveis.
Redação de Resultados, Discussão e Ameaças à Validade				X	X	Capítulos redigidos com figuras e tabelas; limitações descritas.

Etapas (conforme Próximos Passos)	Set	Out	Nov	Dez	Jan/26	Entregáveis / Marcos
Revisão ABNT (citações/refs, listas, numeração) e formatação final					X	Checklist ABNT concluído; PDF final para submissão.
Entrega e preparação para defesa (slides, roteiro, ensaio)					X	Slides prontos; ensaio cronometrado; materiais anexos.

CONSIDERAÇÕES FINAIS

O trabalho até aqui forneceu uma definição sistemática de escopo, objetivos e planejamento metodológico para uma tarefa de previsão direcional intradiária na B3, especificamente em uma proposta forte para uma avaliação completa e reproduzível. O principal objetivo foi fornecer um protocolo sensível ao tempo que não vazze informações e represente melhor o uso real com custos e slippage. Para alcançar isso, o plano integrou:

- i. construção do banco de dados intradiário;
- ii. configuração experimental com janelas deslizantes e validação cruzada walk-forward com embargo temporal;
- iii. comparação de linhas de base (por exemplo, ARIMA e LSTM) com as redes propostas;
- iv. definição de métricas relacionadas à tomada de decisão;
- v. backtests usando custos explícitos;
- vi. testes de robustez e significância; e
- vii. reprodutibilidade, por meio de versionamento e scripts executáveis.

Quanto à base teórico-empírica agora consolidada, o artigo fundamentou-se na dinâmica intradiária (liquidez, volatilidade, volume) e microestrutura, e na decisão de introduzir uma banda morta (positiva) para mitigar ruídos na estimativa da precisão direcional. A revisão apresentou a evolução dos modelos, começando pelos clássicos (como a família ARIMA, modelos Box-Jenkins) até métodos de aprendizado profundo (LSTM, CNN) e arquiteturas contemporâneas com mecanismos de atenção, apontando as limitações de modelos puramente lineares em ambientes não estacionários e na presença de choques, e os ganhos de modelos que lidam com dependência de longo prazo. Além disso, foi mencionada a relevância dos Transformers para séries financeiras multivariadas e de alta frequência, como o TF-T, e algumas evidências de ganhos sobre o LSTM no RMSE e precisão direcional são encontradas sob tamanho de janela longo. O estudo também empregou um modelo híbrido LSTM+CNN como referência para capturar características temporais e locais das características intradiárias, consistente com a intenção de generalidade em vários ambientes de volatilidade.

Para avaliação, uma gama de métricas de decisão e probabilidade foi incluída: precisão direcional com folga (foco principal), qualidade probabilística (Brier Score, Log-Loss e ECE)

e medidas de equilíbrio (Balanced Accuracy, F1, MCC, AUC-PR). A validação econômica foi adicionada com backtests com custo e slippage em Peso, retornando retorno líquido, índice de Sharpe, máximo drawdown e fator de lucro de acordo com estruturas operacionais e custos divulgados pela B3. A significância da diferença entre os modelos será examinada através da estatística de Diebold–Mariano, onde a análise é segmentada de acordo com regimes de volatilidade para garantir a robustez da comparação. Por fim, a reprodutibilidade foi garantida pelo versionamento completo de dados, código, artefatos e seeds com scripts de ponta a ponta para preparar, treinar, avaliar e realizar backtests.

A motivação do tema surge do fato de que observamos consistentemente o desempenho em laboratório e o desempenho no piso em desacordo um com o outro em um mundo intradiário ruidoso com custos. O plano metodológico tenta reduzir essa lacuna integrando walk-forward com prevenção de vazamento de embargo, métricas orientadas para decisão e backtests pós-custo e entregar critérios de validação mais robustos enquanto preserva a possibilidade de generalização entre ativos e estados de mercado. As ameaças à validade (qualidade dos dados, viés de sobrevivência, divisões temporais) e mitigadores de resultados também foram claramente declarados, aumentando a confiabilidade do desenho experimental.

Para concluir, as ações subsequentes, explicadas no Capítulo de próximos passos – posse/limpeza dos dados intradiários, pré-processamento de dados e geração de características, configuração de arquiteturas (linhas de base e propostas), definição do espaço de busca de hiperparâmetros, protocolo de treino/validação walk-forward com embargo e avaliações de métricas e backtests com testes de robustez e significância – são o elo imediato para o PFC2. Realizar essas etapas na próxima fase torna possível (1) realizar os experimentos sob controles claros, (2) comparar os diferentes modelos de forma estatisticamente significativa, (3) relatar os resultados de forma tão transparente e reprodutível quanto desejado, fechando o ciclo metodológico conforme pretendido neste trabalho.

REFERÊNCIAS

AKIBA, T.; SANO, S.; YANASE, T.; OHTA, T.; KOYAMA, M. Optuna: A next-generation hyperparameter optimization framework. In: **KDD**. [S.l.: s.n.], 2019. Citado nas páginas 31 e 37.

ALONSO, M. N. I.; FRANKLIN, R. P. Large language models for financial time series forecasting. **SSRN Working Paper**, 2024. Testados modelos LLM e especialistas como PatchTST, TimeGPT em dados de ações globais. Citado nas páginas 7, 29, 30 e 31.

AMIHUD, Y. Illiquidity and stock returns: Cross-section and time-series effects. **Journal of Financial Markets**, v. 5, n. 1, p. 31–56, jan. 2002. Citado nas páginas 5, 19 e 31.

ANDERSEN, T. G.; BOLLERSLEV, T. Intraday periodicity and volatility persistence in financial markets. **Journal of Empirical Finance**, v. 4, n. 2–3, p. 115–158, jun. 1997. Citado nas páginas 5, 7, 8, 9, 18, 19, 27 e 36.

B3. **Manual de Procedimentos Operacionais de Negociacao da B3 — versao 17/02/2025**. 2025. <<https://www.b3.com.br/data/files/55/65/B5/7D/AC31591029BEEC39AC094EA8/MPO%20de%20Negociacao%20da%20B3.pdf>>. Acesso em: ago. 2025. Citado nas páginas 8, 14, 18, 25, 36 e 37.

B3. **Produtos e Serviços — B3**. 2025. <https://www.b3.com.br/pt_br/produtos-e-servicos/>. Acesso em: ago. 2025. Citado nas páginas 14, 36 e 38.

B3. **Quem Somos — B3**. 2025. Acesso em: ago. 2025. Disponível em: <https://www.b3.com.br/pt_br/b3/institucional/quem-somos/>. Citado nas páginas 5, 13 e 14.

B3. **B3 — Brasil, Bolsa, Balcão**. s.d. Acesso em: 7 ago. 2025. Disponível em: <<https://www.b3.com.br/>>. Citado na página 13.

BANK, W. **Global Economic Prospects: Slow Growth, Policy Challenges**. [S.l.], 2020. Disponível em: <<https://documents1.worldbank.org/curated/en/494581578977519941/pdf/Global-Economic-Prospects-Slow-Growth-Policy-Challenges.pdf>>. Citado nas páginas 5, 6 e 14.

BERGMEIR, C.; BENÍTEZ, J. M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. Acesso em 04 Ago 2025. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S0020025511006773>>. Citado nas páginas 9, 20, 31, 36, 37 e 38.

BODIE, Z.; KANE, A.; MARCUS, A. J. **Investments**. 12. ed. [S.l.]: McGraw-Hill Education, 2021. ISBN 978-1260775156. Citado nas páginas 5, 6, 15 e 17.

BOLLINGER, J. **Bollinger on Bollinger Bands**. New York: McGraw-Hill, 2001. ISBN 978-0071386739. Citado nas páginas 16 e 36.

- BOROVYKH, A.; BOHTE, S.; OOSTERLEE, C. W. **Conditional Time Series Forecasting with Convolutional Neural Networks**. 2017. Disponível em: <<https://arxiv.org/abs/1703.04691>>. Citado na página 37.
- BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. **Time Series Analysis: Forecasting and Control**. 5. ed. [S.l.]: Wiley, 2015. ISBN 9781118675021. Citado nas páginas 6, 9, 25, 31 e 37.
- BRASIL. **Lei nº 6.385, de 7 de dezembro de 1976 (Mercado de Valores Mobiliários e CVM)**. 1976. Acesso em: 7 ago. 2025. Disponível em: <http://www.planalto.gov.br/ccivil_03/leis/l6385.htm>. Citado nas páginas 5 e 13.
- BRASIL. **Lei nº 6.404, de 15 de dezembro de 1976 (Lei das Sociedades por Ações)**. 1976. Acesso em: 7 ago. 2025. Disponível em: <http://www.planalto.gov.br/ccivil_03/leis/l6404consol.htm>. Citado nas páginas 5, 13 e 15.
- BRIER, G. W. Verification of forecasts expressed in terms of probability. **Monthly Weather Review**, v. 78, n. 1, p. 1–3, 1950. Citado nas páginas 9 e 38.
- CAMPBELL, J. Y.; LO, A. W.; MACKINLAY, A. C. **The Econometrics of Financial Markets**. Princeton, NJ: Princeton University Press, 1997. Citado na página 18.
- CHANG, C.; WANG, W.-Y.; PENG, W.-C.; CHEN, T.-F. Llm4ts: Aligning pre-trained llms as data-efficient time-series forecasters. **arXiv preprint**, 2023. Citado nas páginas 7, 30 e 31.
- COSTA, L. D.; MACHADO, A. M. C. Prediction of stock price time series using transformers. **Revista Brasileira de Aprendizado de Máquina e Inteligência Artificial**, 2023. Aplicado a ações do Ibovespa em 2008. Citado nas páginas 28, 29 e 31.
- DACOROGNA, M. M.; GENÇAY, R.; MÜLLER, U. A.; OLSEN, R. B.; PICTET, O. V. **An Introduction to High-Frequency Finance**. San Diego, CA: Academic Press, 2001. ISBN 9780122796715. Citado nas páginas 7 e 18.
- DAYCOVAL. **Índices de mercado: o que são e como utilizar**. 2024. Blog Daycoval. Acesso em 31 de julho de 2025. Disponível em: <<https://blog.daycoval.com.br/indices-de-mercado-o-que-sao/>>. Citado na página 15.
- DERBENTSEV, V. Machine learning approaches for financial time series forecasting. **Epj Data Science**, 2020. Citado na página 31.
- DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. **Journal of Business & Economic Statistics**, v. 13, n. 3, p. 253–263, 1995. Citado nas páginas 9 e 38.
- DING, G.; QIN, L. Study on the prediction of stock price based on the associated network model of lstm. **International Journal of Machine Learning and Cybernetics**, v. 11, n. 6, p. 1307–1317, 2020. Citado nas páginas 6, 7 e 8.
- DUFOUR, A.; ENGLE, R. F. Time and the price impact of a trade. **Journal of Finance**, v. 55, n. 6, p. 2467–2498, dez. 2000. Citado nas páginas 5, 8 e 19.
- ENGLE, R. F.; RUSSELL, J. R. Autoregressive conditional duration: A new model for irregularly spaced transaction data. **Econometrica**, v. 66, n. 5, p. 1127–1162, 1998. Citado nas páginas 5, 7, 8 e 19.

- FABOZZI, F. J.; MODIGLIANI, F. **Capital Markets: Institutions and Instruments**. 4. ed. Upper Saddle River, NJ: Pearson Prentice Hall, 2009. ISBN 978-0136026020. Citado nas páginas 5, 14 e 15.
- FAN, Y.; OUTROS. Smetimes: Efficient large language models for time series forecasting. **arXiv preprint arXiv:2503.03594**, 2025. Citado na página 30.
- FJELLSTRÖM, C. Long short-term memory neural network for financial time series. **arXiv preprint arXiv:2201.08218**, 2022. Citado nas páginas 27 e 31.
- GIACOMEL, F. dos S. **Um Método Algorítmico para Operações na Bolsa de Valores Baseado em Ensembles de Redes Neurais para Modelar e Prever os Movimentos dos Mercados de Ações**. Dissertação (Dissertação de Mestrado) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2016. Orientadora: Profa. Dra. Renata Galante. Citado nas páginas 1 e 18.
- GOEL, R.; WANG, S.; FELDMAN, S.; MADDOX, W. TimesFM: Foundation models for probabilistic time series forecasting. **Journal of Machine Learning Research**, v. 26, n. 54, p. 1–36, 2025. Disponível em: <<http://jmlr.org/papers/v26/24-054.html>>. Citado na página 7.
- GONÇALVES, R. S. **O impacto do horizonte de previsão em modelos ARIMA e LSTM aplicados ao IBX50**. Dissertação (Mestrado) — Universidade Estadual de Campinas, Campinas, SP, 2023. Disponível em: <<https://repositorio.unicamp.br/handle/REPOSIP/377123>>. Acesso em: ago. 2025. Citado nas páginas 26 e 31.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: **ICML**. [S.l.: s.n.], 2017. Citado nas páginas 9 e 38.
- HAMILTON, J. D. A new approach to the economic analysis of nonstationary time series and the business cycle. **Econometrica**, v. 57, n. 2, p. 357–384, 1989. Citado na página 20.
- HASBROUCK, J. **Empirical Market Microstructure: The Institutions, Economics, and Econometrics of Securities Trading**. [S.l.]: Oxford University Press, 2007. ISBN 978-0-19-530164-9. Citado nas páginas 5, 7, 8, 9, 19, 27, 36 e 37.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. Citado nas páginas 27, 28, 31 e 37.
- HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: Principles and Practice**. 2. ed. OTexts, 2018. 2nd ed. Disponível em: <<https://otexts.com/fpp2/>>. Citado nas páginas 6, 9, 19, 31 e 37.
- JIN, M.; WANG, S.; MA, L.; CHU, Z.; ZHANG, J. Y.; SHI, X.; CHEN, P.-Y.; LIANG, Y.; LI, Y.-F.; PAN, S.; WEN, Q. Time-llm: Time series forecasting by reprogramming large language models. **arXiv preprint**, 2023. Citado nas páginas 7, 30 e 31.
- JR, P. R.; OUTROS. Modelo arima aplicado à previsão do índice bovespa. **Open Journal of Statistics**, Scientific Research, v. 4, n. 5, p. 319–324, 2014. Citado nas páginas 7, 9, 25 e 31.
- JUNIOR, M. M. d. O. L. **Proposta de um modelo de predição da bolsa de valores utilizando uma abordagem híbrida**. Dissertação (Dissertação de Mestrado) — Universidade Federal do Maranhão, São Luís, 2013. Citado na página 7.
- KABIR, M. R.; OUTROS. Lstm-mtrans-mlp: Hybrid deep learning ensemble for financial time series forecasting. **Information**, 2025. Citado nas páginas 27, 28 e 31.

KASHIF MUHAMMAD E ŚLEPACZUK, R. Lstm-arima hybrid model for stock market forecasting: A multi-index evaluation. **Expert Systems with Applications**, v. 233, p. 120992, 2024. Citado nas páginas 26 e 31.

LATHUILÈRE, B.; DROIT, A.; IDRISSE, N.; PEZESHKI, M. TimeGPT: Few-shot forecasting with large language models. In: **Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)**. [S.l.: s.n.], 2024. Poster. Citado nas páginas 7 e 31.

LEONUNESBIO. **Introdução à Análise de Séries Temporais: como esses modelos são usados para responder questões ambientais?** 2014. Acessado em: 17/08/2025. Citado nas páginas 1 e 6.

LI, Z. *et al.* Deepseek-ts+: A unified framework for multi-product time series forecasting. **Towards AI**, 2025. <<https://pub.towardsai.net/deepseek-ts-a-unified-framework-for-multi-product-time-series-forecasting-da4932ce6022>>. Citado na página 30.

LIANG, K.; ZHANG, Y.; LIU, X.; XU, W. Hidformer: Dual-tower hypergraph transformer for multimodal stock prediction. In: **Proceedings of the 44th International Conference on Machine Learning (ICML 2025)**. [S.l.: s.n.], 2025. p. 12245–12260. Citado na página 7.

LIM, B.; ZOHREN, S.; ROBERTS, S. Temporal fusion transformers for interpretable multi-horizon time series forecasting. **International Journal of Forecasting**, Elsevier, v. 37, n. 4, p. 1748–1764, 2021. Citado nas páginas 7 e 23.

LIU, Y.; WU, H.; WANG, J.; LONG, M. Non-stationary transformers: Exploring the stationarity in time series forecasting. **arXiv preprint**, 2022. Citado nas páginas 7, 28, 29 e 31.

LO, A. W. **Adaptive Markets: Financial Evolution at the Speed of Thought**. Princeton, NJ: Princeton University Press, 2017. ISBN 978-0-691-15319-1. Citado na página 5.

London Stock Exchange. **London Stock Exchange (LSE)**. s.d. Acesso em: 7 ago. 2025. Disponível em: <<https://www.londonstockexchange.com/>>. Citado na página 13.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: **ICLR**. [S.l.: s.n.], 2019. Citado na página 37.

MAKRIDAKIS, S.; SPILIOTIS, E.; ASSIMAKOPOULOS, V. Statistical and machine learning forecasting methods: Concerns and ways forward. **PLOS ONE**, 2018. Citado nas páginas 31 e 32.

MISHKIN, F. S.; EAKINS, S. G. **Financial Markets and Institutions**. 9. ed. [S.l.]: Pearson, 2018. ISBN 978-0-13-451926-5. Citado nas páginas 5, 7, 13, 14, 15 e 17.

MURPHY, J. J. **Technical Analysis of the Financial Markets: A Comprehensive Guide to Trading Methods and Applications**. 2. ed. New York: New York Institute of Finance, 1999. ISBN 978-0735200661. Citado nas páginas 15, 16, 17 e 36.

NASCIMENTO, O. S.; SANTOS, F. G.; FERREIRA, K. H. A. Previsão de Preços de Ações Utilizando Inteligência Artificial. Sociedade Brasileira de Computação (SBC), Porto Alegre, RS, Brasil, p. 37–47, 2023. Disponível em: <<https://sol.sbc.org.br/index.php/bwaif/article/view/20485>>. Citado nas páginas 6, 7 e 8.

NASDAQ. **Nasdaq**. s.d. Acesso em: 7 ago. 2025. Disponível em: <<https://www.nasdaq.com/>>. Citado na página 13.

NASIR, M.; ZHANG, W.; WANG, J. Forecasting stock prices using lmd-based hybrid arima-xgboost framework. **Journal of Computational Finance**, v. 29, n. 1, p. 33–55, 2025. Forthcoming. Citado nas páginas 26 e 31.

New York Stock Exchange. **New York Stock Exchange (NYSE)**. s.d. Acesso em: 7 ago. 2025. Disponível em: <<https://www.nyse.com/>>. Citado na página 13.

NIE, Z.; LIU, M.; ZHOU, H.; LI, X.; ZHAO, T.; ZHOU, T.; WEN, Q. Patchtst: Transformer with patch attention for long-term time-series forecasting. In: **Proceedings of the 40th International Conference on Machine Learning (ICML 2023)**. [S.l.: s.n.], 2023. p. 16906–16930. Citado nas páginas 7, 29 e 31.

OLAH, C. **Understanding LSTM Networks**. 2015. <<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>>. Acesso em: 18 ago. 2025. Citado nas páginas 1 e 22.

PHANKOKKRUAD, P.; WORASUWANNARAK, C. Enhancing forex market predictions: A comparative study of candlestick patterns and the middam patterns. **ResearchGate**, 2025. Disponível em: <https://www.researchgate.net/publication/388573821_Enhancing_FOREX_Market_Predictions_A_Comparative_Study_of_Candlestick_Patterns_and_the_MIDDAM_Patterns>. Citado na página 17.

PRADO, M. López de. **Advances in Financial Machine Learning**. [S.l.]: Wiley, 2018. Citado nas páginas 9, 31, 36, 37 e 38.

PRING, M. J. **Technical Analysis Explained: The Successful Investor's Guide to Spotting Investment Trends and Turning Points**. 5. ed. New York: McGraw-Hill Education, 2014. ISBN 978-0071824227. Citado na página 17.

SAID, S. E.; DICKEY, D. A. Testing for unit roots in autoregressive-moving average models of unknown order. **Biometrika**, v. 71, n. 3, p. 599–607, 1984. Citado na página 18.

SHARPE, W. F. The sharpe ratio. **Journal of Portfolio Management**, v. 21, n. 1, p. 49–58, 1994. Citado nas páginas 9 e 38.

SIAMI-NAMINI, S.; NAMIN, A. S. Forecasting economics and financial time series: Arima vs. lstm. **arXiv preprint arXiv:1803.06386**, 2018. Citado nas páginas 27 e 31.

SOUZA, Y. G. V.; TARRATACA, L.; CARDOSO, D. O.; ASSIS, L. S. d. Sentiment analysis applied to ibovespa prediction. In: **Anais do Congresso Brasileiro de Inteligência Computacional (CBIC)**. [S.l.: s.n.], 2022. p. 373–388. Citado nas páginas 7, 8 e 25.

SUNKI, A.; SATYAKUMAR, C.; NARAYANA, G. S.; KOPPERA, V.; HAKEEM, M. Time series forecasting of stock market using arima, lstm and fb prophet. In: **MATEC Web of Conferences - ICMED 2024**. [S.l.: s.n.], 2024. v. 392, p. 01163. Citado na página 7.

TANG, H.; OUTROS. Time series forecasting with llms: Understanding and enhancing preferences and limitations. **KDD Exploration**, 2024. Citado nas páginas 30 e 32.

- TANG, J.; CHEN, S.; GONG, C.; ZHANG, J.; TAO, D. Llm-ps: Empowering large language models for time series forecasting with temporal patterns and semantics. **arXiv preprint**, 2025. Citado nas páginas 30 e 31.
- TAYLOR, S. J.; LETHAM, B. Forecasting at scale. **The American Statistician**, v. 72, n. 1, p. 37–45, 2018. Citado nas páginas 9 e 37.
- TSAY, R. S. **Analysis of Financial Time Series**. 3. ed. Hoboken, NJ: Wiley, 2010. Citado nas páginas 7 e 18.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER Łukasz; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems (NeurIPS 2017)**. [S.l.]: Curran Associates, 2017. p. 5998–6008. Citado nas páginas 1, 22 e 23.
- WEN, Q.; ZHOU, T.; ZHANG, C.; CHEN, W.; MA, Z.; YAN, J.; SUN, L. Transformers in time series: A survey. In: **Proceedings of IJCAI**. [S.l.: s.n.], 2022. Citado nas páginas 6, 7, 9, 28, 31 e 32.
- WOOD, R. A.; MCINISH, T. H.; ORD, J. K. An investigation of transactions data for nyse stocks. **The Journal of Finance**, v. 40, n. 3, p. 723–739, 1985. Citado na página 7.
- WU, H.; LI, J.; YU, R.; JIANG, Y.; LIU, M.; WEN, Q.; YU, Y. Timesnet: Temporal 2d-variation modeling for general time series analysis. In: **Proceedings of the 40th International Conference on Machine Learning (ICML 2023)**. [S.l.: s.n.], 2023. p. 24518–24533. Citado na página 7.
- WU, H.; NAYAK, R.; DARVISHI, A.; SIMON, D.; BEHESHTI, M. Deep learning for time series forecasting: The electric load case. **Energies**, MDPI, v. 13, n. 1, p. 101, 2020. Citado na página 23.
- ZENG, A.; CHEN, M.; ZHANG, L.; XU, Q. Are transformers effective for time series forecasting? **arXiv preprint**, 2022. Citado nas páginas 6, 7, 9, 29 e 31.

GLOSSÁRIO

- Gap — Espaço no gráfico de preços entre dois períodos consecutivos, causado por variação abrupta na cotação.
- Slippage — Diferença entre o preço esperado e o preço efetivo de execução de uma ordem.
- Spread — Diferença entre o preço de compra (bid) e o de venda (ask) de um ativo.
- Survivorship bias — Viés de análise que considera apenas casos que “sobreviveram” a um processo, ignorando os demais.
- Splits – No contexto de mercados financeiros, refere-se à divisão ou agrupamento das ações de uma empresa, alterando o número de papéis em circulação sem modificar o valor total investido.
 - Stock Split (desdobramento): aumenta a quantidade de ações e reduz proporcionalmente o preço unitário.
 - Reverse Split (grupamento) ou Inplits: reduz a quantidade de ações e eleva proporcionalmente o preço unitário.
- Time Zone – No contexto do mercado financeiro, refere-se ao fuso horário adotado para registrar e sincronizar horários de negociações, cotações e eventos relevantes. A correta configuração do *time zone* é essencial para alinhar dados de diferentes bolsas e mercados globais, garantindo precisão na análise temporal e na execução de ordens.
- Candlestick – Tipo de gráfico utilizado no mercado financeiro que representa, por meio de velas, a abertura, fechamento, máxima e mínima dos preços de um ativo em um intervalo de tempo definido.
- Candles – Representações gráficas, no formato de velas (*candlestick*), que mostram abertura, fechamento, máxima e mínima de preços de um ativo em um intervalo de tempo no mercado financeiro.
- Spikes Espúrios – No mercado financeiro, referem-se a variações abruptas e atípicas nos preços de um ativo, geralmente causadas por erros de dados, baixa liquidez ou eventos não representativos das condições reais de mercado.

- **Tick-by-Tick** – No mercado financeiro, refere-se a dados que registram cada alteração de preço e volume negociado de um ativo, fornecendo o histórico completo das negociações em ordem cronológica.
- **Timestamping** – No mercado financeiro, é o processo de registrar com precisão o instante exato em que uma negociação, evento ou dado de mercado ocorre, permitindo análises temporais e sincronização de informações.
- **APIs** – No contexto de mercado financeiro e IA, são interfaces de programação que permitem a integração e troca de dados entre sistemas, possibilitando o acesso automatizado a cotações, históricos, ordens e outros serviços em tempo real.
- **Min-Max Scaler** – No contexto de IA aplicada ao mercado financeiro, é uma técnica de normalização que transforma os dados para um intervalo pré-definido, geralmente entre 0 e 1, preservando as proporções originais. É usada para padronizar variáveis, como preços e indicadores, antes do treinamento de modelos.
- **Z-Score** – No contexto de IA e mercado financeiro, é uma medida de padronização que indica quantos desvios-padrão um valor está distante da média. É utilizada para identificar anomalias, como preços atípicos ou variações incomuns em séries temporais.
- **Walk-Forward** – No contexto de IA e mercado financeiro, é uma técnica de validação em séries temporais que consiste em treinar um modelo em um intervalo de dados e testá-lo no período subsequente, avançando progressivamente no tempo para avaliar seu desempenho de forma contínua.
- **Data Leakage** – No mercado financeiro, é o uso indevido de dados futuros no treinamento de modelos de IA, causando previsões artificialmente precisas e sem validade real.
- **Imputation** – No mercado financeiro e IA, é o processo de preencher valores ausentes em séries temporais, garantindo consistência nos dados para análise ou treinamento de modelos.
- **OHLCV** – No mercado financeiro, sigla para *Open*, *High*, *Low*, *Close* e *Volume*, representando respectivamente abertura, máxima, mínima, fechamento e volume negociado de um ativo em um intervalo de tempo.
- **Bayesiana** – No contexto de IA e mercado financeiro, refere-se a métodos baseados no Teorema de Bayes, que atualizam probabilidades à medida que novas informações se tornam disponíveis, auxiliando na previsão e na tomada de decisão.
- **Dropout** – Em IA aplicada ao mercado financeiro, é uma técnica de regularização em redes neurais que desativa aleatoriamente neurônios durante o treinamento, reduzindo overfitting.
- **Learning Rate** – Em IA aplicada ao mercado financeiro, é o parâmetro que define o tamanho dos ajustes nos pesos da rede neural a cada iteração de treinamento.
- **Early Stopping** – Em IA para mercado financeiro, técnica que interrompe o treinamento ao detectar perda de desempenho em validação, evitando overfitting.
- **Gradient Clipping** – Em IA para mercado financeiro, técnica que limita o valor máximo dos gradientes no treinamento, evitando instabilidade e divergência do modelo.

- Scheduler – Em IA para mercado financeiro, mecanismo que ajusta automaticamente a *learning rate* durante o treinamento para melhorar a convergência do modelo.
- Binary Cross-Entropy – Em IA para mercado financeiro, função de perda usada em classificações binárias, medindo a diferença entre probabilidades previstas e valores reais.
- Drawdown – No mercado financeiro, é a redução percentual do valor de um ativo ou portfólio desde um pico até o menor ponto subsequente.
- backtest – Simulação histórica de uma estratégia sob regras e dados passados.
- Balanced Accuracy - Média de sensibilidade e especificidade; robusta a classes desbalanceadas.
- Banda morta - Zona neutra em torno de um limiar para ignorar microvariações e ruídos de microestrutura.
- Bandas de Bollinger - Envelope ao redor de uma média móvel definido por desvios-padrão, sinalizando volatilidade e possíveis suportes/resistências.
- Acurácia direcional (hit rate) - Proporção de acertos na previsão da direção (alta/baixa) do próximo movimento.
- Bid–ask bounce - Oscilação do preço entre bid e ask sem mudança no valor justo, gerando ruído.
- Bootstrap em blocos - Reamostragem por blocos contíguos para preservar dependência temporal em séries.
- Brier Score - Erro quadrático médio entre probabilidades previstas e resultados binários observados.
- Co-location - Hospedagem de servidores no data center da bolsa para reduzir latência de comunicação.
- Custos de transação - Despesas e fricções (corretagem, emolumentos, spread, slippage) consideradas nos backtests.
- Embargo temporal - Janela de exclusão após o treino para impedir contaminação temporal da validação/teste.
- F1-Score - Média harmônica entre precisão (precision) e revocação (recall).
- Latência - Atraso entre envio/recebimento de dados/ordens e sua efetiva execução/registro.
- Log-Loss - Perda logarítmica usada em classificadores probabilísticos; penaliza confiança indevida.
- LSTM (conceito) - Rede recorrente com memória de longo prazo para dependências temporais extensas.
- Microestrutura de mercado - Aspectos de formação de preço em alta frequência (livro de ofertas, tipos de ordens, latência).
- Otimização Bayesiana - Busca de hiperparâmetros guiada por modelo probabilístico do desempenho.

- Prophet - Modelo aditivo com tendências e sazonalidades marcado para séries temporais.
- Regimes de volatilidade - Estratificação do tempo por níveis de volatilidade para análises de robustez.
- Seed (semente aleatória) - Estado inicial do gerador pseudoaleatório para reprodutibilidade.
- Teste de Diebold–Mariano - Teste estatístico para comparar a acurácia preditiva de dois modelos.
- Transformers - Arquitetura baseada em atenção para dependências de longo alcance sem recorrência.
- Turnover - Taxa de giro da carteira (volume negociado relativo ao capital) em um período.
- Validação walk-forward - Treina e testa em janelas deslizantes preservando a ordem temporal.
- Volatilidade - Grau de oscilação dos preços em um período; associada à dispersão dos retornos.
- Índice de Sharpe - Retorno excedente por unidade de risco (desvio-padrão dos retornos).

SIGLAS

- API - Interface de Programação de Aplicações; permite integração e acesso automatizado a dados/serviços.
- ARIMA - Modelo AutoRegressivo Integrado de Médias Móveis para dependências lineares em séries temporais.
- AUC-PR - Área sob a curva Precisão–Revocação; indicada para classes desbalanceadas.
- CNN - Rede Neural Convolucional que extrai padrões locais em janelas temporais.
- DMA - Direct Market Access; envio de ordens diretamente ao sistema de negociação.
- ECE - Expected Calibration Error; discrepância média entre probabilidades previstas e frequências observadas.
- HFT - High-Frequency Trading; estratégias sensíveis a latências de milissegundos e à microestrutura.
- LSTM - Long Short-Term Memory; rede recorrente com memória de longo prazo.
- MCC - Coeficiente de Correlação de Matthews (−1 a 1) para qualidade de classificação binária.
- MME - Média Móvel Exponencial.
- OHLCV - Abertura (Open), Máxima (High), Mínima (Low), Fechamento (Close) e Volume (Volume).
- RSI - Relative Strength Index; oscilador de momento para sobrecompra/sobre venda.